Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №1

За седьмой семестр

По дисциплине: «Интеллектуальный анализ данных»

Тема: Применение метода главных компонент для визуализации выборки seeds

Выполнил:
Студент 4 курса
Группы ИИ-26(2)
Петручик Д.А.
Проверил:
Никитин

Брест 2026

Метод главных компонент для выборки seeds

1 Условие работы и подготовка данных

Цель работы — применить метод главных компонент PCA для визуализации многомерных данных. По варианту 10 используется архив wholesale+customers.zip; класс задаётся столбцом Region. Требуется независимо получить проекции на первые две и три главные компоненты через numpy.linalg.eig и sklearn.decomposition.PCA, визуализировать классы и оценить потери по собственным значениям.

В архиве находится файл Wholesale customers data.csv: 440 строк и 8 числовых колонок. Столбец Region отделяется в вектор меток, а остальные семь колонок — Channel, Fresh, Milk, Grocery, Frozen, Detergents_Paper и Delicassen — образуют матрицу признаков X размера 440 × 7. Представлены классы Region = 1, Region = 2 и Region = 3, содержащие 77, 47 и 316 объектов соответственно. Метки используются только для цветовых маркеров и не участвуют в центрировании, стандартизации, вычислении ковариации и PCA. Столбец Channel сохраняется в составе признаков.

Файл читается через pandas.read_csv с разделителем-запятой; первая строка содержит названия колонок. Столбец класса выбирается по имени Region независимо от его положения в файле. В исходной выборке нет NaN и бесконечных значений. Для явно заданного пропуска в признаке программа предусматривает замену медианой этого столбца; полностью пустой столбец, пропуск класса и бесконечные значения отклоняются.

Характеристики семи входных колонок

Признак	Среднее	Выборочное s	Минимум	Максимум
X1	1,32273	0,46805	1,0000	2,0000
X2	12000,29773	12647,32887	3,0000	112151,0000
X3	5796,26591	7380,37717	55,0000	73498,0000
X4	7951,27727	9503,16283	3,0000	92780,0000
X5	3071,93182	4854,67333	25,0000	60869,0000
X6	2881,49318	4767,85445	3,0000	40827,0000
X7	1524,87045	2820,10594	3,0000	47943,0000

Стандартизация

Основной эксперимент выполнен после стандартизации, поскольку масштабы исходных столбцов различаются. Например, выборочные стандартные отклонения X1 (Channel) и X2 (Fresh) равны 0,46805 и 12647,32887 соответственно. Центрирование и деление на стандартное отклонение приводят признаки к сопоставимому масштабу. Столбец Region содержит метки классов и в стандартизацию не включается.

$$z_{ij} = (x_{ij} - \mu_j)/s_j; \quad \mu_j = (1/n)\Sigma_i x_{ij}$$

$$s_j{}^2 = (1/(n-1))\Sigma_i(x_{ij} - \mu_j)^2; \quad n = 440$$

Используется выборочное стандартное отклонение, ddof = 1. После преобразования средние

равны нулю с точностью численных вычислений, выборочные дисперсии равны единице, а суммарная дисперсия семи признаков равна 7. Оба способа PCA — через numpy.linalg.eig и sklearn.decomposition.PCA — получают одну и ту же подготовленную матрицу Z размера 440 × 7

Ручной способ через собственные значения

По стандартизованной матрице Z строится симметричная ковариационная матрица S размера 7 × 7. Функция numpy.linalg.eig возвращает её собственные значения и собственные векторы. Значения сортируются по убыванию; соответствующие столбцы матрицы собственных векторов переставляются в том же порядке.

$$S = Z^{\mathrm{T}}Z/(n-1);\ \ Sv_{\mathrm{j}} = \lambda_{\mathrm{j}}v_{\mathrm{j}};\ \ \lambda_1 \geq \lambda_2 \geq \ldots \geq \lambda_7$$

$$V_{\mathrm{k}} = [v_1 \ldots v_{\mathrm{k}}];\ \ T_{\mathrm{k}} = ZV_{\mathrm{k}};\ \ k \in \{2,3\}$$

Матрица T_2 имеет размер 210 × 2, T_3 — 210 × 3, 440 × 3 . Их строки задают координаты объектов на графиках. Проверяются отсутствие значимой мнимой части, неотрицательность спектра с учётом округления и ортонормированность базиса. Отбрасывание компонент с малыми собственными значениями уменьшает размерность с наименьшей квадратичной ошибкой в выбранном масштабе.

Библиотечный способ

Для каждой размерности отдельно создаётся sklearn.decomposition.PCA(n_components=k, svd_solver="full", whiten=False) и вызывается fit_transform(Z). Библиотечное решение использует полное сингулярное разложение подготовленной матрицы. Собственные значения, векторы или координаты из ручного решения в PCA не передаются. Whitening отключён, чтобы сохранить обычный масштаб главных компонент.

Знаки и сравнение решений

Векторы v и −v задают одну ось, поэтому два правильных решения могут различаться знаками координат. Для каждой компоненты в каждом решении независимо выбирается знак, при котором наибольший по модулю коэффициент положителен. После этого сравниваются координаты. Дополнительно сравниваются собственные значения и проекторы $V_kV_k^T$, не зависящие от знаков векторов.

Расчёт потерь

$$D_{\mathrm{k}} = \Sigma_{\mathrm{j}=\mathrm{k}}\mathrm{h}_1{}^7\,\lambda_{\mathrm{j}};\ \ L_{\mathrm{k}} = D_{\mathrm{k}}/(\Sigma_{\mathrm{j}=1}{}^7\,\lambda_{\mathrm{j}})\cdot 100\%$$

$$R_{\mathrm{k}} = 100\% - L_{\mathrm{k}};\ \ Z\,\hat{}_{\mathrm{k}} = T_{\mathrm{k}}V_{\mathrm{k}}{}^{\mathrm{T}}$$

$$SSE_{\mathrm{k}} = \|Z - Z\,\hat{}_{\mathrm{k}}\|^2 = (n-1)D_{\mathrm{k}};\ \ MSE_{\mathrm{k}} = SSE_{\mathrm{k}}/(n\cdot 7)$$

D_k — отброшенная дисперсия, L_k — доля потерянной дисперсии, R_k — сохранённая доля. SSE суммирует квадраты отклонений всех 3080 элементов матрицы; MSE усредняет их. Потери относятся к стандартизованным признакам, а не к проценту неверных классов и не ко всей возможной информации о данных.

3 Собственные значения и численные результаты

Собственные значения вычислены по полной стандартизованной выборке. Все семь значений положительны. Сумма равна 7 с точностью вычислений. Доля отдельной компоненты равна $\lambda_j/7$; накопленная доля определяется суммой первых компонент.

Компонента	λ	Доля дисперсии, %	Накопленная доля, %
PC1	3,098727277	44,267533	44,267533
PC2	1,788500919	25,550013	69,817546
PC3	0,740158773	10,573697	80,391242
PC4	0,564919796	8,070283	88,461525
PC5	0,463399953	6,619999	95,081525
PC6	0,281500933	4,021442	99,102966
PC7	0,062792349	0,897034	100,000000

Сравнение сохранённой дисперсии и потерь

k	Способ	Сохранено, %	Потеряно, %
2	NumPy eig	69,817546	30,182454
2	sklearn PCA	69,817546	30,182454
3	NumPy eig	80,391242	19,608758
3	sklearn PCA	80,391242	19,608758

k	D_k	SSE_k	MSE_k
2	2,112772	927,506822	0,301138579
3	1,372613	602,577121	0,195641922

Две главные компоненты сохраняют около 69,82% общей дисперсии, три — около 80,39%. Добавление третьей компоненты увеличивает сохранённую долю примерно на 10,57 процентного пункта и уменьшает ошибку восстановления. Для сохранения не менее 95% дисперсии необходимо оставить пять главных компонент.

Результаты ручного и библиотечного способов совпадают с точностью вычислений. Максимальное расхождение координат после согласования знаков собственных векторов составляет около $1{,}62 \cdot 10^{-14}$.

4 Визуализация первых главных компонент

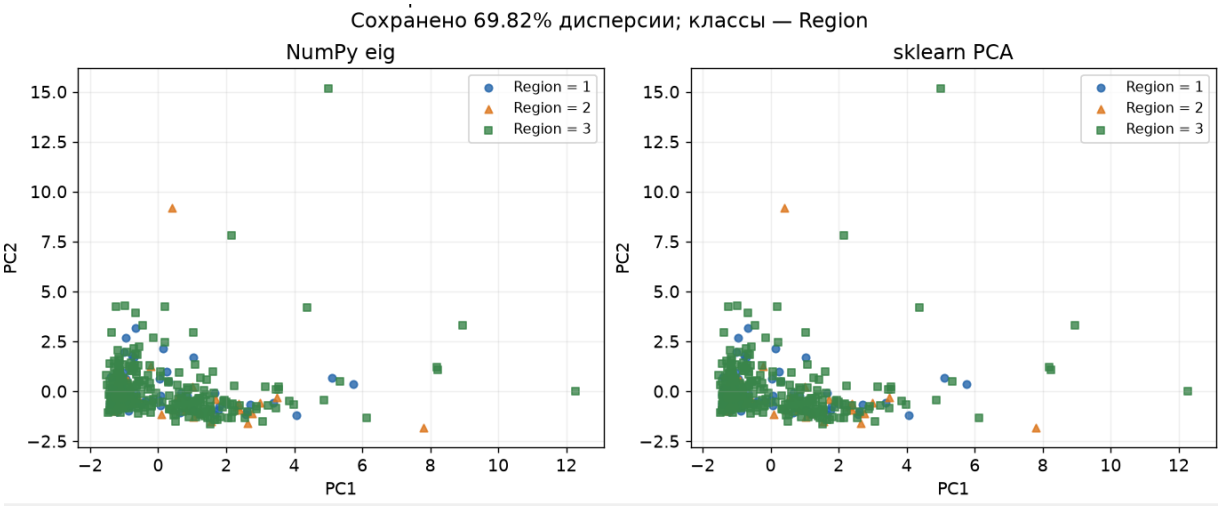


Рисунок 1 — Проекция на первые две компоненты двумя способами

На плоскости PC1–PC2 представлены проекции клиентов Wholesale Customers на первые две главные компоненты. Цвет маркеров обозначает принадлежность объектов к одному из трёх регионов — Region 1, 2 или 3. Эти компоненты сохраняют около 69,82% общей дисперсии стандартизованных признаков. Метки Region не участвуют в вычислении главных компонент: PCA определяет направления наибольшей дисперсии данных и не оптимизирует разделение регионов, поэтому точки разных классов могут перекрываться.

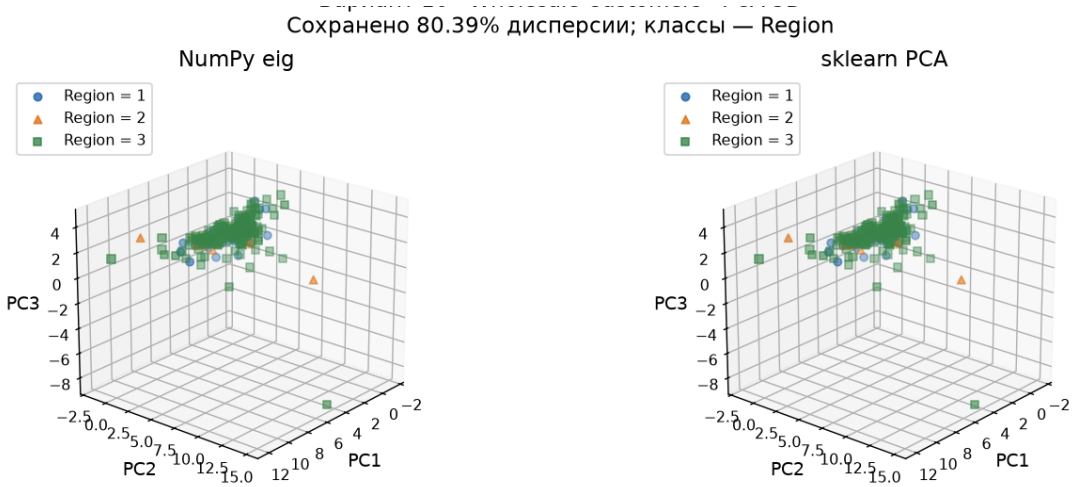


Рисунок 2 — Проекция на первые три компоненты двумя способами

Добавление третьей главной компоненты PC3 увеличивает долю сохранённой дисперсии до 80,39% и уменьшает потери с 30,18% до 19,61%. В пространстве первых трёх компонент точки разных регионов существенно перекрываются; также видны отдельные объекты, удалённые от основного скопления. Для сопоставления двух способов заданы одинаковые пределы осей, цветовые маркеры и ракурс. Проекции NumPy eig и sklearn PCA визуально совпадают, что согласуется с численными результатами сравнения. При запуске программы в интерактивном окне matplotlib пространственный график можно вращать мышью.

5 Интерпретация спектра и влияние масштаба

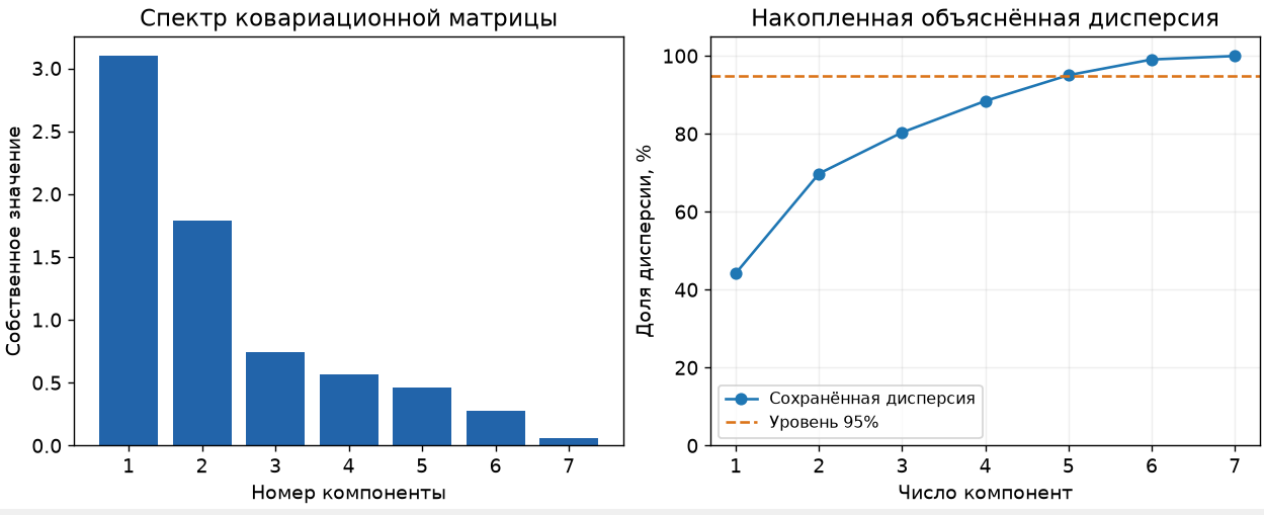


Рисунок 3 — Спектр и накопленная объяснённая дисперсия

PC1 содержит 44,267533% стандартизованной дисперсии; PC2 — 25,550013%; PC3 — 10,573697%. Первые три компоненты суммарно сохраняют 80,391242% дисперсии, а оставшиеся четыре — 19,608758%. Таким образом, переход от семи признаков к трём позволяет отобразить значительную часть изменчивости данных, однако сопровождается потерей около 19,61% дисперсии. Для сохранения не менее 95% дисперсии необходимо использовать пять главных компонент.

Коэффициенты первых трёх компонент

Признак	PC1	PC2	PC3
X1	0,4281	-0,2057	-0,0158
X2	-0,0260	0,5124	0,8087
X3	0,4744	0,2066	-0,0558
X4	0,5367	-0,0072	0,1138
X5	-0,0300	0,5947	-0,1811
X6	0,5244	-0,1195	0,1419
X7	0,1645	0,5333	-0,5261

PC1 в основном объединяет признаки Grocery, Detergents_Paper, Milk и Channel с положительными коэффициентами. Во второй компоненте наибольшие по модулю коэффициенты имеют Frozen, Delicassen и Fresh, причём все они положительны. В третьей компоненте наиболее заметны Fresh и Delicassen с противоположными знаками. Приведены коэффициенты нормированных собственных векторов для стандартизованных признаков; знак каждого вектора выбран так, чтобы его наибольшая по модулю координата была положительной.

Дополнительный расчёт без стандартизации

Подготовка	Потери при k = 2, %	Потери при k = 3, %
Центрирование и деление на s	30,182454	19,608758
Только центрирование	13,521412	6,518403

5 Интерпретация спектра и влияние масштаба

Без деления на выборочное стандартное отклонение s две компоненты сохраняют 86,478588% исходной суммарной дисперсии, а три — 93,481597%. Это не означает, что такой вариант лучше сохраняет все признаки: в исходной шкале признаки с большими дисперсиями имеют больший вес. Проценты потерь при разных способах подготовки относятся к разным метрикам. Для стандартизованных данных три компоненты сохраняют 80,391242% дисперсии и позволяют построить пространственную визуализацию, однако для сохранения не менее 95% дисперсии необходимы пять компонент. Программа также позволяет воспроизвести вариант с одним центрированием.

Проверки реализации

В программе предусмотрены автоматические проверки размера матрицы 440 × 7, распределения объектов по классам Region: 77, 47 и 316 соответственно, а также отсутствия пропусков во встроенной выборке. Проверяются нулевые средние после центрирования, единичные выборочные дисперсии после стандартизации, равенство $Sv_j = \lambda_j v_j$, ортонормированность собственных векторов и восстановление полной матрицы при сохранении всех семи компонент.

Для $k = 2$ и $k = 3$ проверяются согласованность ручного и библиотечного решений и равенство ошибки реконструкции сумме отброшенных собственных значений с множителем $n - 1$. Проверки PCA выполняются как со стандартизацией, так и при одном центрировании. Дополнительно проверяются загрузка CSV и ZIP, независимость матрицы признаков от меток Region и порядка столбцов, а также замена искусственно добавленного NaN медианой соответствующего признака.

6 Вывод

Метод PCA реализован двумя независимыми способами. Результаты numpy.linalg.eig и sklearn.decomposition.PCA совпали с точностью до численных погрешностей, что подтверждено сравнением собственных значений, проекторов, координат и ошибок реконструкции.

Для стандартизованной выборки Wholesale Customers проекция 7 → 2 сохраняет 69,82% дисперсии и теряет 30,18%; проекция 7 → 3 сохраняет 80,39% и теряет 19,61%. Двумерная проекция удобна для обзорного изображения, а трёхмерная сохраняет больше дисперсии и уменьшает ошибку восстановления. При этом три компоненты не достигают ориентира 95%: для этого необходимо сохранить пять компонент.

На графиках точки трёх классов Region существенно перекрываются, поэтому чёткого разделения клиентов по регионам не наблюдается. PCA не использует метки классов, а доля сохранённой дисперсии не является точностью классификации. Выбор масштаба признаков существенно влияет на спектр и численные потери: при одном центрировании две и три компоненты сохраняют соответственно 86,48% и 93,48% дисперсии. Эти значения относятся к исходной шкале признаков, поэтому способ подготовки данных необходимо указывать вместе с результатами PCA.