Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №2

За седьмой семестр

По дисциплине «Интеллектуальный анализ данных»

Автоэнкодеры и визуализация рукописных цифр

Выполнил:
Студент 4 курса
Группы ИИ-26(2)
Петручик Д.А.

Проверил:
Никитин С.К.

Брест 2026

1 Условие работы и подготовка данных

Цель работы — сравнить полносвязный автоэнкодер, t-SNE и PCA при снижении размерности до двух и трёх координат. Для варианта 10 используется выборка Optical Recognition of Handwritten Digits.

Файл optdigits.tra содержит 3823 объекта и 65 столбцов. Первые 64 столбца — признаки, последний — класс цифры от 0 до 9. Метки используются только для раскраски и обозначения точек; они не участвуют в обучении и выборе параметров. Пропусков и бесконечных значений нет.

Таблица 1 — Распределение классов

Класс	Число объектов	Доля, %
0	376	9,84
1	389	10,18
2	380	9,94
3	389	10,18
4	387	10,12
5	376	9,84
6	377	9,86
7	387	10,12
8	380	9,94
9	382	9,99

Каждый объект представляет матрицу 8 × 8, развёрнутую в вектор. Её элементы — количества закрашенных пикселей в блоках 4 × 4 исходного изображения 32 × 32. Все значения целые, от 0 до 16 [1].

Стандартизация и схема эксперимента

Для каждого признака вычисляются среднее и выборочное стандартное отклонение. Нулевой масштаб заменяется единицей. В полной выборке признаки 1 и 40 постоянны; после центрирования они равны нулю. Единичная дисперсия проверяется только у непостоянных столбцов.

$$z_{ij} = \frac{x_{ij} - \mu_j}{s_j}; \quad {s_j}^2 = \frac{\sum_{i=1}^{n} \left(x_{ij} - \mu_j\right)^2}{n - 1}$$

Случайная перестановка np.random.default_rng(42) задаёт 2293 обучающих, 765 валидационных и 765 тестовых объектов. При подборе сети стандартизация обучается только на обучающей части. Модель выбирается только по валидационной MSE; тестовая ошибка в выборе не используется. Это внутреннее разбиение optdigits.tra; файл optdigits.tes не используется.

Для итоговых визуализаций параметры стандартизации вычисляются заново по всем 3823 объектам. Выбранные сети повторно обучаются на полной выборке столько эпох, сколько определила валидация. PCA и t-SNE получают эту же полную стандартизованную матрицу.

2 Модель автоэнкодера

Кодировщик сжимает 64 признака до k скрытых координат, декодировщик восстанавливает вход. Для k = 2 и k = 3 обучаются отдельные сети из слоёв torch.nn.Linear. Внутренние скрытые слои используют ReLU, узкий слой и выход декодировщика линейны: стандартизованные признаки и скрытые координаты могут быть отрицательными.

$$h = f_\theta(z), \quad \hat{z} = g_\varphi(h), \quad h \in \mathbb{R}^k, \quad k \in \{2, 3\}$$

$$MSE = \frac{\sum_{i=1}^{n} \sum_{j=1}^{64} (z_{ij} - \hat{z}_{ij})^2}{n \cdot 64}$$

Минимизируется средняя квадратичная ошибка восстановления. Использован Adam: β_1 = 0,9, β_2 = 0,999, $\varepsilon = 10^{-8}$; weight decay = 0. Каждая эпоха включает один шаг по всей обучающей части. Сеть обучается на CPU в float32 с одним потоком и детерминированными алгоритмами; стандартизация и PCA вычисляются в float64.

Экспериментальный подбор параметров

Проверены архитектуры 64–32–k–32–64 и 64–64–32–k–32–64–64 со скоростями обучения 0,001 и 0,003. Максимум — 1500 эпох. При отсутствии уменьшения валидационной MSE в течение 150 эпох обучение останавливается; сохраняются веса лучшей эпохи.

Таблица 2 — Подбор автоэнкодера

k	Скрытые слои кодировщика	Скорость обучения	Лучшая эпоха	MSE обучения	MSE валидации
2	32	0,001	1427	0,409882	0,417330
2	32	0,003	906	0,396982	0,431069
2	64–32	0,001	667	0,360834	0,398054
2	64–32	0,003	403	0,323460	0,406868
3	32	0,001	1500	0,321702	0,363010
3	32	0,003	1490	0,307800	0,360309
3	64–32	0,001	968	0,246897	0,293708
3	64–32	0,003	540	0,243657	0,292776

Для k = 2 выбрана сеть 64-64-32-2-32-64-64, скорость обучения 0,001, эпоха 667. Валидационная MSE равна 0,398054, тестовая — 0,423512.

Для k = 3 выбрана сеть 64-64-32-3-32-64-64, скорость обучения 0,003, эпоха 540. Валидационная MSE равна 0,292776, тестовая — 0,333132.

Выбор оптимален только среди проверенных комбинаций при seed = 42. Один запуск и одно разбиение не позволяют оценить устойчивость результата к другой инициализации или составу выборки.

3 Обучение и скрытое представление

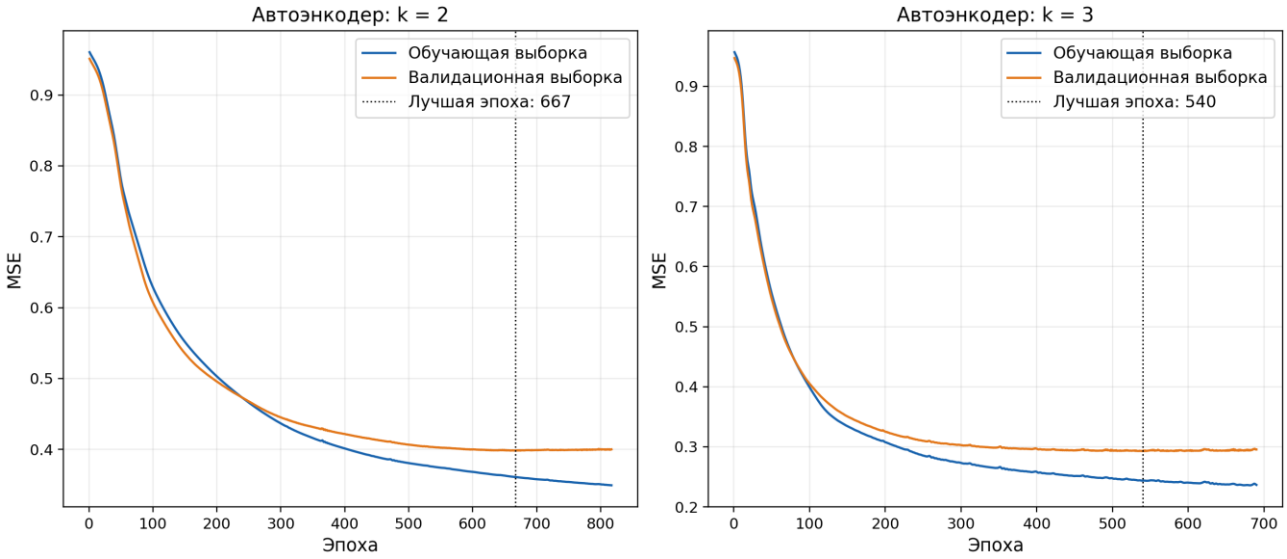


Рисунок 1 — Кривые обучения выбранных автоэнкодеров

Кривые показывают MSE обучения и валидации, пунктир отмечает выбранную эпоху. Для итоговых проекций сеть повторно обучается на полной выборке, поэтому график подбора и скрытые координаты относятся к разным этапам эксперимента.

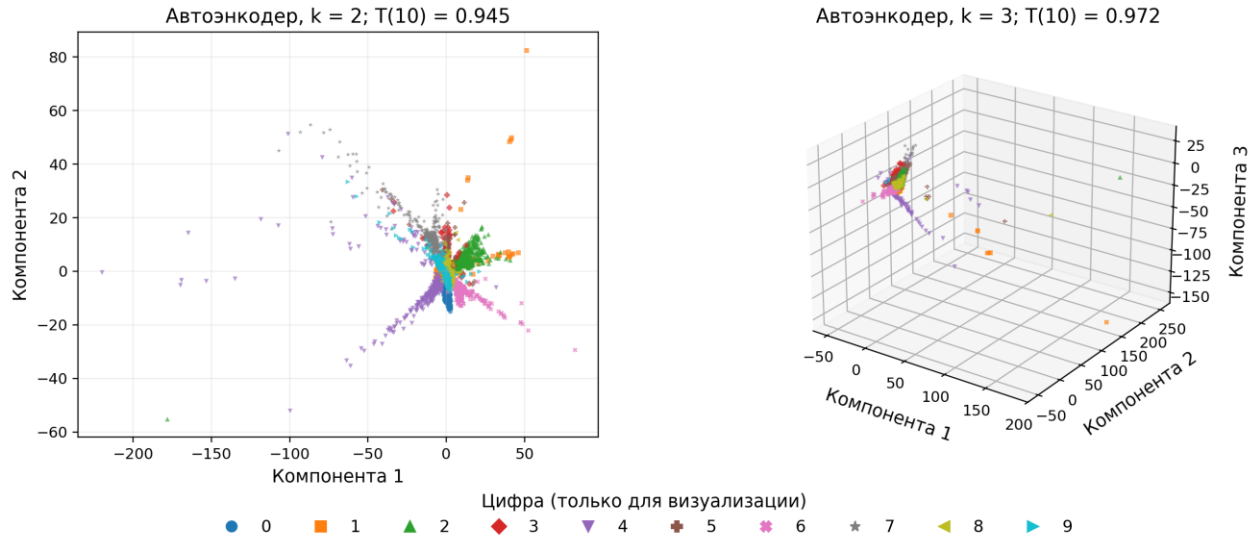


Рисунок 2 — Двумерное и трёхмерное представления автоэнкодера

Десять цветов и форм маркеров соответствуют цифрам 0–9. Проекции отражают различия, полезные для восстановления признаков. Группы частично перекрываются. Отдельные объекты с крайними координатами растягивают масштаб осей; все 3823 точки сохранены. Визуальные группы сами по себе не оценивают точность классификации.

Координаты кодировщика h_1, h_2 и h_3 являются обученными скрытыми признаками. Они не обязаны быть ортогональными или упорядоченными по дисперсии. Двумерная модель обучена отдельно, а не получена отбрасыванием третьей координаты.

4 Визуализация методом t-SNE

t-SNE сопоставляет вероятностные соседства исходных объектов и их низкоразмерного представления, минимизируя KL-дивергенцию. Использована sklearn.manifold.TSNE: init="pca", learning_rate="auto", max_iter=1500, method="barnes_hut", random_state=42 [2].

Для каждой размерности проверены perplexity = 20, 40 и 60. Параметр задаёт масштаб локального соседства. Все запуски получают одинаковые 64 стандартизованных признака. Метки цифр не используются при расчёте проекций и выборе perplexity.

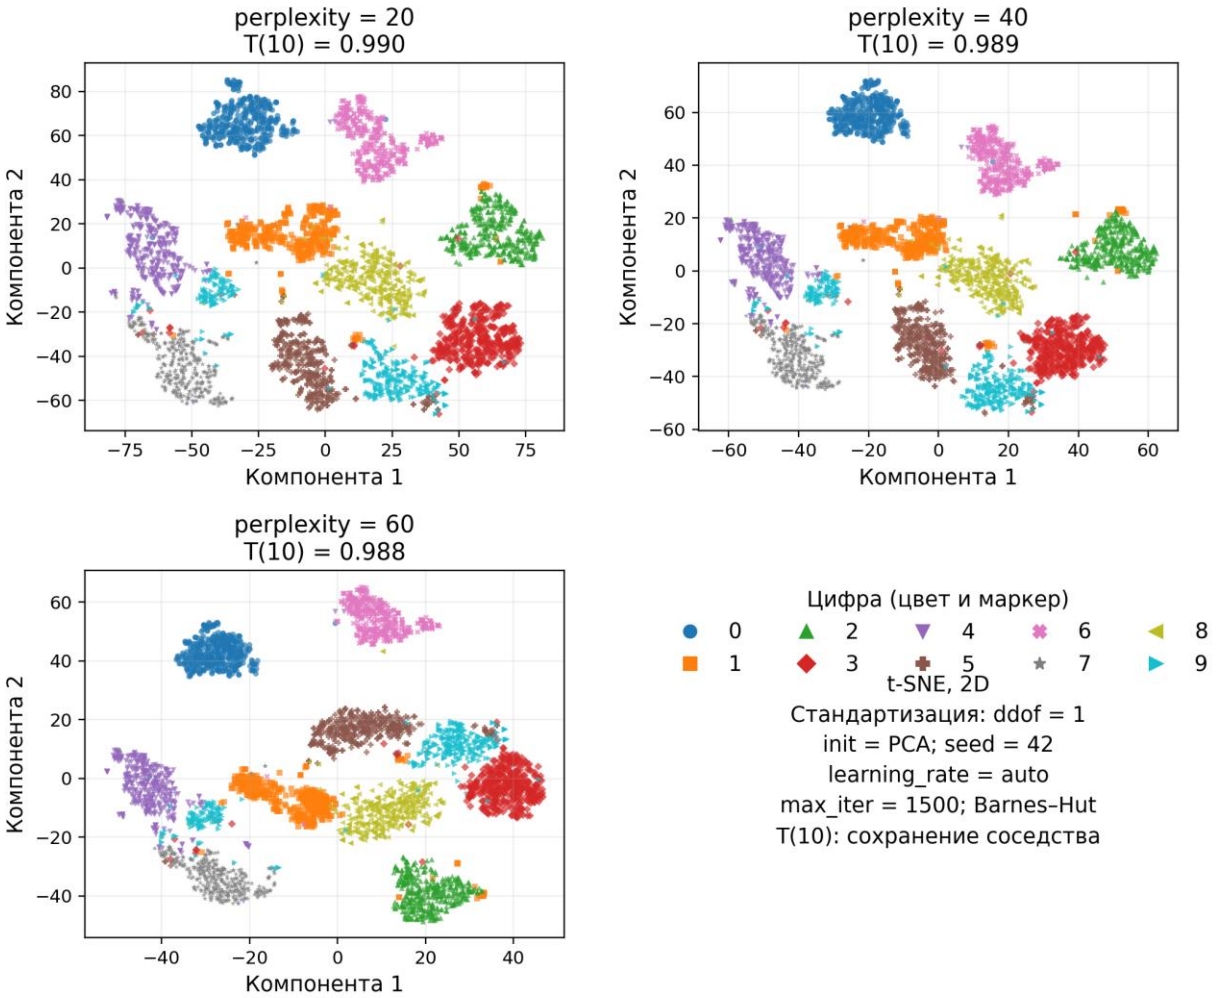


Рисунок 3 — Влияние perplexity на двумерную визуализацию t-SNE

По trustworthiness T(10) выбран perplexity = 20: T(10) = 0,989905. T(10) штрафует ложных соседей среди десяти ближайших точек проекции с учётом их рангов в исходном пространстве; расстояние евклидово. Чем ближе значение к 1, тем лучше сохраняются локальные соседства.

Изменение perplexity меняет форму групп. Расстояния между отдельными группами, их относительные размеры и ориентацию осей нельзя непосредственно трактовать как геометрию исходного пространства.

5 Трёхмерный t-SNE и оценка соседств

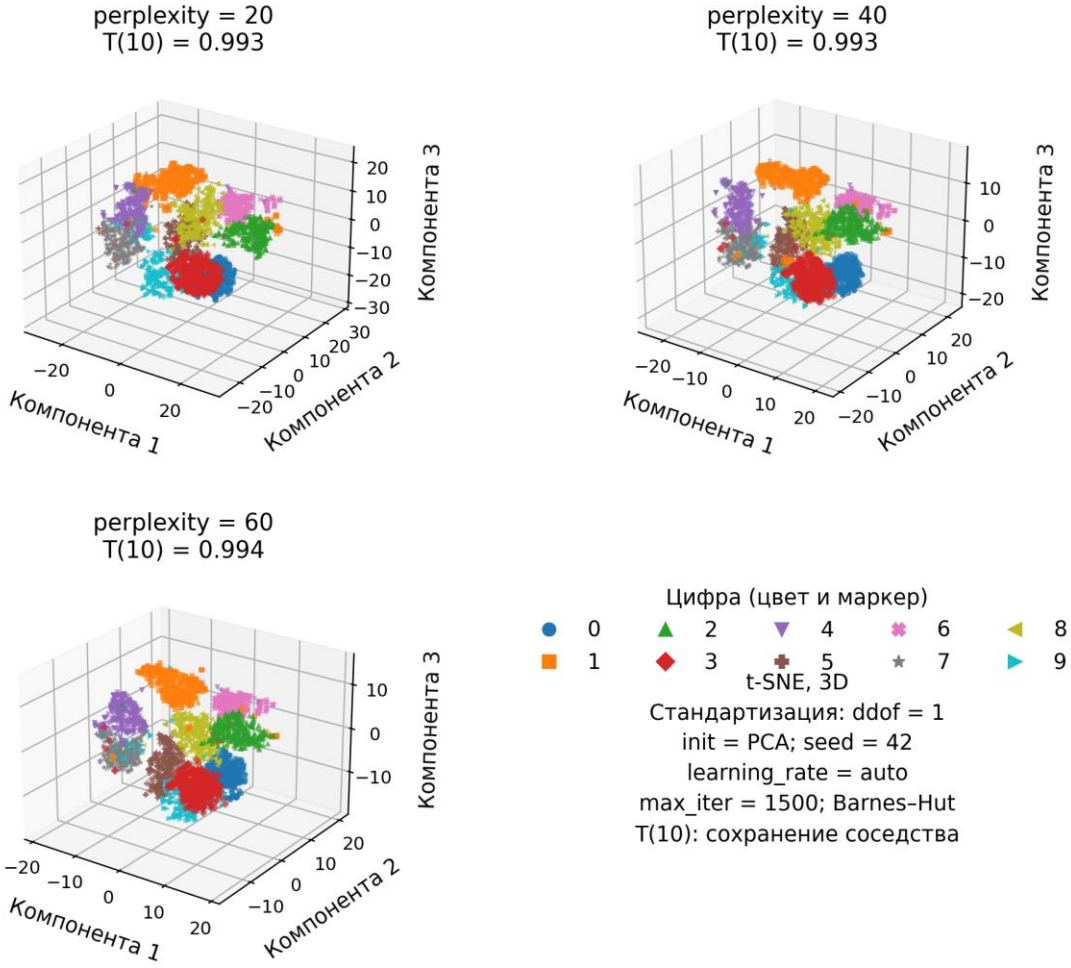


Рисунок 4 — Влияние perplexity на трёхмерную визуализацию t-SNE

Таблица 3 — Метрики шести запусков t-SNE

Размерность	Perplexity	KL-дивергенция	T(10)
2	20	1,174779	0,989905
2	40	1,050652	0,988695
2	60	0,965510	0,987722
3	20	1,031665	0,992703
3	40	0,899141	0,993425
3	60	0,813757	0,994053

Для трёх координат выбран perplexity = 60: T(10) = 0,994053. Выбор сделан по соседствам, без меток классов. При разных perplexity изменяются исходные вероятности, поэтому сравнение значений KL само по себе не определяет лучший вариант.

Для t-SNE здесь нет декодировщика, поэтому MSE восстановления и доля объяснённой дисперсии не рассчитываются. Реализация sklearn TSNE не предоставляет transform для новых объектов [2].

6 Применение метода главных компонент

Ручной PCA строит ковариационную матрицу стандартизованных данных. Собственные значения и векторы вычисляются функцией numpy.linalg.eigh, предназначенной для симметричных матриц, затем сортируются по убыванию значений. Первые k векторов образуют ортонормированный базис проекции.

$$S = \frac{Z^T Z}{n - 1}; \quad T_k = ZV_k; \quad \hat{Z}_k = T_k V_k{}^T$$

$$R_k = 100 \cdot \frac{\sum_{j=1}^{k} \lambda_j}{\sum_{j=1}^{64} \lambda_j}\%$$

Результат сопоставлен со sklearn.decomposition.PCA(svd_solver="full"). Из-за произвольного знака собственного вектора сравниваются проекторы $V_k V_k{}^T$ и спектры. Для отдельной тестовой оценки PCA обучается на обучающей части средствами sklearn. Два постоянных признака дают нулевую дисперсию; сумма собственных значений полной матрицы равна 62.

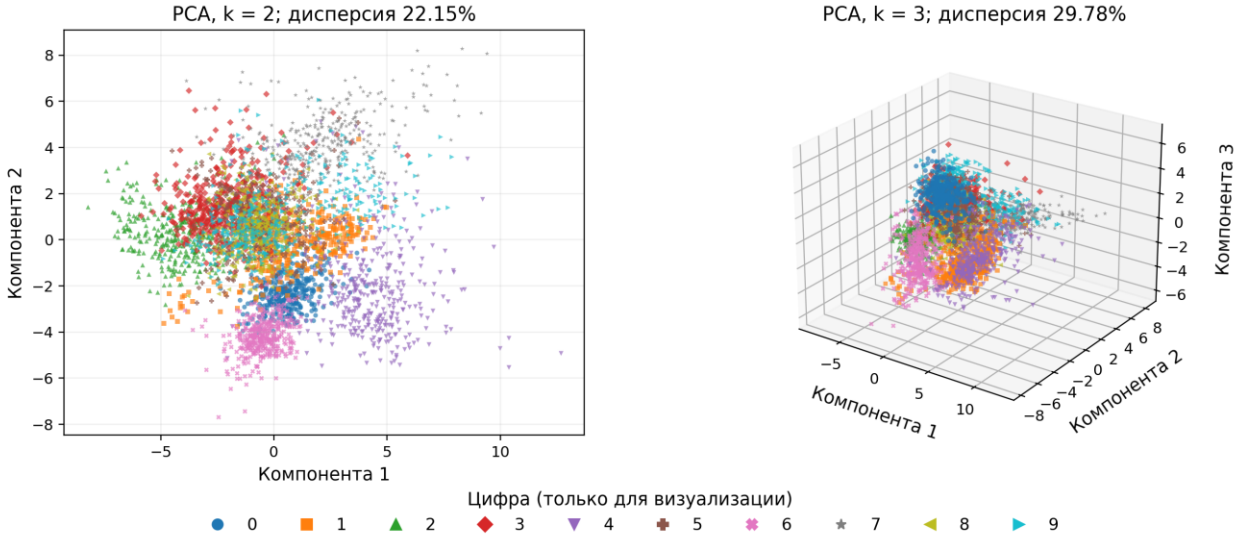


Рисунок 5 — Проекции рукописных цифр на две и три главные компоненты

Таблица 4 — Сохранение дисперсии и восстановление PCA

k	Сохранено, %	Потеряно, %	MSE полной выборки
2	22,1548	77,8452	0,753928
3	29,7812	70,2188	0,680066

Две компоненты сохраняют 22,15% стандартизованной дисперсии, три — 29,78%. Третья добавляет 7,63 процентного пункта. Это характеристика сжатия признаков, а не точность распознавания цифр.

Проверено равенство MSE сумме отброшенных собственных значений, умноженной на (n − 1)/(n · 64). В знаменателе остаются все 64 входных признака, включая постоянные.

7 Сравнение методов

Таблица 5 — Сопоставление качества сжатия и соседств

Метод	k	MSE полной выборки	MSE теста	T(10) полной выборки
PCA	2	0,753928	0,675603	0,813095
Автоэнкодер	2	0,357328	0,423512	0,945025
t-SNE p=20	2	—	—	0,989905
PCA	3	0,680066	0,606045	0,902813
Автоэнкодер	3	0,253438	0,333132	0,972375
t-SNE p=60	3	—	—	0,994053

MSE полной выборки относится к моделям, обученным на всех 3823 объектах с полной стандартизацией. MSE теста вычислена на 765 отложенных объектах; модели и масштабы обучены только на 2293 объектах. Сравнивать методы следует внутри одного столбца: различие между полной и тестовой MSE не объясняется только переобучением.

При k = 2 тестовая MSE автоэнкодера равна 0,423512, PCA — 0,675603. В данном разбиении ошибка автоэнкодера на 37,31% меньше. Этот результат относится к выбранной архитектуре, параметрам и инициализации.

При k = 3 тестовая MSE автоэнкодера равна 0,333132, PCA — 0,606045. В данном разбиении ошибка автоэнкодера на 45,03% меньше. Этот результат относится к выбранной архитектуре, параметрам и инициализации.

Интерпретация различий

PCA даёт упорядоченные ортогональные направления и точную оценку потерянной дисперсии. Его оптимальность по квадратичной ошибке относится к линейным ортогональным проекциям; нелинейный автоэнкодер может дать меньшую ошибку.

Автоэнкодер предоставляет кодировщик и декодировщик: новые объекты можно стандартизовать сохранёнными параметрами и преобразовать сетью. Такая гибкость требует подбора архитектуры и обучения. MSE и T(10) оценивают разные свойства, поэтому меньшая ошибка восстановления не гарантирует лучшего сохранения соседств.

t-SNE предназначен прежде всего для изучения локальных групп. Его оси не являются главными компонентами, а качество рисунка на всей выборке не оценивает работу на независимых новых данных. При интерпретации необходимо учитывать perplexity и инициализацию.

Тестовая часть не участвовала в выборе сети. Оценка выполнена на одном фиксированном разбиении без доверительных интервалов. Классификатор не обучался; выводы о точности распознавания цифр по этим графикам не делаются.

Выводы

Выполнено снижение размерности Optical Recognition of Handwritten Digits с 64 признаков до двух и трёх координат. Построены отдельные представления автоэнкодера, t-SNE и PCA; во всех графиках цифры 0–9 обозначены едиными цветами и формами маркеров.

Архитектура, скорость обучения и число эпох автоэнкодера выбраны по валидационной ошибке. Для каждой размерности рассмотрены четыре комбинации архитектуры и скорости обучения. Тестовая ошибка не использовалась при выборе модели. Финальные изображения построены после повторного обучения на полной выборке.

На тестовой части MSE автоэнкодера составила 0,423512 для двух и 0,333132 для трёх скрытых координат. Эти значения характеризуют восстановление признаков и не являются метрикой классификации.

Для t-SNE исследованы perplexity 20, 40 и 60. По T(10) выбраны 20 для двумерного и 60 для трёхмерного представления. Геометрия визуализации зависит от масштаба соседства; расстояния между группами не трактуются как точные расстояния исходного пространства.

PCA сохраняет 22,15% дисперсии при двух компонентах и 29,78% при трёх. Увеличение размерности уменьшает ошибку восстановления, однако сохраняется только часть информации 64 исходных признаков.

Выбор метода зависит от цели: PCA удобен для линейного сжатия с интерпретируемыми потерями, автоэнкодер — для нелинейного кодирования и восстановления, t-SNE — для локальной визуализации. Качество восстановления, сохранение соседств и визуальное разделение классов — разные критерии.