Министерство образования Республики Беларусь

Учреждение образования

«Брестский государственный технический университет»

Кафедра ИИТ

Лабораторная работа №3

По дисциплине «Интеллектуальный анализ данных»

Тема: «Предобучение нейронных сетей
с использованием автоэнкодерного подхода»

Выполнил:
Студент 4 курса
Группы ИИ-26
Петручик Д.А.
Проверила:
Никитин

Брест 2026

Цель работы

Цель работы: освоить послойное предобучение глубоких нейронных сетей с помощью автоэнкодеров и сравнить его с обучением сети со случайной инициализацией весов.

Для моего варианта решена задача регрессии Appliances. Пункт 4 выполнен на наборе Optical Recognition of Handwritten Digits из ЛР2: использован файл optdigits.tra, целевая переменная взята из последнего столбца.

Параметр	Вариант 10	Набор из ЛР2
Набор данных	Appliances Energy Prediction	Optical Recognition of Handwritten Digits
Исходный файл	energydata_complete.csv	optdigits.tra
Тип задачи	Регрессия	Классификация
Целевая переменная	Appliances, Вт·ч	Последний столбец, цифра 0–9
Число объектов	19 735	3 823
Вход сети	29 подготовленных признаков	64 значения изображения 8 × 8
Пропуски	0	0

Выполненные этапы

1. Обучены полносвязные сети с четырьмя скрытыми слоями и отдельным выходным слоем без предобучения.

2. Для всех скрытых слоёв последовательно обучены автоэнкодеры. Затем обучен выходной слой и выполнена точная настройка всей сети.

3. На отдельной тестовой части рассчитаны метрики, построены графики и матрицы ошибок. Для каждого режима проведено три запуска с seed 42, 43 и 44.

4. Та же схема сравнения применена к данным ЛР2. Исходный код, данные и результаты сохранены в комплекте работы.

Основной результат

На Appliances средняя RMSE уменьшилась с 92,01 до 89,58 Вт·ч, но MAE выросла с 60,87 до 61,07 Вт·ч. На цифрах средняя Accuracy снизилась с 0,9656 до 0,9586. Следовательно, в данном эксперименте предобучение не обеспечило общего улучшения качества.

Подготовка данных

Appliances Energy Prediction

Данные упорядочены по времени. Для оценки переноса на более поздний период выделены последовательные обучающая, валидационная и тестовая части. Модели оценивают потребление по признакам того же временного шага; это регрессия на отложенном периоде, а не прогноз с заданным горизонтом вперёд.

Часть	Объекты	Начало	Конец
Обучение	13814	2026-01-11 17:00	2026-04-16 15:10
Валидация	2960	2026-04-16 15:20	2026-05-07 04:30
Тест	2961	2026-05-07 04:40	2026-05-27 18:00

Из исходных столбцов исключены цель Appliances, строковая дата и случайные признаки rv1, rv2. Оставшиеся 25 числовых признаков дополнены синусом и косинусом часа суток и дня недели. Получены 29 входных признаков. Параметры StandardScaler для X и цели вычислены только по обучающей части; метрики рассчитаны после обратного преобразования цели.

Диапазон Appliances составляет 10–1080 Вт·ч, среднее по набору равно 97,69 Вт·ч. Нулевых значений цели нет, поэтому MAPE определена для всех тестовых объектов.

Optical Recognition of Handwritten Digits

Прочитан optdigits.tra без заголовка: первые 64 столбца содержат значения от 0 до 16, 65-й столбец содержит класс. Признаки разделены на 16. Это фиксированное преобразование диапазона, не требующее обучения на данных. Файл optdigits.tes в эксперименте не используется.

Часть	Объекты	Способ выделения
Обучение	2446	80% от оставшихся после выделения теста
Валидация	612	20% от оставшихся после выделения теста
Тест	765	20% исходного optdigits.tra

Оба разбиения выполнены с сохранением долей классов, random_state=42. Индексы объектов одинаковы для всех моделей и сохранены отдельно. Случайные разбиения внутри tra оценивают качество на новых объектах этой выборки; принадлежность изображения автору при таком разделении не контролируется.

Цифра	0	1	2	3	4	5	6	7	8	9
Весь tra	376	389	380	389	387	376	377	387	380	382
Тест	75	78	76	78	78	75	75	78	76	76

Архитектура и алгоритм предобучения

Параметр	Регрессия	Классификация
Размеры слоёв	29 → 64 → 32 → 16 → 8 → 1	64 → 128 → 64 → 32 → 16 → 10
Обучаемых параметров	4673	19354
Скрытые активации	ReLU	ReLU
Выход	Одно линейное значение	10 логитов; класс = argmax
Потери с учителем	MSE стандартизованной цели	CrossEntropyLoss

Каждая архитектура содержит пять полносвязных обучаемых слоёв, что выполняет условие «более 3». Для классификации softmax не добавляется перед CrossEntropyLoss: эта функция принимает логиты и сама выполняет необходимое преобразование.

Послойное обучение по алгоритму лекции

1. Для очередного скрытого слоя создаётся автоэнкодер: Linear(d, h), ReLU, Linear(h, d). Декодер имеет линейный выход.

2. Автоэнкодер восстанавливает собственный вход и минимизирует MSE в течение 50 эпох. Метки классов и значения Appliances на этом этапе не используются.

3. Веса и смещения энкодера переносятся в соответствующий слой основной сети. Его выходы для обучающих объектов становятся входом следующего автоэнкодера.

4. Этап повторяется для всех четырёх скрытых слоёв. Декодеры после переноса весов отбрасываются.

5. Скрытые слои фиксируются; выходной слой обучается с учителем 10 эпох.

6. Все слои размораживаются, затем сеть дообучается целиком. Сохраняется состояние с наименьшими валидационными потерями.

Настройка	Значение
Оптимизатор и шаг	Adam, learning rate = 0,001
Размер мини-пакета	128
Дообучение всей сети	Не более 100 эпох; patience = 15
Порог улучшения валидационных потерь	0,000001
Повторные запуски	seed = 42, 43, 44; одно разбиение
Вычисления	CPU; один поток; детерминированные операции

Внутри каждой пары режимы стартуют с одной копии исходных весов и получают один порядок мини-пакетов при дообучении. Предобученный режим имеет дополнительные 200 эпох автоэнкодеров и 10 эпох обучения выхода; равенство полного вычислительного бюджета не предполагается.

Результаты регрессии Appliances

Таблица содержит среднее ± выборочное стандартное отклонение по трём запускам на одних 2961 тестовых объектах. Δ = результат с предобучением минус результат без него. Для MAE, RMSE и MAPE лучше меньшее значение, для R^2 — большее.

Метрика	Без предобучения	С предобучением	Δ средних
MAE, Вт·ч	60,87 ± 13,78	61,07 ± 9,69	+0,20
RMSE, Вт·ч	92,01 ± 8,15	89,58 ± 4,04	-2,43
MAPE, %	73,64 ± 24,49	75,13 ± 17,32	+1,49
R^2	-0,0306 ± 0,1830	0,0270 ± 0,0867	+0,0575

Метрики отдельных запусков

Seed	RMSE без	RMSE с	R^2 без	R^2 с
42	84,38	91,20	0,1378	-0,0072
43	91,07	84,98	-0,0042	0,1255
44	100,59	92,56	-0,2253	-0,0374

Предобучение снижает среднюю RMSE на 2,43 Вт·ч, или 2,64%. Средняя MAE увеличивается на 0,20 Вт·ч, MAPE — на 1,49 процентного пункта. Эффект зависит от инициализации: при seed=42 предобучение ухудшает RMSE, при seed=43 и 44 улучшает её.

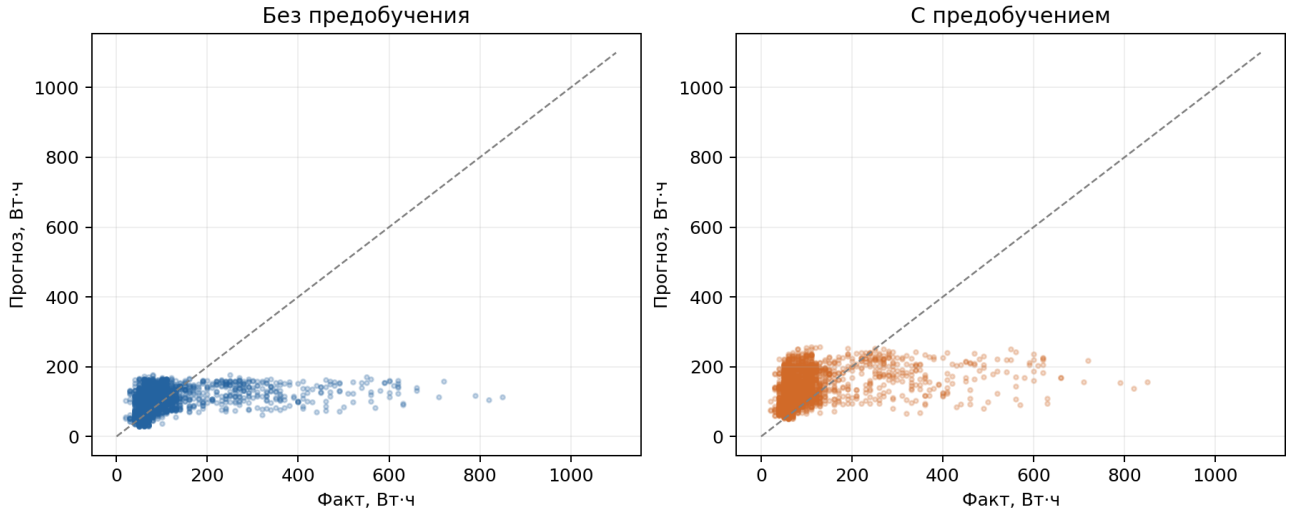


Рисунок 1. Фактическое и предсказанное энергопотребление, seed=42

Пунктир соответствует идеальному прогнозу. Обе модели сглаживают высокие значения потребления. При seed=42 предобученная сеть также чаще завышает малые значения, что согласуется с увеличением MAPE с 45,79 до 81,43%.

Анализ качества и обучения регрессора

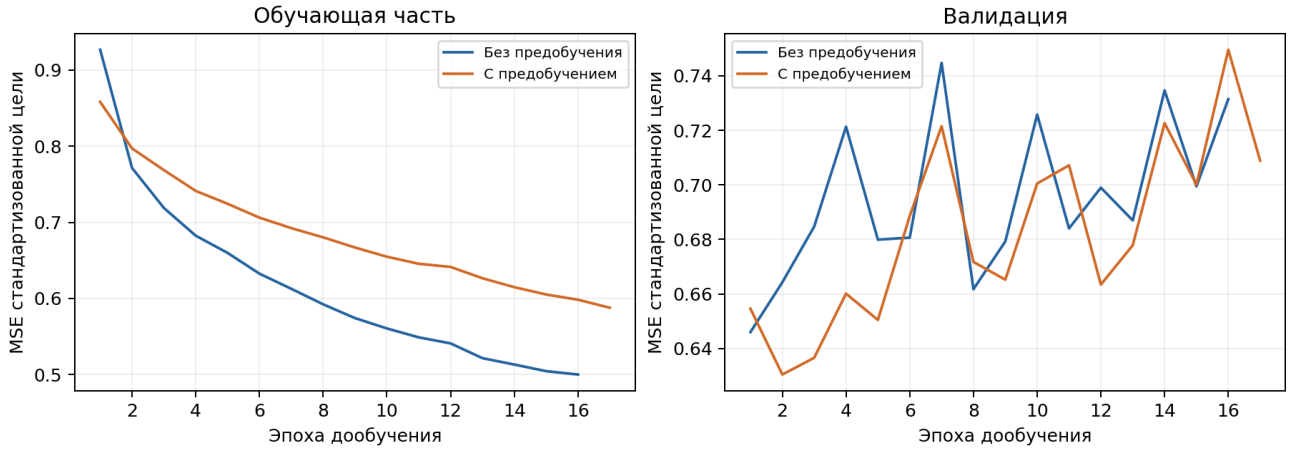


Рисунок 2. Обучающие и валидационные потери регрессора, seed=42

Обучающая ошибка снижается, однако валидационная после первых эпох в целом растёт. При seed=42 лучшая базовая модель выбрана после 1-й эпохи, предобученная — после 2-й; сами циклы завершились на 16-й и 17-й эпохах. На тесте использованы восстановленные лучшие состояния.

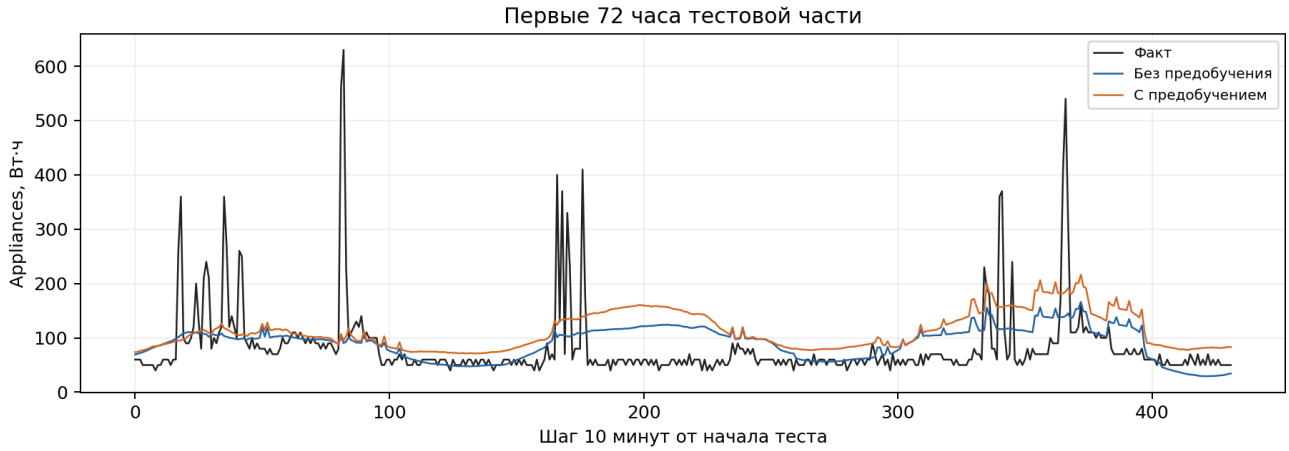


Рисунок 3. Прогноз на первых 432 тестовых шагах, seed=42

Видны резкие всплески, которые модели не воспроизводят. Раннее ухудшение валидационных потерь указывает на ограниченную переносимость модели на следующий временной период. Возможные причины — переобучение и изменение распределения признаков; их отдельный вклад данным сравнением не установлен.

Сравнение с постоянным прогнозом

Модель	MAE, Вт·ч	RMSE, Вт·ч	R^2
Среднее Appliances обучающей части	52,83	90,89	-0,0004

Средняя RMSE предобученной сети лишь немного ниже ошибки постоянного прогноза, а MAE выше. Значения R^2 около нуля и отрицательные значения отдельных запусков означают, что качество регрессии невысокое. Результат не даёт оснований считать выбранную сеть хорошей моделью энергопотребления.

Результаты классификации цифр

Для каждого запуска рассчитаны Accuracy, Precision, Recall и F1. Macro означает равный вес всех десяти классов; weighted учитывает число объектов класса. Все метрики в таблице представлены долями от 0 до 1; большее значение лучше.

Метрика	Без предобучения	С предобучением	Δ средних
Accuracy	0,9656 ± 0,0072	0,9586 ± 0,0020	-0,0070
Precision macro	0,9660 ± 0,0073	0,9595 ± 0,0018	-0,0065
Recall macro	0,9657 ± 0,0073	0,9587 ± 0,0019	-0,0070
F1 macro	0,9656 ± 0,0073	0,9588 ± 0,0019	-0,0069
F1 weighted	0,9656 ± 0,0072	0,9587 ± 0,0019	-0,0069

Результаты отдельных запусков

Seed	Accuracy без	Accuracy с	F1 macro без	F1 macro с
42	0,9739	0,9608	0,9740	0,9609
43	0,9608	0,9582	0,9608	0,9581
44	0,9621	0,9569	0,9621	0,9573

Средняя точность составляет 96,56% без предобучения и 95,86% с предобучением; разница равна −0,70 процентного пункта. Средняя F1 macro уменьшается с 0,9656 до 0,9588. Во всех трёх запусках обе метрики выше у базовой сети.

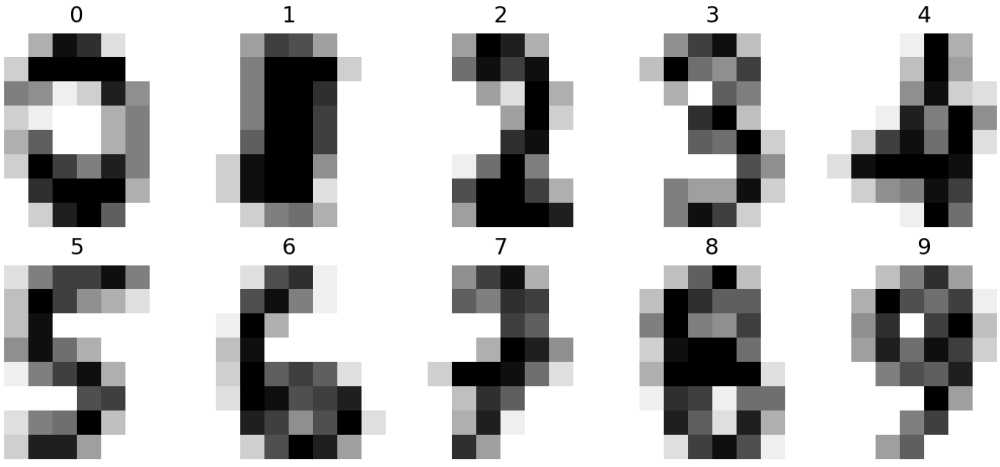


Рисунок 4. Примеры десяти классов из тестовой части

Классы близки по численности, поэтому результаты нельзя объяснить сильным дисбалансом. Восстановление признаков автоэнкодером оптимизирует другую цель, чем разделение цифр. В выбранной архитектуре это не привело к улучшению распознавания.

Матрицы ошибок и показатели классов

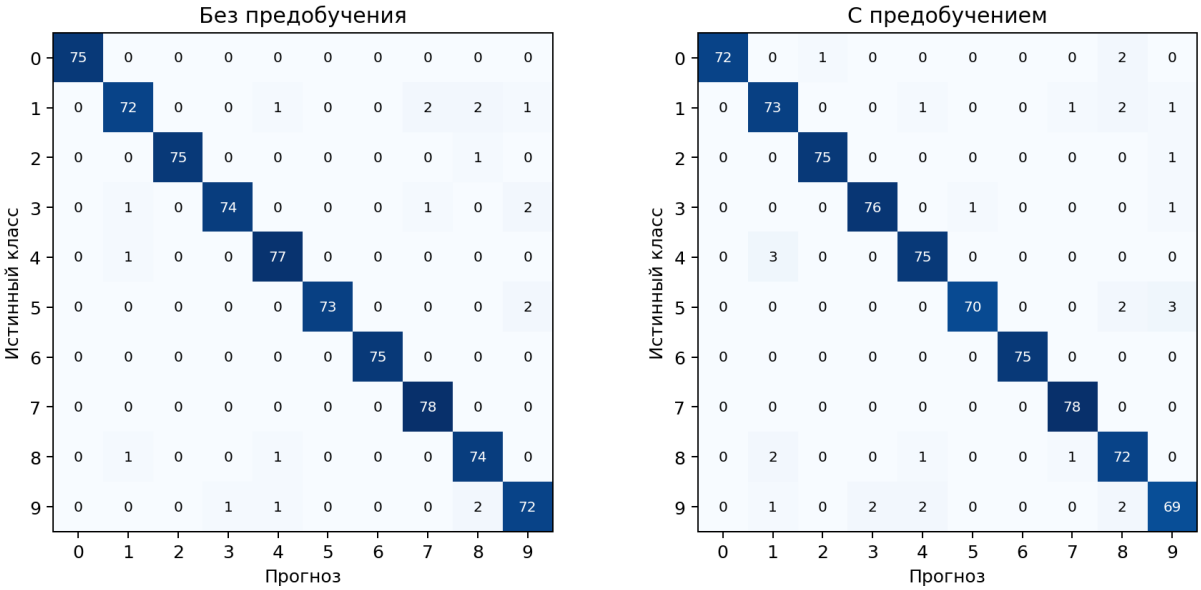


Рисунок 5. Матрицы ошибок для двух режимов, seed=42

Строка задаёт истинный класс, столбец — предсказанный. При seed=42 базовая сеть правильно распознала 745 из 765 изображений, предобученная — 735 из 765. Число ошибок выросло с 20 до 30.

Цифра	Объекты теста	F1 без предобучения	F1 с предобучением
0	75	1,0000	0,9796
1	78	0,9412	0,9299
2	76	0,9934	0,9868
3	78	0,9673	0,9744
4	78	0,9747	0,9554
5	75	0,9865	0,9589
6	75	1,0000	1,0000
7	78	0,9811	0,9873
8	76	0,9548	0,9231
9	76	0,9412	0,9139

Например, в режиме предобучения цифра 5 трижды распознана как 9, а цифра 4 трижды распознана как 1. Цифра 6 распознана без ошибок обоими режимами. Сравнение отдельных классов показывает, где возникает снижение общей точности; оно не является доказательством конкретной причины ошибок.

Сходимость и выводы

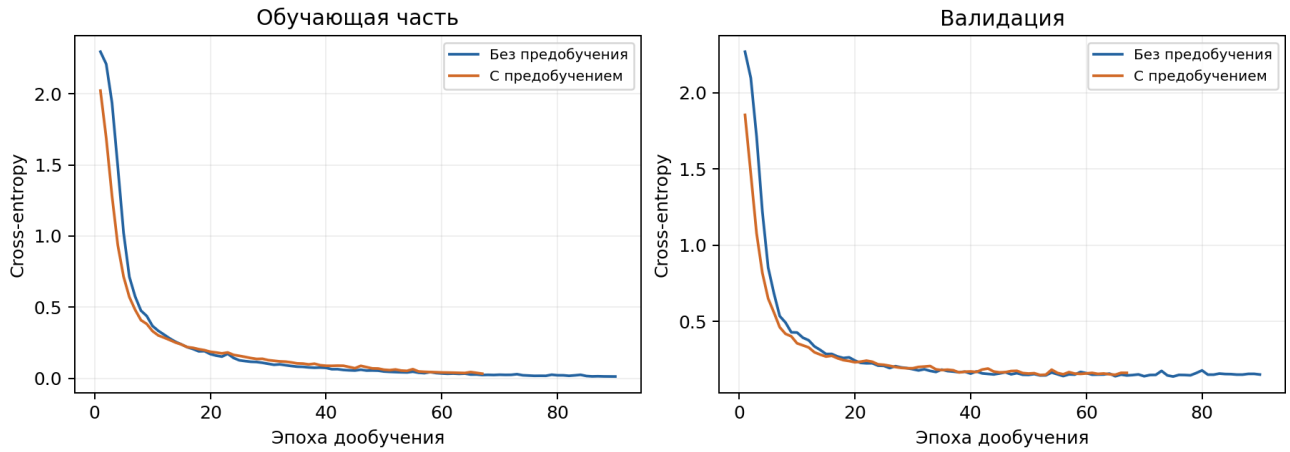


Рисунок 6. Потери классификатора при дообучении, seed=42

Для цифр при seed=42 минимум валидационных потерь достигнут на 75-й эпохе базовой сети и 52-й эпохе предобученной. Более ранний минимум не означает лучшего качества на тесте. Время включает все обучающие этапы соответствующего режима и зависит от среды выполнения.

Набор	**Без предобучения, с**	**С предобучением, с**
Appliances	1,11	9,56
Цифры	1,27	2,94

Вывод

1. Реализован полный послойный автоэнкодерный подход: восстановление входа, перенос весов четырёх энкодеров, обучение выхода с фиксированными признаками и точная настройка всей сети.

2. Для Appliances предобучение дало смешанный результат: средняя RMSE уменьшилась, но MAE и MAPE выросли. Разброс по инициализациям велик, а качество относительно постоянного прогноза невысокое.

3. Для optdigits.tra базовая сеть дала более высокие Accuracy и F1 macro во всех трёх запусках. Автоэнкодерное предобучение в выбранной конфигурации не улучшило распознавание цифр и потребовало дополнительного времени.

4. Предобучение не является гарантированным способом повышения качества. Итог зависит от данных, архитектуры, функции потерь и режима обучения. Три запуска на одном разбиении показывают чувствительность к инициализации, но не заменяют проверку на других разбиениях и статистическую оценку значимости.