Министерство образования Республики Беларусь Учреждение образования

«Брестский государственный технический университет»

Кафедра ИИТ

Лабораторная работа №4

За седьмой семестр

По дисциплине: «Интеллектуальный анализ данных»

Тема: Предобучение нейронных сетей с использованием RBM

Выполнил:

Студент 4 курса
Группы ИИ-26(2)
Петручик Д.А.

Проверил:

Никитин С.К.

Брест 2026

Вариант 10

Цель работы:

Реализовать послойное предобучение многослойной нейронной сети с помощью стека ограниченных машин Больцмана и сравнить его с обучением с нуля и автоэнкодерным предобучением. Основная задача это регрессия Appliances.

Исходные данные

energy: размер исходной таблицы 19735 × 29; train / validation / test: 13814 / 2960 / 2961.

digits: размер исходной таблицы 3823 × 65; train / validation / test: 2446 / 612 / 765.

Для Appliances строки отсортированы по времени и разделены в отношении 70/15/15. Исключены date, rv1 и rv2; час суток и день недели представлены синусом и косинусом. Всего 28 входов. StandardScaler признаков и цели обучается только на train. Метрики рассчитаны после обратного преобразования цели, в Вт·ч.

Для цифр используются только 3823 строки optdigits.tra, как в приложенном коде ЛР 3. 64 признака делятся на 16. Выполнено стратифицированное разделение: 20% на test, затем 20% оставшихся данных на validation, random_state=42. Файл optdigits.tes не используется; это внутренний тест внутри tra, а не официальный тест UCI.

Алгоритм предобучения RBM

RBM состоит из видимого и скрытого слоёв. Внутри каждого слоя связей нет. Скрытые единицы бинарные; вероятность их активации $p(h=1|v)=\text{sigmoid}(Wv+b)$. Веса W и скрытое смещение b после предобучения копируются в соответствующий слой сети.

Для стандартизованных непрерывных признаков Appliances первый слой — Gaussian–Bernoulli RBM с фиксированной дисперсией 1: $v|h \sim N(W^Th+a, I)$. Остальные слои — Bernoulli–Bernoulli RBM: $p(v=1|h)=\text{sigmoid}(W^Th+a)$. Для цифр все слои бинарные. Значения пикселей и вероятности предыдущего слоя интерпретируются как параметры Бернулли и стохастически бинаризуются при обучении RBM. При передаче признаков дальше используются вероятности sigmoid, а не случайные состояния.

Используется Contrastive Divergence CD-1. Для мини-пакета v_0 вычисляются p_0 и случайное h_0; затем восстанавливаются случайное v_1 и вероятности p_1. Обновление весов: $\Delta W = \eta[(p_0^Tv_0 - p_1^Tv_1)/m - \lambda W]$. Смещения обновляются по средним разностям v_0-v_1 и p_0-p_1. Добавляется momentum. Ошибка реконструкции сохраняется для диагностики, но не является supervised-метрикой качества.

Параметр	Значение
Предобучение каждого из 4 слоёв	50 эпох, только train
RBM	CD-1, batch=128, λ=0.0001
Скорость RBM	0.001 Gaussian; 0.05 Bernoulli
Momentum	0.5 первые 5 эпох, затем 0.9
Автоэнкодеры	Adam, lr=0.001, MSE, линейный декодер

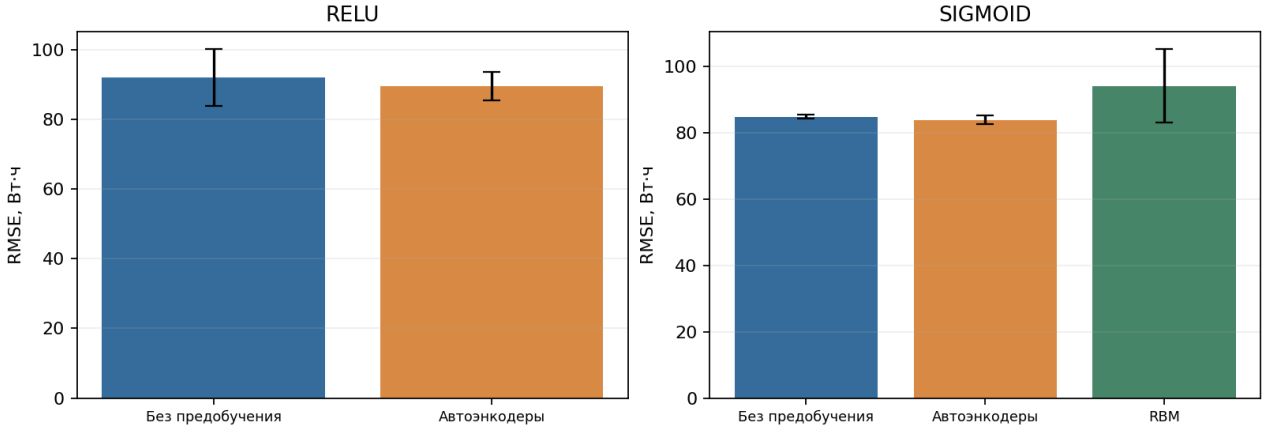
Обучение выходного слоя	10 эпох после AE/RBM, скрытые веса заморожены
Дообучение всей сети	Adam, lr=0.001, до 100 эпох, batch=128
Останов дообучения	15 эпох без улучшения validation loss на 10^{-6}
Выбор итоговых весов	Минимальная validation loss
Повторения	seed = 42, 43, 44

Регрессия использует MSE, классификация — CrossEntropyLoss с линейными выходными logits. Все скрытые слои после предобучения размораживаются. Для каждого seed внутри одной активации все режимы стартуют с одной копии исходной сети. Тест не используется для предобучения, выбора эпох или нормализации. Время включает предобучение, разогрев выходного слоя и дообучение, но не оценку теста.

Результаты регрессии Appliances

Значения представлены как среднее ± выборочное стандартное отклонение по выбранным seed. Это разброс инициализаций на одном фиксированном разделении, а не доверительный интервал.

Модель	MAE	RMSE	R2
relu / Без предобучения	60.8658 ± 13.7774	92.0118 ± 8.1481	-0.0306 ± 0.1830
relu / Автоэнкодеры	61.0695 ± 9.6861	89.5789 ± 4.0406	0.0270 ± 0.0867
sigmoid / Без предобучения	46.0200 ± 1.5641	84.8579 ± 0.5704	0.1280 ± 0.0117
sigmoid / Автоэнкодеры	49.9032 ± 1.7132	83.9534 ± 1.3272	0.1464 ± 0.0271
sigmoid / RBM	57.5216 ± 13.7200	94.2197 ± 11.0780	-0.0849 ± 0.2528



Столбцы показывают среднее; отрезки — стандартное отклонение.

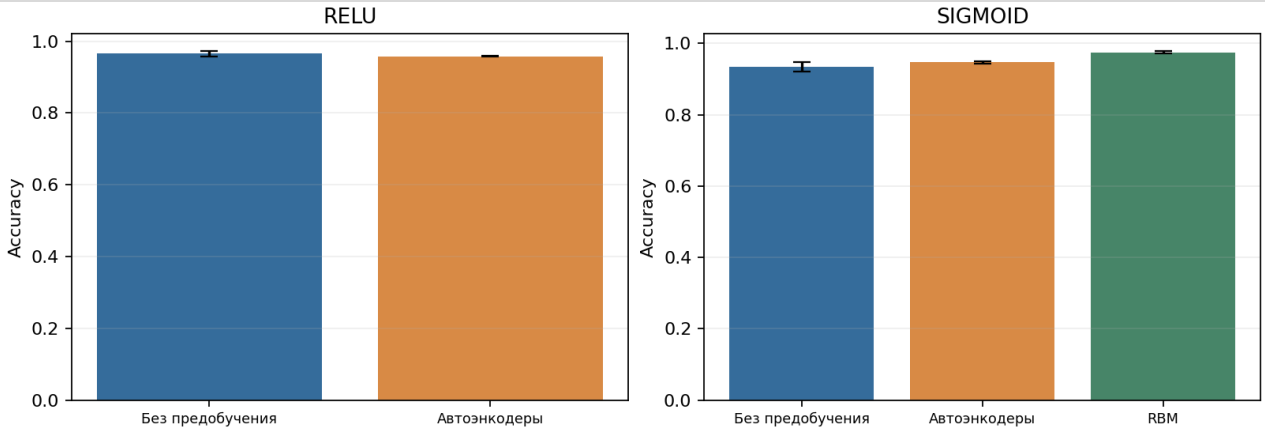
В контролируемом сравнении sigmoid лучший средний RMSE получен в режиме «Автоэнкодеры»: 83.9534. RBM: 94.2197; без предобучения: 84.8579; автоэнкодеры: 83.9534.

Модель	Среднее время, с	Лучшие эпохи по seed
relu / Без предобучения	1.2	1, 1, 3
relu / Автоэнкодеры	10.5	2, 3, 5
sigmoid / Без предобучения	2.0	12, 10, 11
sigmoid / Автоэнкодеры	12.0	12, 10, 11
sigmoid / RBM	10.2	31, 8, 30

Результаты распознавания цифр

Значения представлены как среднее ± выборочное стандартное отклонение по выбранным seed. Это разброс инициализаций на одном фиксированном разделении, а не доверительный интервал.

Модель	Accuracy	F1_macro	Recall_macro
relu / Без предобучения	0.9656 ± 0.0072	0.9656 ± 0.0073	0.9657 ± 0.0073
relu / Автоэнкодеры	0.9586 ± 0.0020	0.9588 ± 0.0019	0.9587 ± 0.0019
sigmoid / Без предобучения	0.9342 ± 0.0131	0.9342 ± 0.0134	0.9344 ± 0.0131
sigmoid / Автоэнкодеры	0.9468 ± 0.0027	0.9471 ± 0.0025	0.9469 ± 0.0027
sigmoid / RBM	0.9752 ± 0.0035	0.9753 ± 0.0034	0.9753 ± 0.0034



Столбцы показывают среднее; отрезки — стандартное отклонение.

В контролируемом сравнении sigmoid лучший средний Accuracy получен в режиме «RBM»: 0.9752. RBM: 0.9752; без предобучения: 0.9342; автоэнкодеры: 0.9468.

Модель	Среднее время, с	Лучшие эпохи по seed
relu / Без предобучения	1.5	75, 71, 43
relu / Автоэнкодеры	3.5	52, 56, 43
sigmoid / Без предобучения	1.8	100, 100, 100
sigmoid / Автоэнкодеры	4.0	100, 100, 96
sigmoid / RBM	4.4	100, 98, 99

Вывод

Для energy RBM не улучшил средний RMSE относительно обучения sigmoid-сети с нуля: 84.8579 → 94.2197. Результат относится к выбранным гиперпараметрам и фиксированному разбиению.

Для digits RBM улучшил средний Accuracy относительно обучения sigmoid-сети с нуля: 0.9342 → 0.9752. Результат относится к выбранным гиперпараметрам и фиксированному разбиению.

Предобучение не гарантирует улучшения итогового прогноза. RBM учится моделировать распределение входов без целевой переменной; полезные для реконструкции закономерности могут быть слабо связаны с регрессией или классом. Глубокая сигмоидальная сеть чувствительна к инициализации. Дополнительный этап увеличивает вычислительные затраты, поэтому оценивать следует одновременно качество и время.

Ограничения: гиперпараметры не оптимизировались; использованы несколько инициализаций и одно разделение. Сигмоидальные модели отличаются от исходных ReLU, поэтому сравнение с ЛР 3 дано отдельными строками. Материалы лекции не приложены; реализован стандартный CD-1. Значения в отчёте получены реальным запуском приложенного кода на CPU.