Министерство образования Республики Беларусь

Учреждение образования

«Брестский государственный технический университет»

Кафедра ИИТ

Лабораторная работа №5

За седьмой семестр

По дисциплине: «Интеллектуальный анализ данных»

Тема: Деревья решений

Выполнил:

Студент 4 курса
Группы ИИ-26(2)
Петручик Д.А.

Проверил:

Никитин С.К.

Брест 2026

Вариант 10

Цель работы

Сравнить одиночное дерево решений, случайный лес и три алгоритма бустинга — AdaBoost, CatBoost и XGBoost — в задаче предсказания дохода выше 50 тысяч долларов в год. Основная метрика по заданию — precision положительного класса >50K.

Данные и разделение выборки

Использован набор Adult из UCI Machine Learning Repository, построенный на данных переписи США 1994 года. В нём 48 842 записи и 14 входных признаков. Целевая переменная income имеет классы <=50K и >50K. Используется готовое разделение UCI: adult.data — обучение, adult.test — тест. Строки между файлами не перераспределяются.

Часть	Всего	<=50K	>50K	Доля >50K
Обучение	32561	24720	7841	24.08%
Тест	16281	12435	3846	23.62%

Числовые признаки: age, fnlwgt, education-num, capital-gain, capital-loss, hours-per-week. Категориальные: workclass, education, marital-status, occupation, relationship, race, sex, native-country. Все 14 признаков сохранены; fnlwgt используется как входной признак, а не вес наблюдения.

Обработка пропусков и категорий

При чтении удалены пробелы после разделителей; символ ? преобразован в пропуск. В adult.test пропущена служебная строка, а конечная точка в метке дохода удалена. Положительный класс >50K закодирован единицей, <=50K — нулём. Строки с пропусками сохранены.

Признак	Пропуски train	Пропуски test
workclass	1836	963
occupation	1843	966
native-country	583	274

Для дерева, леса, AdaBoost и XGBoost категории заполнены модой train и преобразованы OneHotEncoder; неизвестные категории теста игнорируются. Получено 105 числовых столбцов. Числовые пропуски обрабатываются медианой train. Стандартизация для деревьев не требуется. CatBoost получает исходные категориальные столбцы с отдельной категорией Missing; числовые пропуски также заполняются медианой train.

Алгоритмы и параметры эксперимента

Дерево последовательно разбивает выборку по признакам, уменьшая неоднородность классов. Случайный лес усредняет результаты деревьев, обученных на bootstrap-выборках с выбором случайного подмножества признаков. AdaBoost последовательно повышает вес ошибочно классифицированных объектов. XGBoost строит регуляризованный градиентный бустинг. CatBoost поддерживает обработку категориальных признаков внутри алгоритма.

Модель	Основные параметры
DecisionTree	criterion=gini; max_depth=8; min_samples_leaf=20
RandomForest	200 деревьев; max_depth=None; min_samples_leaf=2; max_features=sqrt; bootstrap=True
AdaBoost	200 итераций; learning_rate=0.5; базовое дерево max_depth=1; SAMME
CatBoost	500 итераций; depth=6; learning_rate=0.05; Logloss; исходные категории
XGBoost	400 деревьев; max_depth=4; learning_rate=0.05; subsample=0.8; colsample_bytree=0.8; tree_method=hist

Все модели обучены на одной train-выборке и оценены на одном тесте. Seed равен 42; для ансамблей с поддержкой параллелизма используются 2 потока CPU. Гиперпараметры заданы до просмотра тестовых результатов. Подбор гиперпараметров, ранняя остановка по тесту и настройка порога на тесте не выполнялись. Для всех моделей класс >50K назначается при predict_proba >= 0.5.

В CatBoost обработка категорий отличается от One-Hot Encoding других моделей. Поэтому сравниваются практические связки «подготовка данных + алгоритм», а не только алгоритмы на идентичной числовой матрице. Бустинг реализован с помощью библиотечных классов; самостоятельная реализация оптимизаторов в задании отдельно не требуется.

Метрики оценки

TP — верно предсказанный высокий доход; FP — ошибочно предсказанный высокий доход; FN — пропущенный высокий доход; TN — верно предсказанный доход не выше 50K.

Precision = TP / (TP + FP) — доля действительно высоких доходов среди всех положительных прогнозов. Именно по этой метрике выбирается лучший результат варианта 10. Recall = TP / (TP + FN) показывает, какая доля людей с высоким доходом обнаружена. F1 = 2 · precision · recall / (precision + recall). Accuracy — доля всех правильных ответов.

Дополнительно сохранены ROC-AUC и Average Precision, рассчитанные по вероятностям. Average Precision не тождественна precision при пороге 0.5. Поскольку положительный класс составляет около четверти выборки, одной accuracy недостаточно. Precision рассматривается вместе с recall и количеством положительных прогнозов.

Воспроизводимость

Версии при запуске: python 3.12.14, numpy 2.3.5, pandas 2.2.3, sklearn 1.8.0, catboost 1.2.10, xgboost 3.4.1.

В results/metadata.json сохранены версии, параметры, размеры выборок, пропуски и SHA256 исходных файлов. Прогнозы для каждого объекта, матрицы ошибок и classification_report сохранены отдельно. Время ниже измерено на CPU в этой среде; оно зависит от оборудования и нагрузки.

Результаты на тестовой выборке

Модель	Precision	Recall	F1	Accuracy
DecisionTree	0.7944	0.5315	0.6369	0.8568
RandomForest	0.7640	0.6087	0.6776	0.8632
AdaBoost	0.7704	0.5653	0.6521	0.8575
CatBoost	0.7766	0.6570	0.7118	0.8743
XGBoost	0.7836	0.6479	0.7094	0.8746

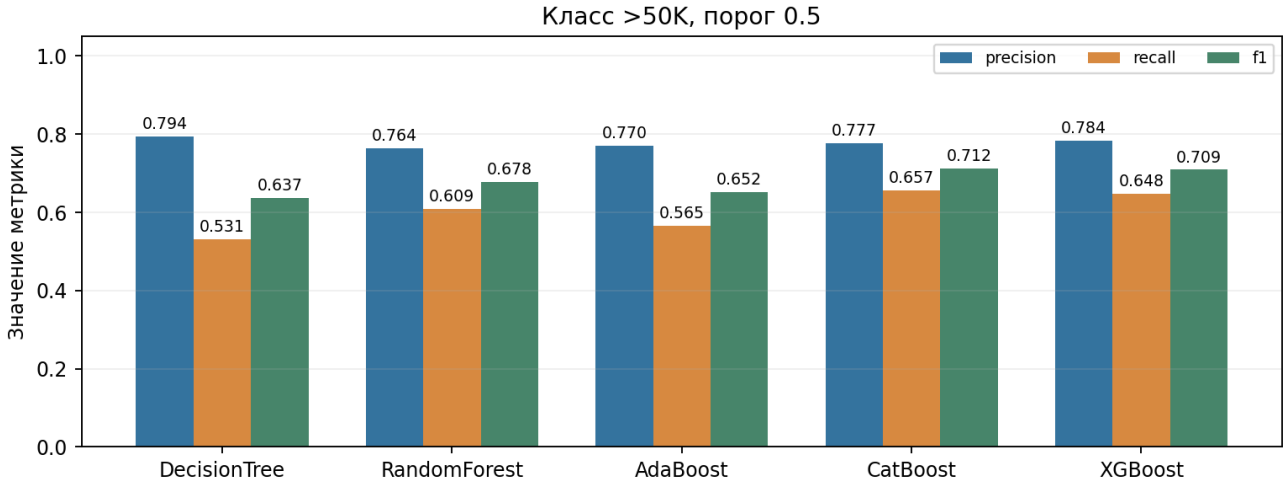


Рисунок 1. Метрики положительного класса при одинаковом пороге 0.5.

Сравнение по основной метрике

Наибольший precision получен у DecisionTree: 0.7944 (79.44%). Из 2573 прогнозов >50K верны 2044, ошибочны 529. Следовательно, примерно 79.4% людей, отнесённых этой моделью к высокодоходному классу, действительно относятся к нему в тесте.

Recall этой модели равен 0.5315: обнаружено 2044 из 3846 людей с высоким доходом. Пропущено 1802. Максимальный F1 получен у CatBoost (0.7118); это отдельный критерий, который не подменяет precision из задания.

Модель	ROC-AUC	Avg. precision	Обучение, с	Прогноз, с
DecisionTree	0.9043	0.7573	0.16	0.002
RandomForest	0.9149	0.7965	3.22	0.196
AdaBoost	0.9106	0.7830	7.12	0.141
CatBoost	0.9283	0.8269	13.77	0.024
XGBoost	0.9267	0.8243	1.14	0.025

Время общего препроцессинга для четырёх моделей — 0.15 с; оно не включено в обучение. Время обучения CatBoost включает внутреннюю обработку категорий. Одно измерение времени не является устойчивым бенчмарком.

Анализ ошибок

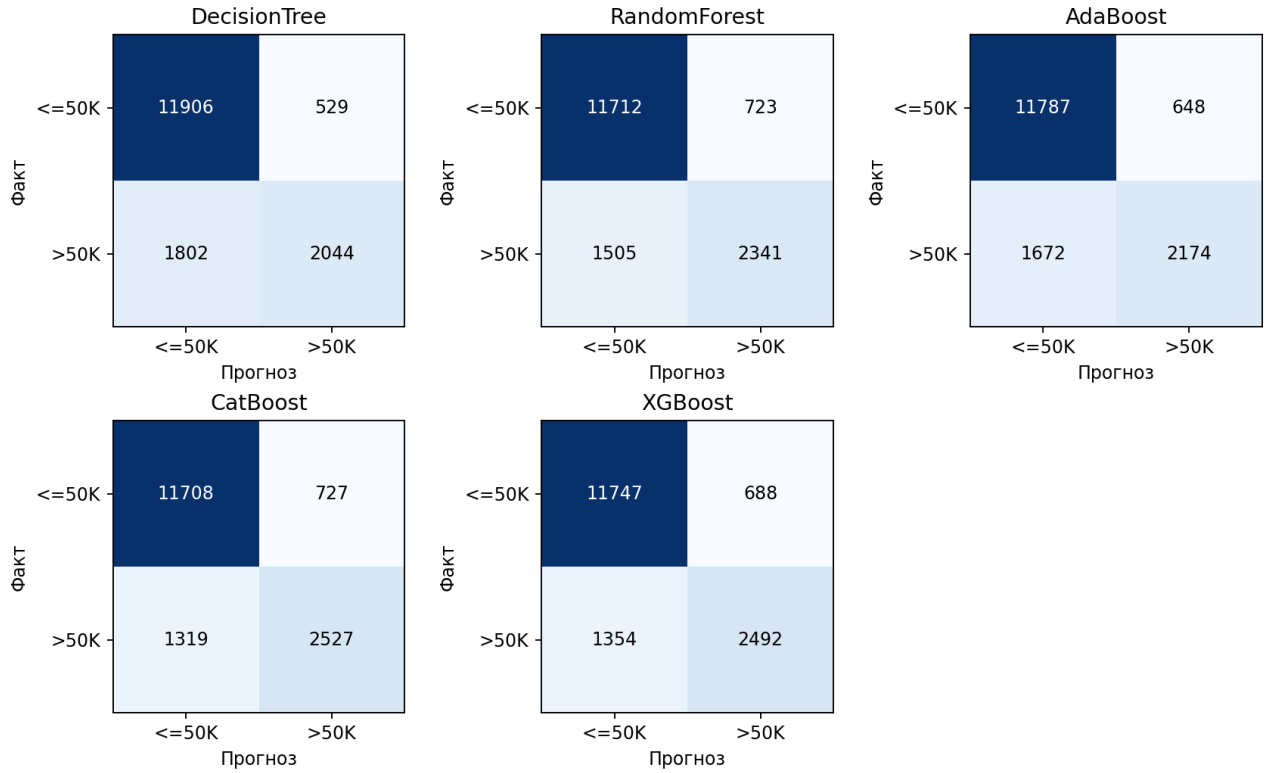


Рисунок 2. Матрицы ошибок. По строкам — истинный класс, по столбцам — прогноз.

Модель	TN	FP	FN	TP
DecisionTree	11906	529	1802	2044
RandomForest	11712	723	1505	2341
AdaBoost	11787	648	1672	2174
CatBoost	11708	727	1319	2527
XGBoost	11747	688	1354	2492

Чем больше FP при фиксированном TP, тем ниже precision. Однако уменьшение числа положительных прогнозов может повышать precision ценой роста FN. Поэтому число ложноположительных ответов само по себе не определяет победителя: нужно учитывать отношение TP к TP+FP.

Применимость методов

DecisionTree: precision 0.7944, recall 0.5315. Простая модель с ограниченной глубиной; её правила удобно объяснять, но одно дерево хуже усредняет случайные особенности выборки.

RandomForest: precision 0.7640, recall 0.6087. Ансамбль снижает зависимость от одного дерева; требует больше памяти, а отдельное решение труднее объяснить.

AdaBoost: precision 0.7704, recall 0.5653. Последовательно обучает неглубокие деревья; простые базовые модели могут недостаточно описывать сложные взаимодействия признаков.

CatBoost: precision 0.7766, recall 0.6570. Подходит для смешанных таблиц с категориями и позволяет обходиться без внешнего One-Hot Encoding.

XGBoost: precision 0.7836, recall 0.6479. Градиентный бустинг с ограничением сложности деревьев; в этой реализации работает с общей числовой матрицей после One-Hot Encoding.

Выводы

Выполнена бинарная классификация Adult Census Income. Пропуски обработаны без удаления строк, категориальные признаки подготовлены для каждой модели. Обучены и проверены пять методов. По требуемой метрике precision для класса >50K лучший результат в данном эксперименте показал DecisionTree: 79.44%.

Этот вывод относится к официальному разделению UCI, выбранным параметрам и порогу 0.5. Он не доказывает превосходство алгоритма при любых настройках. Проведён один запуск на одном разделении; статистическая значимость различий не проверялась. Для улучшения модели параметры и порог следует подбирать внутри train, сохраняя отдельный тест для итоговой оценки.

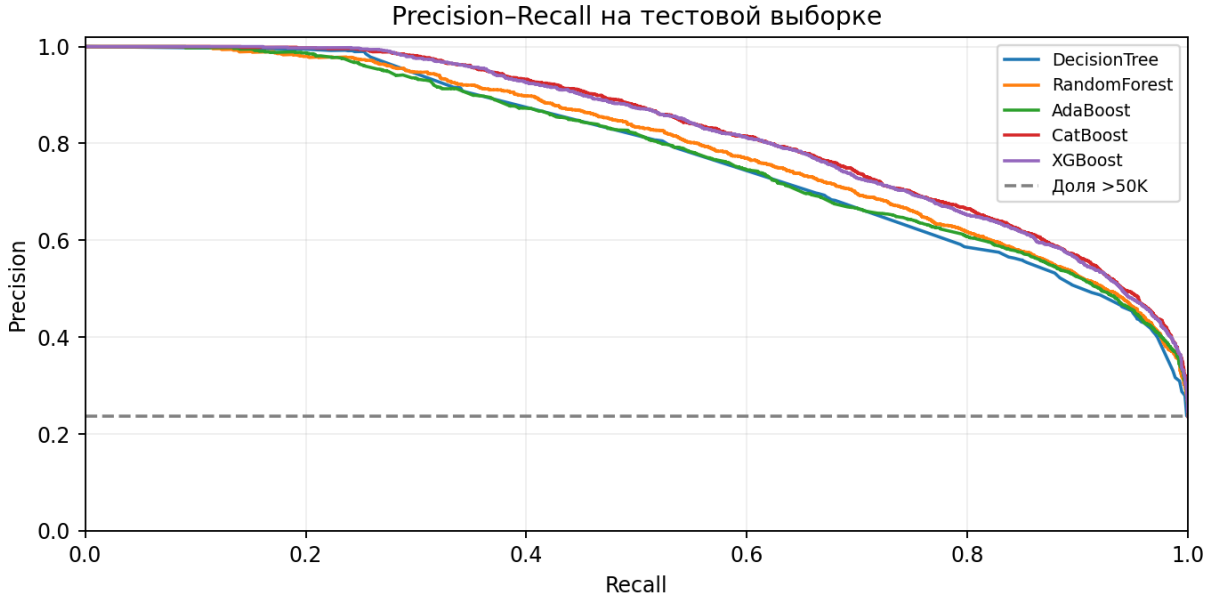


Рисунок 3. Изменение precision и recall при изменении порога. Кривые приведены для анализа; порог по ним не подбирался.