

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №1
За седьмой семестр
По дисциплине: «Интеллектуальный анализ данных»
Тема: «РСА»

Выполнил:
Студент 4 курса
Группы ИИ-26(1)
Прокопюк А.Д.
Проверил:
Никитин С.К.

Брест 2026

Цель: научиться применять метод PCA для осуществления визуализации данных

№ варианта	Выборка	Класс
12	hcv+data.zip	Category

1. Используя выборку по варианту, осуществить проецирование данных на плоскость первых двух и трех главных компонент (двумя способами: 1. вручную через использование `numpy.linalg.eig` для вычисления собственных значений и собственных векторов и 2. с помощью `sklearn.decomposition.PCA` для непосредственного применения метода PCA – два независимых варианта решения);

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

data = pd.read_csv("lab1/hcvdat0.csv")

y = data["Category"]

X = data.drop(columns=["Unnamed: 0", 'Category'])
X["Sex"] = X["Sex"].map({"m" : 0, "f" : 1})
X = X.fillna(X.mean())
X = (X - X.mean()) / X.std()





cov = np.cov(X, rowvar=False)
eigenval, eigwnvec = np.linalg.eig(cov)

idx = np.argsort(eigenval)[::-1]
eigenval = eigenval[idx]
eigwnvec = eigwnvec[:, idx]

PC = eigwnvec[:, :3] # PC1, PC2, PC3

X_pca = X.values @ PC
X_pca = X_pca.real
```

2. Выполнить визуализацию полученных главных компонент с использованием средств библиотеки `matplotlib`, обозначая экземпляры разных классов с использованием разных цветовых маркеров;



При сопоставлении ручной реализации PCA и библиотечной наблюдается зеркальное отражение распределения точек относительно осей. Это обусловлено неопределенностью знака собственных векторов. Оба метода находят идентичные направления главных компонент (линии наибольшей дисперсии), но алгоритмы вычисления (разложение по собственным значениям в NumPy и сингулярное разложение SVD в Sklearn) могут возвращать векторы с противоположными знаками. Умножение векторов на -1 инвертирует координаты точек, что носит исключительно визуальный характер и не влияет на математический смысл, дисперсию и взаимное расположение кластеров данных.

3. Используя собственные значения, рассчитанные на этапе 1, вычислить потери, связанные с преобразованием по методу PCA. Сделать выводы;

PCA 2d loss: 0.6362312273317774

PCA 3d loss: 0.5182563293772792

При преобразовании данных к двум главным компонентам теряется 63.62% общей дисперсии, то есть сохраняется 36.38% информации о вариативности исходных данных. При использовании трёх главных компонент потери уменьшаются до 51.83%, а сохраняемая доля увеличивается до 48.17%. Это означает что, переход

от двух к трём компонентам позволяет сохранить больше информации, однако даже три компонента описывают менее половины общей дисперсии исходных данных.

Вывод: научился применять метод PCA для осуществления визуализации данных