Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №1

За седьмой семестр

По дисциплине: «Интеллектуальный анализ данных»

Тема: Применение метода главных компонент для визуализации выборки seeds

Выполнил:
Студент 4 курса
Группы ИИ-26(2)
Турич Д.А.
Проверил:
Никитин С.К.

Брест 2026

Метод главных компонент для выборки seeds

1 Условие работы и подготовка данных

Цель работы — применить метод главных компонент (PCA), чтобы представить многомерные данные в удобном для визуального анализа виде. В варианте 1 используется архив seeds.zip; класс объекта указан в последнем столбце. Нужно двумя независимыми способами — с помощью numpy.linalg.eig и sklearn.decomposition.PCA — построить проекции данных на первые две и первые три главные компоненты, отобразить классы на графиках и оценить потери информации, опираясь на собственные значения.

В архиве есть файл seeds_dataset.txt: 210 строк и 8 числовых столбцов. Первые семь столбцов образуют матрицу признаков X размером 210 × 7, а восьмой столбец выделяется в вектор меток. В данных присутствуют три класса — 1, 2 и 3, по 70 объектов в каждом. Метки применяются только для цветового обозначения точек и не участвуют в центрировании, расчёте ковариационной матрицы и выполнении PCA.

Файл должен читаться через pandas.read_csv, причём разделителем считается один или несколько пробельных символов. Несколько идущих подряд табуляций также рассматриваются как разделители, а не как пропуски. В исходной выборке нет NaN и бесконечных значений. Если пропуск в признаке задан явно, программа должна заменить его медианой соответствующего столбца. Столбец, полностью состоящий из пустых значений, и отсутствие метки класса считаются недопустимыми.

Характеристики семи входных колонок

Признак	Среднее	Выборочное s	Минимум	Максимум
X1	14,84752	2,90970	10,5900	21,1800
X2	14,55929	1,30596	12,4100	17,2500
X3	0,87100	0,02363	0,8081	0,9183
X4	5,62853	0,44306	4,8990	6,6750
X5	3,25860	0,37771	2,6300	4,0330
X6	3,70020	1,50356	0,7651	8,4560
X7	5,40807	0,49148	4,5190	6,5500

Стандартизация

Перед основным экспериментом данные стандартизировали, так как исходные столбцы имеют разные масштабы. Например, стандартные отклонения признаков X1 и X3 равны 2,90970 и 0,02363. Чтобы каждый признак учитывался в одинаковом масштабе, значения делят на стандартное отклонение соответствующего столбца:

$$z_{ij} = (x_{ij} - \mu_j)/s_j;\ \mu_j = (1/n)\Sigma_i x_{ij}$$

$$s_j^2 = (1/(n - 1))\Sigma_i(x_{ij} - \mu_j)^2;\ n = 210$$

Здесь применяется выборочное стандартное отклонение, то есть ddof = 1. После такого преобразования средние становятся нулевыми с точностью до округления, дисперсии равны единице, а суммарная дисперсия по всем семи признакам составляет 7. И метод PCA через numpy.linalg.eig, и метод PCA через sklearn.decomposition.PCA работают с одной и той же подготовленной матрицей Z.

2 Два независимых способа вычисления PCA

Ручной вариант через собственные значения

На основе матрицы Z, полученной после центрирования, составляется симметричная ковариационная матрица S размером 7 × 7. С помощью numpy.linalg.eig находятся её собственные значения и собственные векторы. Затем собственные значения упорядочиваются по убыванию, а столбцы матрицы собственных векторов переставляются в том же порядке.

$$S = Z^{T}Z/(n - 1);\ Sv_j = \lambda_j v_j;\ \lambda_1 \geq \lambda_2 \geq \ldots \geq \lambda_7$$

$$V_k = [v_1 \ldots v_k];\ T_k = ZV_k,\ k \in \{2,3\}$$

Матрица T_2 получается размером 210 × 2, а T_3 — 210 × 3. Их строки задают координаты объектов на графиках. Проверяется, что мнимая часть пренебрежимо мала, собственные значения неотрицательны с точностью до округления, а базис ортонормирован. Если отбросить компоненты с малыми собственными значениями, размерность уменьшается с минимальной квадратичной ошибкой в выбранном масштабе.

Библиотечный вариант

Для каждой размерности отдельно создаётся объект sklearn.decomposition.PCA(n_components=k, svd_solver="full", whiten=False), после чего вызывается fit_transform(Z). В библиотечном решении используется полное сингулярное разложение подготовленной матрицы. Собственные значения, собственные векторы и координаты из ручного варианта в PCA не передаются. Отключение whiten необходимо, чтобы главные компоненты сохраняли обычный масштаб.

Знаки и сравнение решений

Так как векторы v и −v задают одну и ту же ось, два корректных решения могут отличаться знаками координат. Для каждой компоненты в каждом решении знак выбирается независимо так, чтобы наибольший по модулю коэффициент был положительным. После этого координаты сравниваются. Дополнительно сопоставляются собственные значения и проекторы $V_k V_k^{T}$, которые не зависят от знаков векторов.

Расчёт потерь

$$D_k = \sum_{j=k+1}^{7} \lambda_j;\quad L_k = D_k / \left(\sum_{j=1}^{7} \lambda_j\right) \cdot 100\%$$

$$R_k = 100\% - L_k;\quad \hat{Z}_k = T_k V_k^{T}$$

$$SSE_k = \|Z - \hat{Z}_k\|^2 = (n-1)D_k;\quad MSE_k = SSE_k / (n \cdot 7)$$

Здесь D_k — отброшенная дисперсия, L_k — доля потерянной дисперсии, R_k — доля сохранённой. SSE суммирует квадраты отклонений всех 1470 элементов матрицы, а MSE усредняет их. Эти потери относятся к стандартизованным признакам, а не к проценту неверно классифицированных объектов и не ко всей возможной информации о данных.

3 Собственные значения и численные результаты

Собственные значения были найдены для всей стандартизованной выборки. Все семь полученных значений больше нуля. Их сумма с точностью до вычислительной погрешности равна 7. Вклад каждой отдельной компоненты рассчитывается как $\lambda_j/7$, а накопленная доля — как сумма вкладов первых компонент.

Компонента	λ	Доля дисперсии, %	Накопленная доля, %
PC1	5,031201186	71,874303	71,874303
PC2	1,197572847	17,108184	88,982486
PC3	0,678003439	9,685763	98,668250
PC4	0,068364477	0,976635	99,644885
PC5	0,018713609	0,267337	99,912222
PC6	0,005332046	0,076172	99,988394
PC7	0,000812397	0,011606	100,000000

Сравнение сохранённой дисперсии и потерь

k	Способ	Сохранено, %	Потеряно, %
2	NumPy eig	88,982486	11,017514
2	sklearn PCA	88,982486	11,017514
3	NumPy eig	98,668250	1,331750
3	sklearn PCA	98,668250	1,331750

k	D_k	SSE_k	MSE_k
2	0,771225967	161,186227	0,109650495
3	0,093222528	19,483508	0,013254087

Если взять две компоненты, сохраняется 88,982486% дисперсии, а если три — 98,668250%. Третья компонента даёт прибавку 9,685763 процентного пункта и снижает потерю с 11,017514% до 1,331750%. Для сохранения не менее 95% дисперсии стандартизованных данных достаточно трёх компонент; двух для этого недостаточно.

Расхождение между собственными значениями, найденными ручным способом и с помощью библиотеки, не превышает $4{,}45 \cdot 10^{-15}$. После выбора знаков максимальное несовпадение координат составляет $3{,}13 \cdot 10^{-15}$, а для элементов проекторов — $3{,}34 \cdot 10^{-16}$. Эти различия находятся на уровне машинного округления. Непосредственно вычисленная ошибка реконструкции совпала с $(n - 1)D_k$ и с ошибкой библиотечного решения.

4 Визуализация первых главных компонент

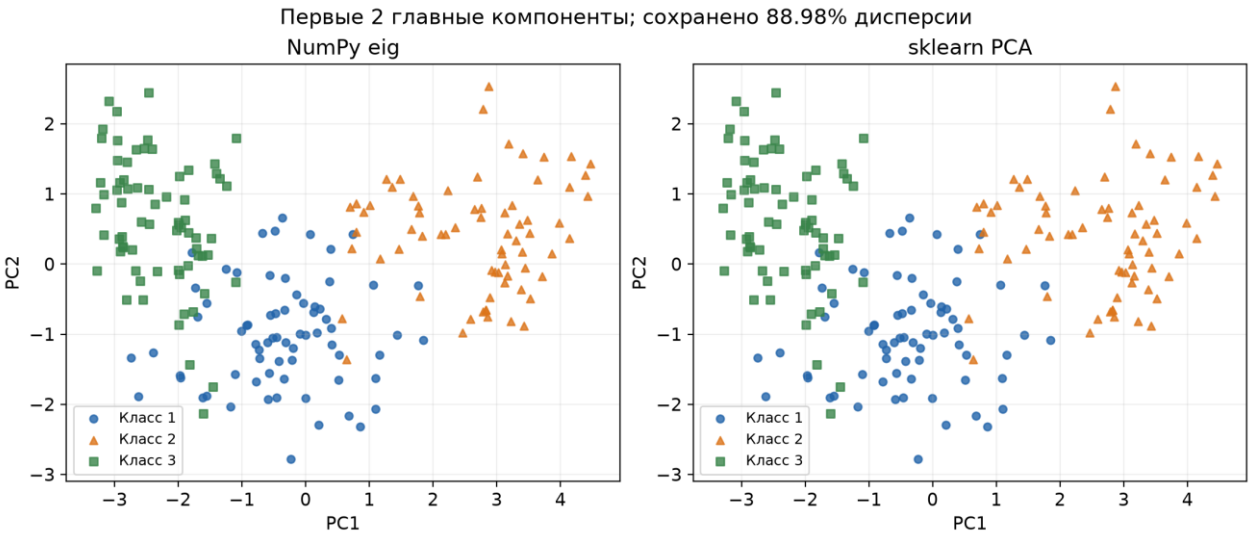


Рисунок 1 — Проекция на первые две компоненты двумя способами

На плоскости PC1–PC2 видны три преимущественные области: класс 2 расположен справа, класс 3 — слева, класс 1 — между ними и ниже по PC2. В пограничных областях точки разных классов перемешиваются. PCA не использует метки и не оптимизирует разделение классов, поэтому такое перекрытие допустимо.

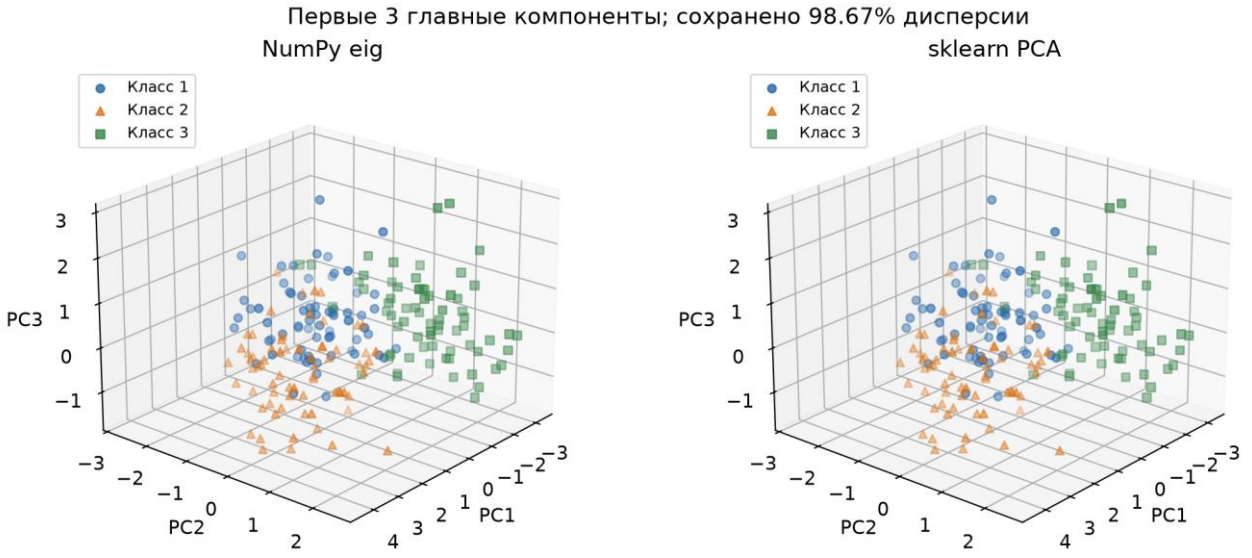


Рисунок 2 — Проекция на первые три компоненты двумя способами

Третья главная компонента (PC3) выявляет дополнительные различия между объектами вдоль третьего направления и снижает потери примерно до 1,33%. Чтобы графики можно было сопоставлять, для них заданы одинаковые границы осей, цвета маркеров и точка обзора. Проекции справа и слева совпадают; способ вычисления не влияет на геометрическую конфигурацию данных. При обычном запуске программы трёхмерный график можно вращать с помощью мыши.

5 Интерпретация спектра и влияние масштаба

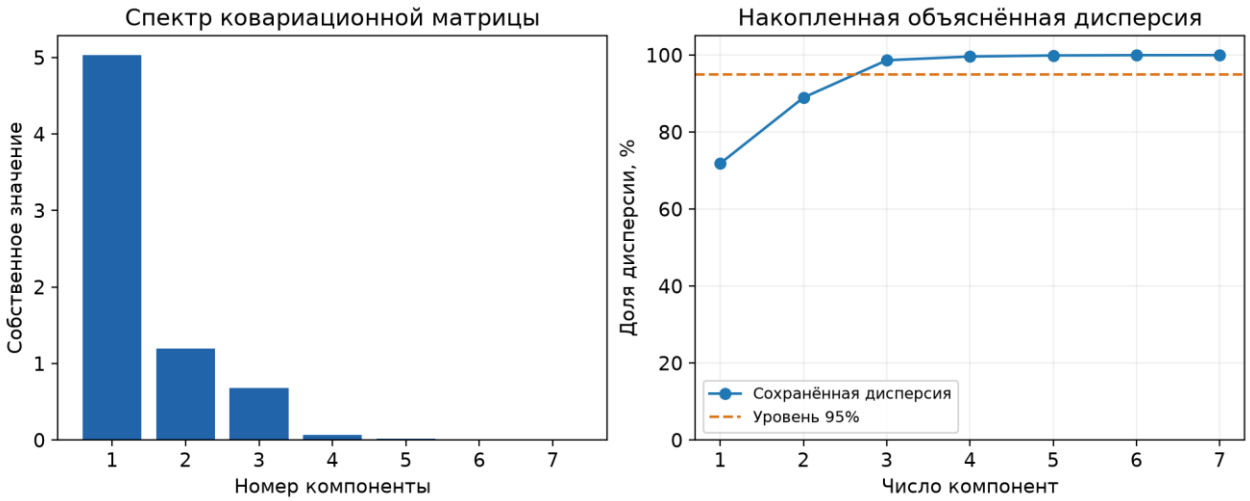


Рисунок 3 — Спектр и накопленная объяснённая дисперсия

PC1 содержит 71,874303% стандартизованной дисперсии; PC2 — 17,108184%; PC3 — 9,685763%. После третьей компоненты спектр резко уменьшается: все оставшиеся компоненты вместе дают 1,331750%. Поэтому переход от семи признаков к трём позволяет сохранить основную геометрию выборки в выбранной метрике.

Коэффициенты первых трёх компонент

Признак	PC1	PC2	PC3
X1	0,4445	0,0266	0,0259
X2	0,4416	0,0840	-0,0598
X3	0,2770	-0,5292	0,6297
X4	0,4236	0,2060	-0,2119
X5	0,4328	-0,1167	0,2165
X6	-0,1187	0,7169	0,6795
X7	0,3872	0,3772	-0,2139

PC1 в основном объединяет признаки X1, X2, X4, X5 и X7 с положительными коэффициентами. Во второй компоненте наиболее заметны X6 и X3 с противоположными знаками, в третьей — X6 и X3 с одинаковыми знаками. Приведены коэффициенты нормированных собственных векторов; их знак выбран по описанному правилу.

Дополнительный расчёт без стандартизации

Подготовка	Потери при k = 2, %	Потери при k = 3, %
Центрирование и деление на s	11,017514	1,331750
Только центрирование	0,698235	0,132444

Без деления на s две компоненты сохраняют уже 99,301765% исходной суммарной дисперсии. Это не означает, что этот вариант лучше сохраняет все признаки: в исходной шкале крупные дисперсии имеют больший вес. Проценты относятся к разным метрикам. Основной вывод о достаточности трёх компонент относится к стандартизованным данным; программа также позволяет воспроизвести вариант с одним центрированием.

Проверки реализации

Автоматизированные проверки показали, что матрица имеет размер 210 × 7, содержит три класса по 70 объектов и не имеет пропусков. Были проверены нулевые средние и единичные выборочные дисперсии после стандартизации, выполнение равенства $Sv_j = \lambda_j v_j$, ортонормированность собственных векторов и возможность полностью восстановить исходную матрицу при сохранении всех семи компонент.

При k = 2 и k = 3 подтверждены совпадение ручного и библиотечного решений, равенство ошибки реконструкции сумме отброшенных собственных значений, умноженной на n − 1, корректная загрузка TXT и ZIP, а также замена специально добавленного NaN медианой. Все эти проверки успешно выполнялись как после стандартизации, так и при одном центрировании.

6 Выводы

Мет Метод PCA реализован двумя независимыми способами. Результаты numpy.linalg.eig и sklearn.decomposition.PCA совпали в пределах машинного округления, что подтверждено сравнением спектров, проекторов, координат и реконструкций.

Для стандартизованной выборки seeds переход 7 → 2 сохраняет 88,98% дисперсии и теряет 11,02%; переход 7 → 3 сохраняет 98,67% и теряет 1,33%. Двумерная проекция удобна для общего обзора, а трёхмерная заметно точнее передаёт геометрию и достигает выбранного ориентира 95%.

На графиках видна структура трёх классов, однако частичное перекрытие между ними сохраняется. Доля сохранённой дисперсии не равна точности классификации. Выбор масштаба признаков существенно влияет на спектр и численные потери, поэтому способ подготовки данных должен быть указан вместе с результатом PCA.