Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №2
За седьмой семестр
По дисциплине: «Интеллектуальный анализ данных»
Тема: Автоэнкодеры и визуализация выборки WDBC

Выполнил:
Студент 4 курса
Группы ИИ-26
Турич Д.А.
Проверил:
Никитин С.К.

Брест 2026

Автоэнкодеры и визуализация выборки WDBC

1 Условие работы и подготовка данных

Цель работы — научиться применять автоэнкодеры для визуализации многомерных данных и сравнить их с t-SNE и методом главных компонент. По варианту 6 используется Wisconsin Diagnostic Breast Cancer (WDBC). Для каждого метода строятся двумерное и трёхмерное представления с различными цветами и формами маркеров для двух классов.

Выборка загружается функцией sklearn.datasets.load_breast_cancer. Она содержит 569 объектов и 30 числовых признаков. В исходном формате WDBC первый столбец — идентификатор, второй — диагноз M/B; они не входят в матрицу признаков. В версии scikit-learn идентификатор исключён, диагноз вынесен в target: 0 соответствует M, 1 соответствует B. Пропусков и бесконечных значений нет.

Класс	Обозначение (target)	Число объектов	Доля в выборке, %
Злокачественные	M → 0	212	37,26
Доброкачественные	B → 1	357	62,74

Тридцать числовых колонок WDBC не являются независимыми: они построены как три статистические свёртки от десяти базовых характеристик клеточного ядра. К характеристикам относятся радиус, текстура, периметр, площадь, гладкость, компактность, вогнутость, число вогнутых точек, симметрия и фрактальная размерность. Каждая из них представлена в трёх вариантах: mean — среднее значение по образцу, error — стандартная ошибка среднего, worst — среднее трёх наибольших измерений. Итоговое число признаков: 10 × 3 = 30..

Стандартизация и схема эксперимента

Исходные 30 признаков WDBC измеряются в разных единицах и имеют разный разброс, поэтому перед снижением размерности каждый столбец приводится к нулевому среднему и единичной выборочной дисперсии. Преобразование выполняется по формуле

$$z_{ij} = (x_{ij} - \mu_j) / s_j; \quad s_j^2 = \Sigma_i (x_{ij} - \mu_j)^2 / (n - 1)$$

где μ_j и s_j — среднее и выборочное стандартное отклонение j-го столбца. Метки классов в преобразовании не участвуют и далее используются исключительно для визуального кодирования точек.

Для итоговых иллюстраций выбранный автоэнкодер повторно обучается на всех 569 объектах, при этом число эпох берётся таким же, как было найдено на валидации. Методы PCA и t-SNE для визуализации также получают полную стандартизованную выборку — так все три метода сравниваются в одинаковых условиях. Числовые результаты далее приводятся отдельно для полной выборки и для тестовой части: эти величины относятся к разным режимам обучения и разным параметрам масштабирования, поэтому их не следует сопоставлять напрямую..

2 Модель автоэнкодера

Автоэнкодер образован двумя частями: кодировщик сжимает 30 входных признаков до k латентных координат, а декодировщик по ним восстанавливает исходный вектор. Все слои — обычные полносвязные torch.nn.Linear. Для k = 2 и k = 3 обучаются раздельные сети; при этом первые две координаты трёхмерной модели не заменяют независимый двумерный эксперимент.

$$h = f\theta(z), \quad \hat{z} = g\varphi(h), \quad h \in R^{k}, \quad k \in \{2,3\}$$

$$MSE = \Sigma_{i}\Sigma_{j}(z_{ij} - \hat{z}_{ij})^{2} / (n \cdot 30)$$

Во внутренних слоях используется активация ReLU. Латентный слой и выход декодировщика оставлены линейными, поскольку и скрытые координаты, и стандартизованные признаки могут принимать отрицательные значения. В качестве функции потерь выбрана средняя квадратичная ошибка восстановления MSE. Оптимизатор — Adam с параметрами $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$ и $\varepsilon = 10^{-8}$, без weight decay.

Экспериментальный подбор параметров

Рассмотрены две симметричные конфигурации сети: 30–16–k–16–30 и 30–32–16–k–16–32–30. В каждой из них проверены темпы обучения 0,001 и 0,003. Число эпох ограничено значением 1500; за одну эпоху выполняется один проход по всей обучающей части. Если валидационная MSE не снижается на протяжении 150 эпох подряд, обучение останавливается. В качестве итоговых берутся веса той эпохи, где валидационная ошибка была минимальной.

k	Скрытые слои кодировщика	Скорость обучения(lr)	Лучшая эпоха	MSE обучения	MSE валидации
2	16	0,001	1428	0,262757	0,293421
2	16	0,003	538	0,270777	0,300369
2	32–16	0,001	402	0,293936	0,304206
2	32–16	0,003	222	0,288834	0,305639
3	16	0,001	486	0,220618	0,232095
3	16	0,003	223	0,214205	0,229429
3	32–16	0,001	393	0,198327	0,231716
3	32–16	0,003	238	0,184674	0,233804

При k = 2 выбрана конфигурация 30–16–2–16–30 со скоростью обучения 0,001; лучшей оказалась эпоха 1428 с валидационной MSE 0,293421 и тестовой 0,287862.

При k = 3 выбрана конфигурация 30–16–3–16–30 со скоростью обучения 0,003; лучшей оказалась эпоха 223 с валидационной MSE 0,229429 и тестовой 0,216510.

Полученное сравнение справедливо лишь в рамках указанной сетки параметров и при одной фиксированной инициализации; оно не подтверждает глобальную оптимальность выбранной сети. Обучение проводится на CPU в формате float64 с одним потоком и включёнными детерминированными алгоритмами.

3 Обучение и скрытое представление

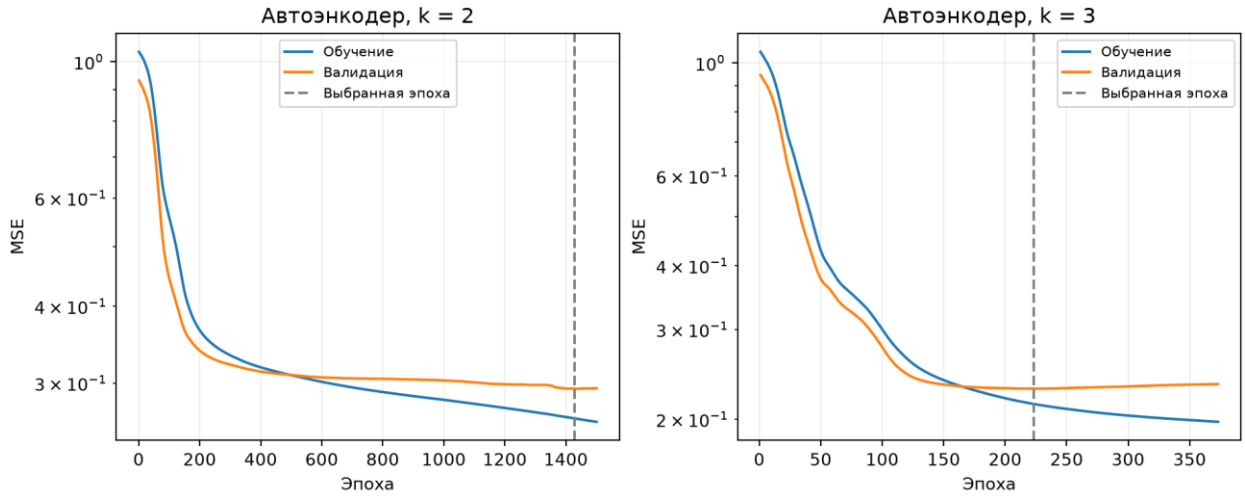


Рисунок 1 — Кривые обучения выбранных автоэнкодеров

Непрерывные линии отображают ошибку на обучающей и валидационной частях, а вертикальная штриховая линия указывает выбранную эпоху. Логарифмическая шкала даёт возможность сопоставить начальный спад и последующие изменения. Кривые относятся к этапу подбора параметров, тогда как итоговые проекции ниже получены после повторного обучения на полной выборке.

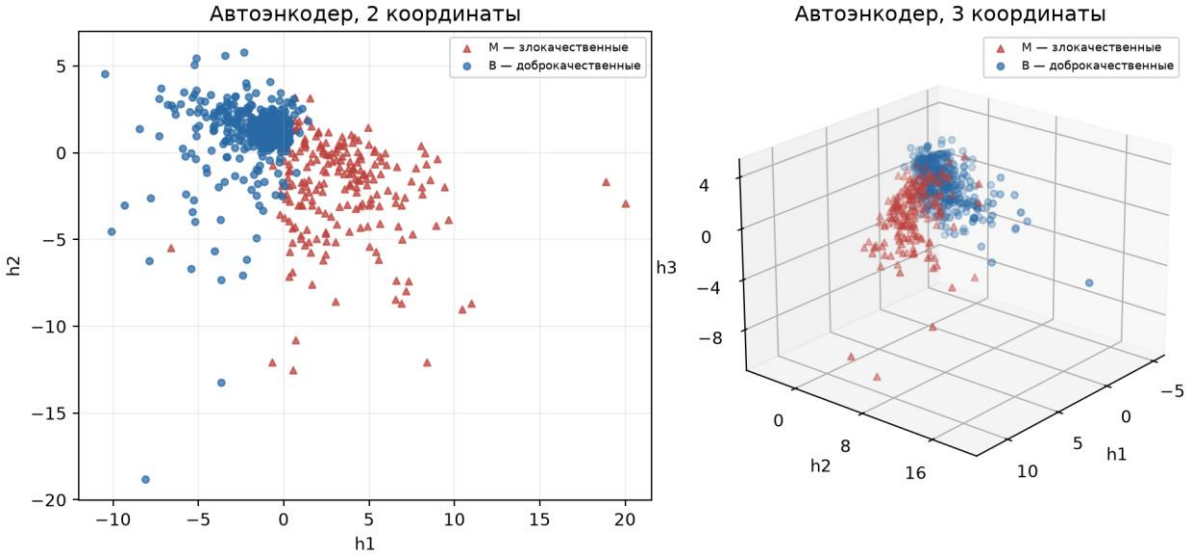


Рисунок 2 — Двумерное и трёхмерное представления автоэнкодера

Красные треугольники соответствуют классу M, синие круги — классу B. Латентное пространство отражает те различия объектов, которые необходимы для восстановления признаков. В нём просматривается структура классов, но в пограничных областях точки по-прежнему перекрываются. Диагноз при обучении не используется, и точность классификации не оптимизируется.

Оси h1, h2 и h3 — это обученные латентные координаты. Для нелинейного автоэнкодера они не обязаны быть ортогональными, упорядоченными по дисперсии или совпадать с главными компонентами. Их масштаб и ориентация задаются весами сети.

4 Визуализация методом t-SNE

Метод t-SNE ставит в соответствие вероятностные соседства объектов в исходном и низкоразмерном пространствах, минимизируя между ними KL-дивергенцию. В отличие от PCA, он нацелен в первую очередь на локальную структуру. Использована реализация `sklearn.manifold.TSNE` с параметрами `init="pca"`, `learning_rate="auto"`, `max_iter=1500`, методом Barnes–Hut и `random_state=42`.

Для каждой размерности проверены значения perplexity = 20, 40 и 60. Перплексивность задаёт эффективный масштаб соседства и должна быть меньше числа объектов. Цветовые метки одинаковы во всех экспериментах; абсолютные размеры и расстояния между отдельными облаками t-SNE не трактуются как расстояния в исходных 30 признаках.

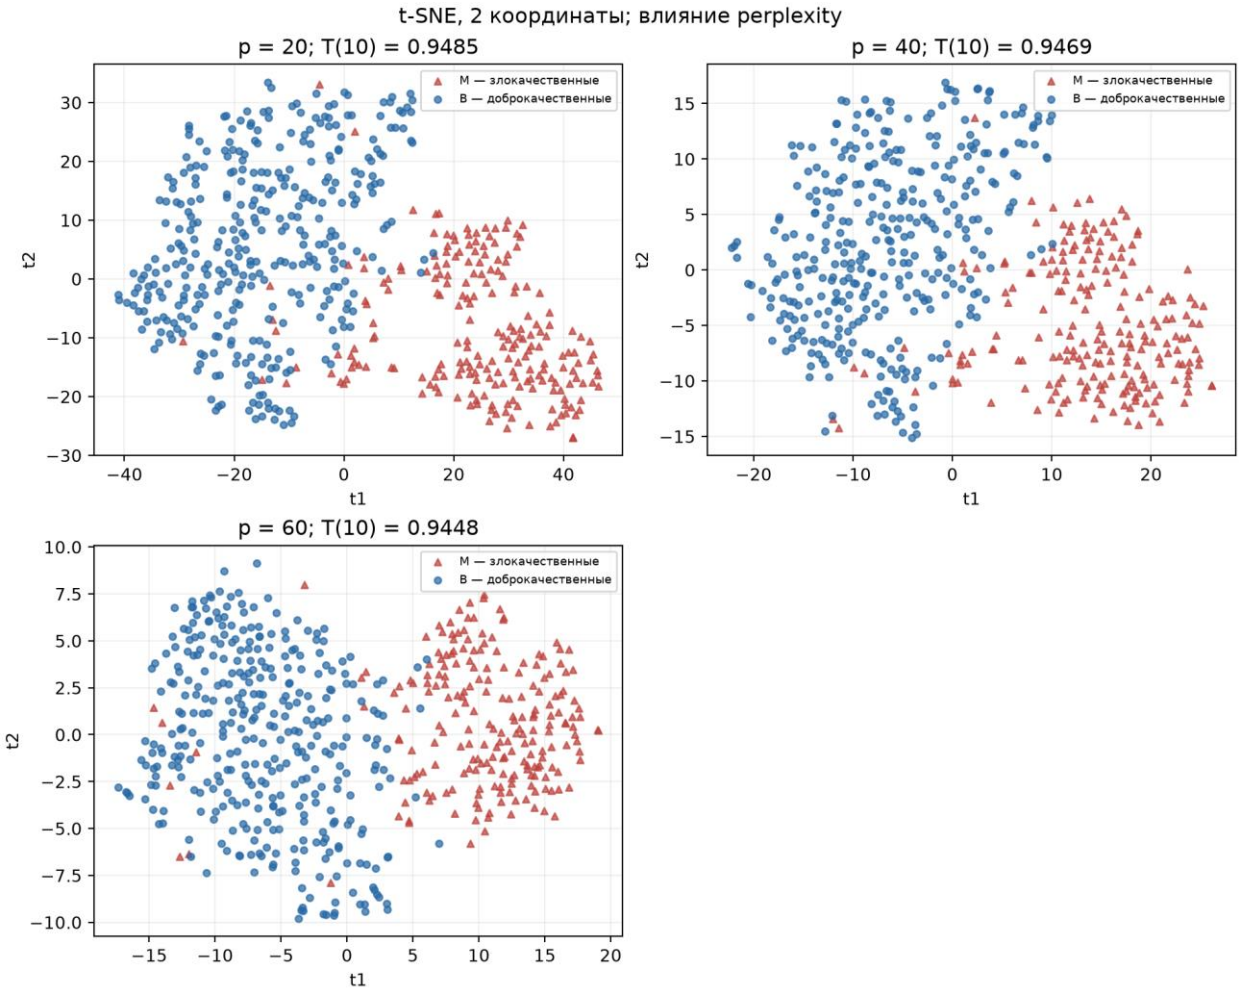


Рисунок 3 — Влияние perplexity на двумерную визуализацию t-SNE

Для двумерного представления максимальная trustworthiness T(10) достигнута при perplexity = 20: 0,948451. Этот вариант выбран по сохранению соседств, а не по использованию диагнозов. Изменение параметра меняет форму облаков, поэтому выбор не опирается только на визуально удачное разделение классов.

5 Трёхмерный t-SNE и оценка соседств

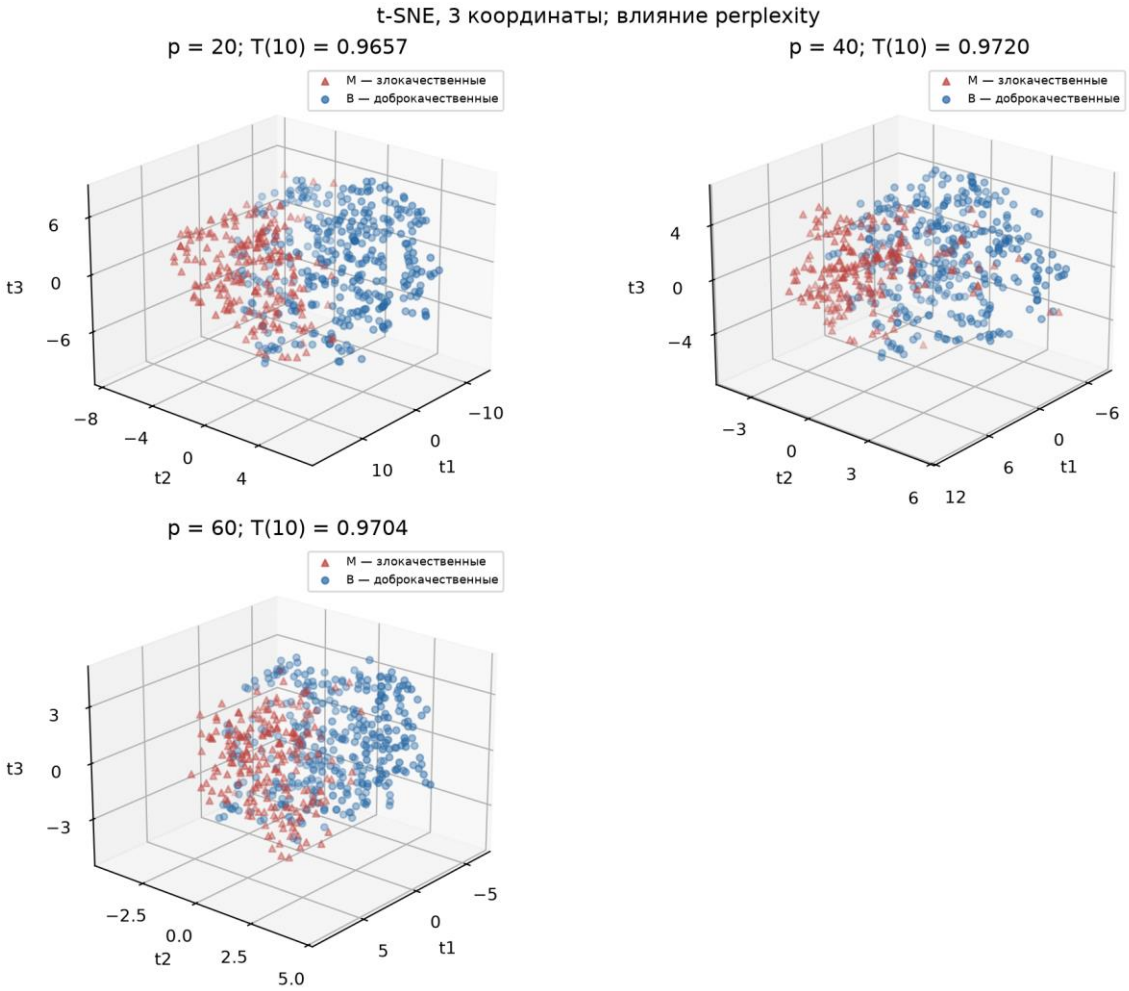


Рисунок 4 — Влияние perplexity на трёхмерную визуализацию t-SNE

Размерность	Perplexity	KL-дивергенция	T(10)
2	20	1,037734	0,948451
2	40	0,850243	0,946859
2	60	0,729892	0,944845
3	20	0,842602	0,965697
3	40	0,659314	0,971986
3	60	0,525900	0,970353

При трёх координатах выбран perplexity = 40, T(10) = 0,971986. Trustworthiness показывает, насколько ближайшие соседи в проекции совпадают с соседями в исходном стандартизованном пространстве. Использованы 10 соседей и евклидова метрика; большее значение лучше, максимум равен 1.

KL приведена как значение целевой функции каждого запуска. При разных perplexity меняются сами исходные вероятности, поэтому минимальная KL между такими запусками не является самостоятельным критерием выбора. У t-SNE нет используемого здесь декодировщика: MSE восстановления и доля объяснённой дисперсии для него не рассчитываются.

6 Применение метода главных компонент

Метод из первой лабораторной работы применён к 30 признакам WDBC. По стандартизованной матрице вычисляется ковариация, а собственные значения и векторы находятся через numpy.linalg.eig. Далее они сортируются по убыванию. Проверены вещественность результата, неотрицательность спектра и ортонормированность выбранного базиса.

$$S = Z^{\mathrm{T}}Z / (n - 1); \quad T_k = ZV_k; \quad Z_k = T_k V_k^{\mathrm{T}}$$

$$R_k = 100 \cdot \Sigma_{j=1}^{k} \lambda_j / \Sigma_{j=1}^{30} \lambda_j$$

Полученный результат независимо сопоставлен с sklearn.decomposition.PCA при svd_solver="full". Так как знак собственного вектора произволен, для проверки подпространства сравниваются проекторы $V_k V_k^{\mathrm{T}}$. Для графиков наибольший по модулю коэффициент каждого вектора делается положительным.

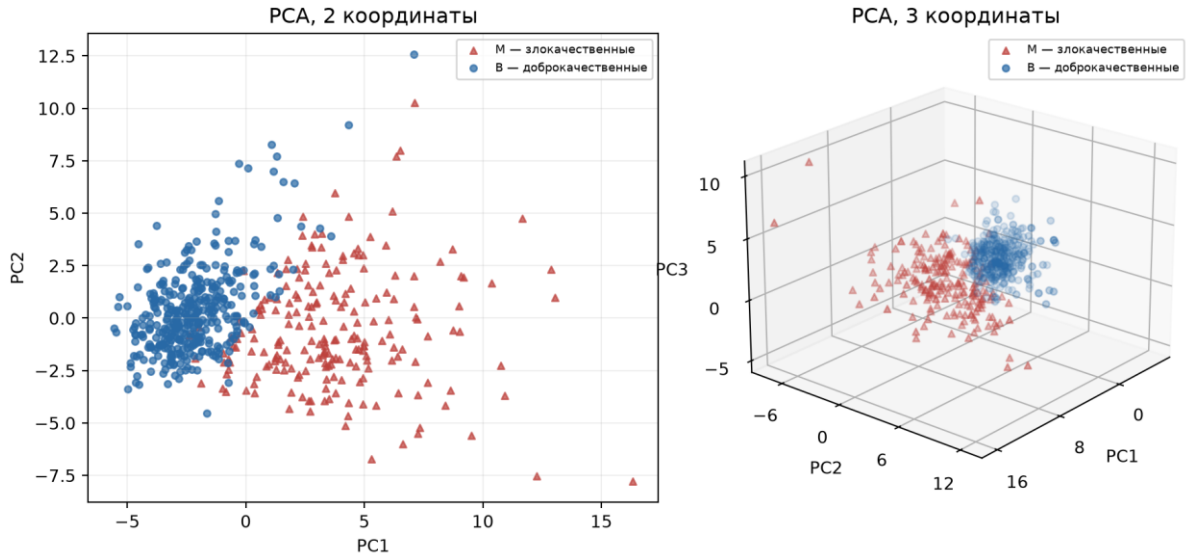


Рисунок 5 — Проекции WDBC на две и три главные компоненты

k	Сохранено, %	Потеряно, %	MSE полной выборки
2	63,2432	36,7568	0,366922
3	72,6364	27,3636	0,273155

Первые две компоненты удерживают 63,24 % стандартизованной дисперсии, три — 72,64 %. Третья компонента добавляет 9,39 процентного пункта. Различия между классами частично видны уже на плоскости, однако облака перекрываются.

Проверено равенство ошибки восстановления сумме отброшенных собственных значений с множителем (n − 1)/(n · 30). Доля сохранённой дисперсии относится к стандартизованным признакам и не является долей верно распознанных диагнозов.

7 Сравнение методов

Метод	k	MSE (полная)	MSE (тест)	T(10) (полная)
PCA	2	0,366922	0,360687	0,871348
Автоэнкодер	2	0,267602	0,287862	0,908507
t-SNE p=20	2	—	—	0,948451
PCA	3	0,273155	0,280674	0,929201
Автоэнкодер	3	0,220465	0,216510	0,946183
t-SNE p=40	3	—	—	0,971986

MSE по полной выборке относится к моделям, обученным на всех объектах после полной стандартизации. MSE теста — к моделям, обученным только на 341 объекте с масштабами этой обучающей части. Поэтому сравнение корректно вести внутри каждого столбца; различие полной и тестовой MSE не следует целиком приписывать переобучению.

При k = 2 тестовая ошибка автоэнкодера составляет 0,287862, PCA — 0,360687. В данном разбиении ошибка автоэнкодера на 20,19 % меньше. Нелинейная модель способна учитывать зависимости, недоступные линейному подпространству, однако результат зависит от архитектуры и обучения.

При k = 3 тестовая ошибка автоэнкодера составляет 0,216510, PCA — 0,280674. В данном разбиении ошибка автоэнкодера на 22,86 % меньше. Нелинейная модель способна учитывать зависимости, недоступные линейному подпространству, однако результат зависит от архитектуры и обучения.

Интерпретация различий

PCA даёт упорядоченные ортогональные направления и точную оценку потерянной дисперсии. Его удобно применять как быстрый и воспроизводимый базовый метод. Оптимальность PCA по квадратичной ошибке относится к линейным ортогональным проекциям и не исключает меньшей ошибки нелинейного автоэнкодера.

Автоэнкодер объединяет кодировщик и декодировщик: новые объекты можно стандартизовать сохранёнными параметрами и преобразовать обученной сетью. За эту гибкость приходится платить подбором параметров. Ошибка восстановления и сохранение соседств характеризуют разные свойства, поэтому лучшая MSE не гарантирует лучшую визуализацию.

t-SNE удобен для исследования локальных групп и показывает высокие значения T(10) в выполненных запусках. Однако его оси не имеют смысла главных компонент; реализация sklearn TSNE не предоставляет `transform` для новых объектов. Качество рисунка на всей выборке не является оценкой работы на независимых новых данных.

Тестовая часть не участвовала в выборе автоэнкодера. Оценка выполнена на одном фиксированном разбиении и не сопровождается доверительными интервалами. Ни один эксперимент не обучает классификатор, поэтому на основании этих графиков вывод о точности диагностики не делается.

8 Программа и проверка корректности

Данные WDBC входят в состав scikit-learn: после установки библиотек не нужны ни отдельный CSV, ни архив, ни доступ к сети. Основной запуск обучает восемь вариантов сетей, отбирает два автоэнкодера, выполняет шесть запусков t-SNE и рассчитывает PCA для двух размерностей.

Команды запуска

```
python -m pip install numpy "scikit-learn>=1.5" matplotlib torch
python iad_lab2_variant1.py
python iad_lab2_variant1.py --no-show
python iad_lab2_variant1.py --self-test
```

При обычном запуске открываются графики matplotlib, а трёхмерные рисунки можно вращать мышью. Флаг `--no-show` сохраняет результаты без окон. Каталог `results_lab2` создаётся рядом со скриптом; другой каталог задаётся параметром `--out`. Параметр `--epochs` изменяет предел обучения; для воспроизведения отчёта используется значение по умолчанию 1500.

В каталог результатов записываются пять PNG, JSON с параметрами и метриками, CSV с координатами и кривыми обучения, а также два файла весов `.pt` с архитектурой и параметрами стандартизации. Исходный код для вычислений остаётся одним Python-файлом.

Проверки реализации

Режим `--self-test` проверяет непересечение обучающей, валидационной и тестовой частей; нулевые средние и единичные выборочные дисперсии; совпадение проекторов ручного PCA и sklearn для k = 2, 3 и 30; формулу ошибки реконструкции; уменьшение MSE в процессе обучения; размеры выходов и повторяемость автоэнкодера при одинаковом seed. Эти проверки пройдены.

Основной запуск дополнительно контролирует размер 569 × 30, численность классов, конечность данных и скрытых координат, совпадение спектров PCA и отсутствие расходимости обучения. Таблицы и изображения отчёта получены именно этим запуском, а не заданы вручную.

9 Выводы

Для варианта 6 выполнено снижение размерности WDBC с 30 признаков до двух и трёх координат тремя методами. Построены отдельные визуализации автоэнкодера, t-SNE и PCA; классы обозначены одинаковыми цветами и формами маркеров.

Архитектура и скорость обучения автоэнкодера выбраны экспериментально по валидационной ошибке среди четырёх комбинаций для каждой размерности. Сохранены веса лучшей эпохи; тестовая часть задействована только после выбора. Нелинейное представление обеспечивает восстановление признаков и выявляет структуру классов при сохранении пограничного перекрытия.

Для t-SNE проверены значения perplexity 20, 40 и 60. По T(10) выбраны 20 для двумерного и 40 для трёхмерного представления. Сравнение показало зависимость геометрии рисунка от параметра соседства. Расстояния между облаками и размеры кластеров не трактуются как точное воспроизведение исходной геометрии.

PCA сохраняет 63,24 % дисперсии при двух компонентах и 72,64 % при трёх. Ручное вычисление через eig согласуется с библиотечной реализацией. Рост размерности улучшает восстановление PCA, однако даже три компоненты не сохраняют всю дисперсию 30 признаков.

Выбор метода определяется задачей: PCA удобен для линейного сжатия с интерпретируемыми потерями, автоэнкодер — для нелинейного кодирования с восстановлением, t-SNE — для локальной визуализации. Качество восстановления, сохранение соседств и визуальное разделение классов не являются взаимозаменяемыми критериями.