Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №3
За седьмой семестр
По дисциплине: «Интеллектуальный анализ данных»
Тема: Предобучение нейронных сетей с использованием автоэнкодеров

Выполнил:
Студент 4 курса
Группы ИИ-26(2)
Турич Д.А.
Проверил:
Никитин С.К.

Брест 2026

Послойное предобучение глубоких нейронных сетей

1 Условие работы и исходные данные

Цель работы — реализовать предобучение глубокой нейронной сети с помощью автоэнкодера и сопоставить качество классификации с обучением той же архитектуры без предобучения. В варианте 6 используется Credit Approval с целевой переменной «+ / −». Согласно пункту 4 задания эксперимент повторяется на WDBC — выборке варианта 6 из лабораторной работы №2.

Для каждой выборки выполнены три парных запуска с разными начальными весами. Основные показатели — F1 положительного класса и матрица ошибок; дополнительно рассчитаны accuracy, precision, recall, macro-F1 и ROC-AUC. В проведённых экспериментах предобучение не улучшило средний F1: на Credit Approval он снизился, на WDBC остался тем же.

Датасет	N	Признаков	Классы 0 / 1	Численность 0 / 1
Credit Approval	690	15	− / +	383 / 307
WDBC	569	30	B / M	357 / 212

Credit Approval

Исходный файл crx.data взят из UCI Machine Learning Repository. Он содержит 15 входных столбцов A1–A15 и класс A16. Названия и значения атрибутов обезличены, поэтому предметный смысл им не приписывается. Положительному классу «+» присвоено значение 1, классу «−» — 0.

Числовые столбцы: A2, A3, A8, A11, A14 и A15. Остальные девять — категориальные. Символ «?» обозначает пропуск. Всего найдено 67 пропущенных значений в 37 строках. Числовые пропуски заменяются медианой, категориальные — наиболее частым значением, причём оба показателя вычисляются по обучающей части.

Числовые столбцы стандартизуются через StandardScaler; категориальные преобразуются OneHotEncoder без удаления первой категории. Неизвестная категория при обработке отложенных данных кодируется нулевым блоком. После обучения преобразователя на train получается 46 входных координат: 6 числовых и 40 категориальных индикаторов.

WDBC из лабораторной работы 2

Выборка загружается через `sklearn.datasets.load_breast_cancer`. Матрица содержит 30 числовых признаков; идентификатор в неё не входит. Диагноз используется только как целевая переменная. Здесь класс M перекодирован в 1, класс B — в 0, чтобы recall характеризовал выявление положительного класса M. Пропусков нет; стандартизатор обучается только на train.

2 Архитектура и алгоритм предобучения

Применена полносвязная сеть d–64–32–16–8–1, где d = 46 для Credit Approval и d = 30 для WDBC. Она включает четыре скрытых слоя и выходной слой, то есть пять обучаемых линейных преобразований. Вход обучаемым слоем не считается. Требование методички «более 3 слоёв» выполнено.

$$x \rightarrow Linear(d, 64) \rightarrow ReLU \rightarrow Linear(64,32) \rightarrow ReLU$$

$$\rightarrow Linear(32,16) \rightarrow ReLU \rightarrow Linear(16,8) \rightarrow ReLU \rightarrow Linear(8,1)$$

Выходной слой возвращает логит a. Вероятность положительного класса равна sigmoid(a). В ходе supervised-обучения используется BCEWithLogitsLoss, объединяющая сигмоиду и бинарную кросс-энтропию численно устойчивым способом. Порог классификации зафиксирован заранее на уровне 0,5 и по тесту не подбирается.

Послойный алгоритм из лекции

1. Первый скрытый слой играет роль кодировщика автоэнкодера d–64–d. Кодировщик использует ReLU, декодировщик линеен. Сеть обучается восстанавливать подготовленные входы train по MSE без привлечения меток классов.
2. По завершении 100 эпох веса и смещения кодировщика переносятся в первый скрытый слой классификатора. Декодировщик отбрасывается. Выходы кодировщика вычисляются без градиентов и становятся обучающими входами следующего автоэнкодера.
3. Таким же образом обучаются автоэнкодеры 64–32–64, 32–16–32 и 16–8–16. При обучении очередного слоя ранее обученные слои остаются зафиксированными. Переносится именно кодирующая половина каждой сети вместе со смещениями.
4. После предобучения четырёх скрытых слоёв выходной слой классификатора обучается с учителем при фиксированном кодировщике. Затем все слои размораживаются, и вся сеть совместно дообучается методом обратного распространения ошибки. Последовательность соответствует слайду 13 приложенной лекции.

$$h_l = ReLU(W_l h_{l-1} + b_l); \quad h_0 = x$$

$$\hat{h}_{l-1} = D_l h_l + c_l; \quad MSE_l = \Sigma_i \Sigma_l (h_{i,l} - \hat{h}_{i,l})^2 / (n \cdot d_{l-1})$$

Для слоя l восстанавливается его собственный вход h_{l-1}, а не исходная метка класса и не всегда исходный вектор x. Линейный декодировщик допускает восстановление отрицательных стандартизованных координат. Первое скрытое пространство шире входа, что является допустимым избыточным автоэнкодером. Последующие слои постепенно уменьшают размерность до восьми

3 Схема сравнения и метрики

Каждая выборка однократно делится стратифицированно в пропорции 60/20/20 при random_state=42. Пропорции классов сохраняются с округлением до целого числа объектов. Разбиение общее для обоих режимов и всех трёх инициализаций. Индексы частей сохраняются в results.json.

Датасет	Подвыборка	Объекты	Класс 0	Класс 1
Credit Approval	Обучение	414	230	184
Credit Approval	Валидация	138	76	62
Credit Approval	Тест	138	77	61
WDBC	Обучение	341	214	127
WDBC	Валидация	114	71	43
WDBC	Тест	114	72	42

Медианы, моды, средние значения, стандартные отклонения и словари категорий вычисляются только по train. Предобучение также получает исключительно train, без меток. Validation служит для выбора эпохи supervised-дообучения. Test подключается после выбора весов — для расчёта итоговых метрик; результаты теста не влияют на параметры обучения.

Настройка	Величина
Инициализации	42, 43, 44; одинаковые начальные веса внутри пары
Оптимизатор	Adam; lr = 0,001; $\beta_1 = 0{,}9$; $\beta_2 = 0{,}999$; $\varepsilon = 10^{-8}$
Предобучение	100 эпох на каждый из четырёх автоэнкодеров
Выходной слой	30 supervised-эпох при фиксированных скрытых слоях
Совместное дообучение	До 400 эпох; patience = 50; минимум validation BCE
Режим вычислений	Полный batch, CPU, float32, один поток

В режиме без предобучения этап автоэнкодеров пропускается. Чтобы изолировать его влияние, оба режима получают одинаковую supervised-схему: 30 эпох только для выходного слоя, затем дообучение всей сети. В baseline скрытые слои на первом этапе случайны. Совпадают начальные веса, архитектура, оптимизатор, максимальный supervised-бюджет и правило выбора эпохи; фактическое число шагов может различаться из-за early stopping.

$$Precision = TP / (TP + FP); \quad Recall = TP / (TP + FN)$$

$$F1 = 2TP / (2TP + FP + FN); \quad Accuracy = (TP + TN) / N$$

В матрицах ошибок строки соответствуют истинным классам, столбцы — предсказанным, порядок классов [0, 1]. Macro-F1 усредняет F1 по двум классам. ROC-AUC вычисляется по вероятностям, а не по бинарным предсказаниям, поэтому может различаться при совпадающих матрицах ошибок.

4 Результаты послойного предобучения

Кривые и детальные матрицы далее приведены для заранее выбранного seed=42. Этот запуск не отбирался как лучший по тесту. Предобучение каждого слоя останавливается после 100 эпох; указаны MSE перед первым шагом и после последнего.

Датасет	Автоэнкодер	MSE до	MSE после
Credit Approval	46–64–46	0,356780	0,041660
Credit Approval	64–32–64	0,325680	0,061902
Credit Approval	32–16–32	0,446011	0,045942
Credit Approval	16–8–16	0,578245	0,188742
WDBC	30–64–30	1,036022	0,116054
WDBC	64–32–64	0,555984	0,079317
WDBC	32–16–32	0,897913	0,196242
WDBC	16–8–16	0,873593	0,341176

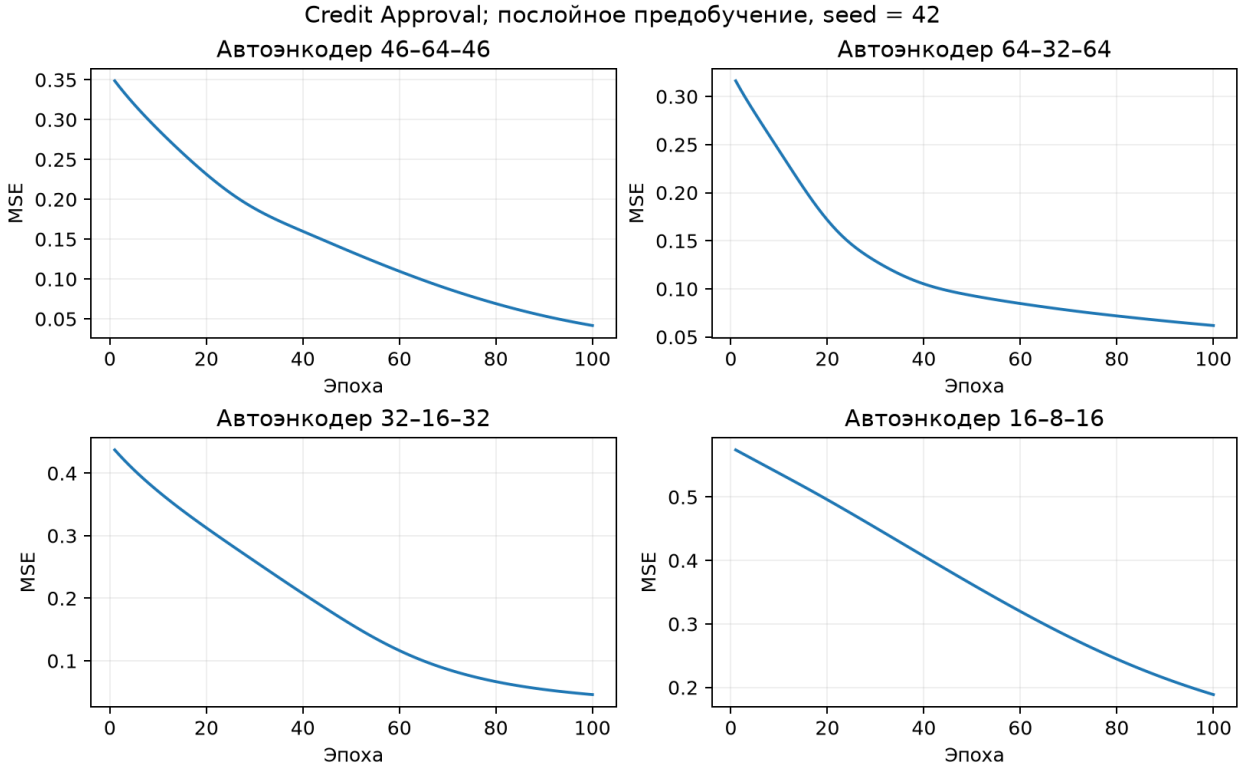


Рисунок 1 — Обучение четырёх автоэнкодеров Credit Approval

У всех восьми автоэнкодеров в двух выборках MSE снизилась. Это подтверждает, что сеть научилась восстанавливать входное представление. Однако значения MSE разных слоёв относятся к разным размерностям и масштабам, поэтому напрямую сравнивать их как качество классификации нельзя.

Код проверяет неизменность предыдущих слоёв при обучении текущего автоэнкодера и неизменность выходного слоя на этапе предобучения. После переноса весов первый supervised-этап обновляет только выходной слой; на этапе тонкой настройки изменяются все параметры сети.

5 Классификация Credit Approval

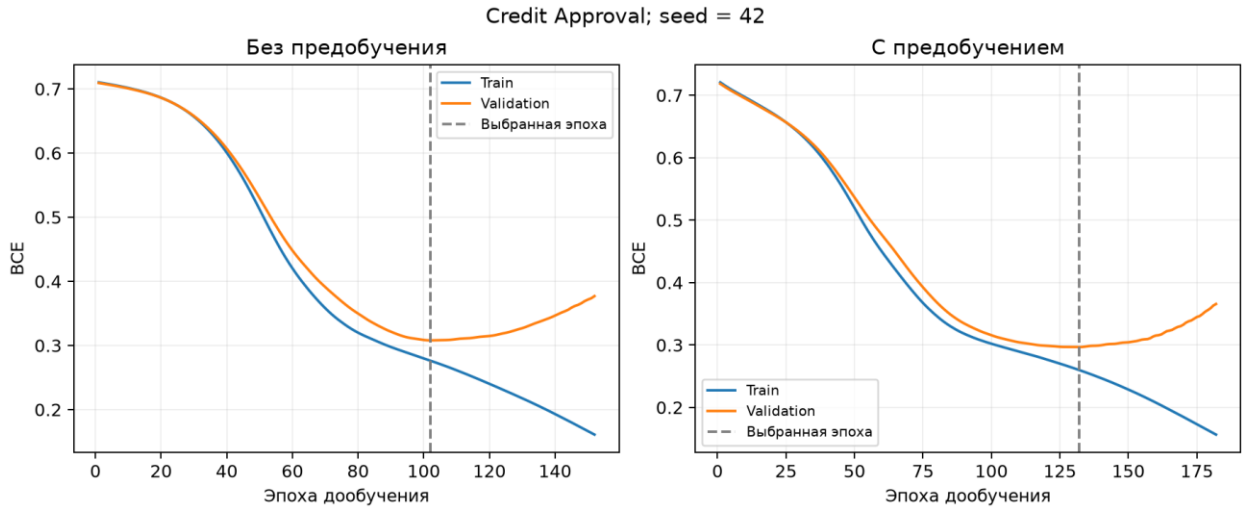


Рисунок 2 — Supervised-дообучение Credit Approval при seed 42

Минимальная validation BCE без предобучения составила 0,307900 на эпохе 102; с предобучением — 0,296726 на эпохе 132. Вертикальная линия отмечает выбранную эпоху. По оси X отсчитываются только эпохи совместного дообучения, без 30 эпох обучения выхода и без этапов автоэнкодеров.

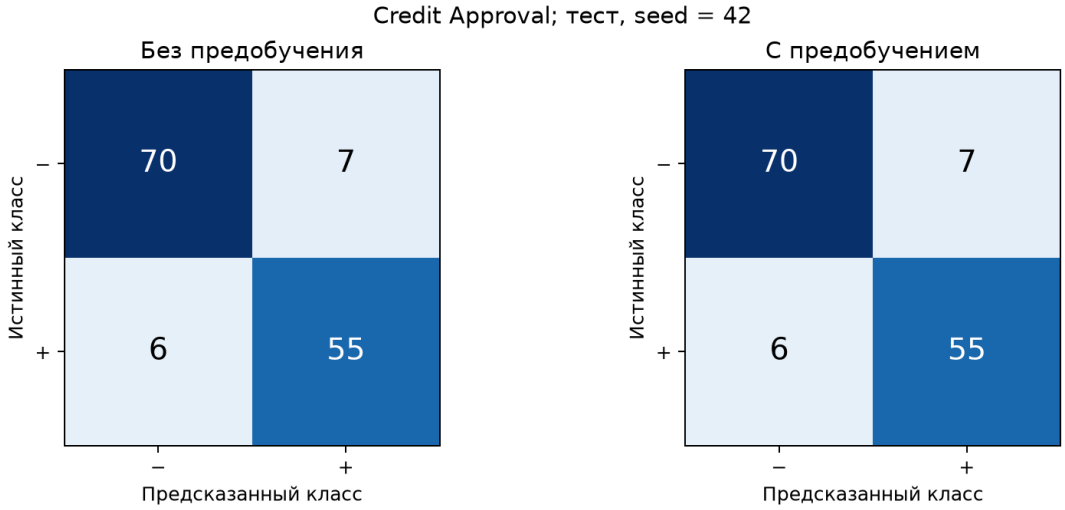


Рисунок 3 — Матрицы ошибок Credit Approval на тесте при seed 42

В рассматриваемом запуске оба режима дали одинаковые матрицы ошибок: TN = 70, FP = 7, FN = 6, TP = 55. Accuracy = 90,58 %, precision = 0,8871, recall = 0,9016, F1 = 0,8943. Это совпадение относится к порогу 0,5; сами веса и вероятности моделей при этом различаются.

ROC-AUC без предобучения составила 0,955291, с предобучением — 0,957207. Для оценки зависимости результата от инициализации далее приведены все три запуска, включая seed 43 и 44.

6 Классификация WDBC

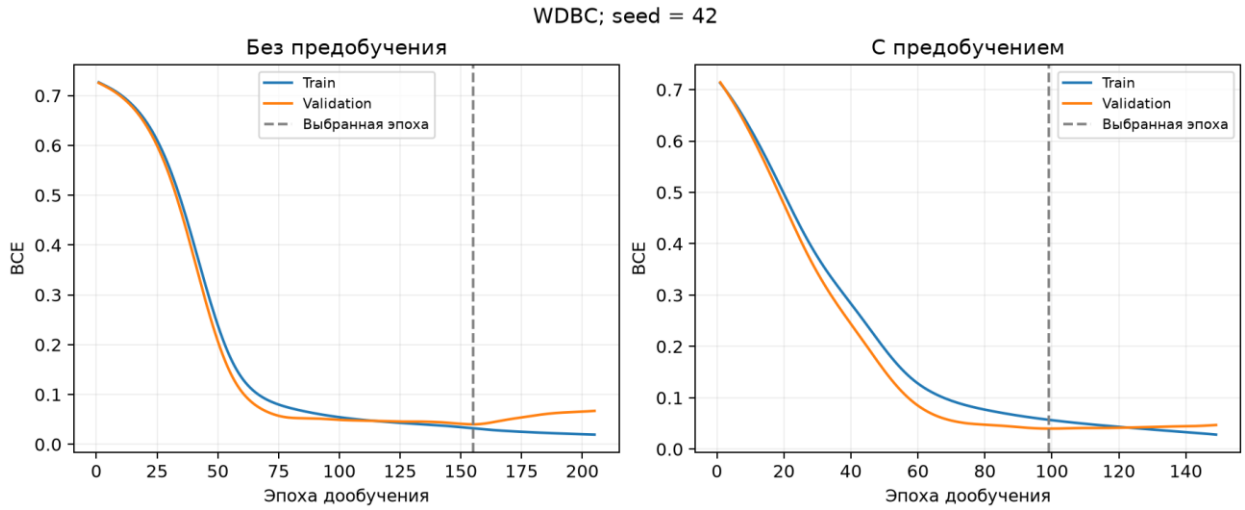


Рисунок 4 — Supervised-дообучение WDBC при seed 42

Минимальная validation BCE без предобучения составила 0,040014 на эпохе 155; с предобучением — 0,039937 на эпохе 99. Вертикальная линия отмечает выбранную эпоху. По оси X отсчитываются только эпохи совместного дообучения, без 30 эпох обучения выхода и без этапов автоэнкодеров

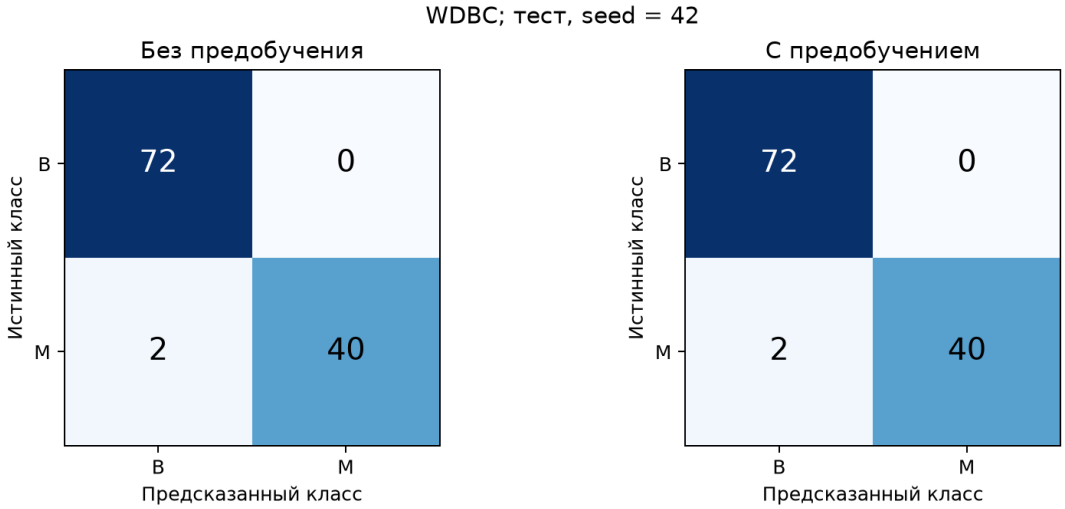


Рисунок 5 — Матрицы ошибок WDBC на тесте при seed 42

В рассматриваемом запуске оба режима дали одинаковые матрицы ошибок: TN = 72, FP = 0, FN = 2, TP = 40. Accuracy = 98,25 %, precision = 1,0000, recall = 0,9524, F1 = 0,9756. Это совпадение относится к порогу 0,5; сами веса и вероятности моделей при этом различаются.

При этом совпадение матриц не означает совпадения решений по каждому объекту: при seed=42 предсказания различаются для двух тестовых объектов. Число ошибок каждого типа остаётся тем же. Для seed=43 и 44 совпадают и бинарные предсказания.

ROC-AUC без предобучения составила 0,980159, с предобучением — 0,996032. Для оценки зависимости результата от инициализации далее приведены все три запуска, включая seed 43 и 44.

7 Сравнение по трём инициализациям

Датасет	Режим	F1 без предобучения	F1 с предобучением	Разность F1
Credit Approval	42	0,8943	0,8943	0,0000
Credit Approval	43	0,9032	0,8571	-0,0461
Credit Approval	44	0,8960	0,8943	-0,0017
WDBC	42	0,9756	0,9756	0,0000
WDBC	43	0,9630	0,9630	0,0000
WDBC	44	0,9630	0,9630	0,0000

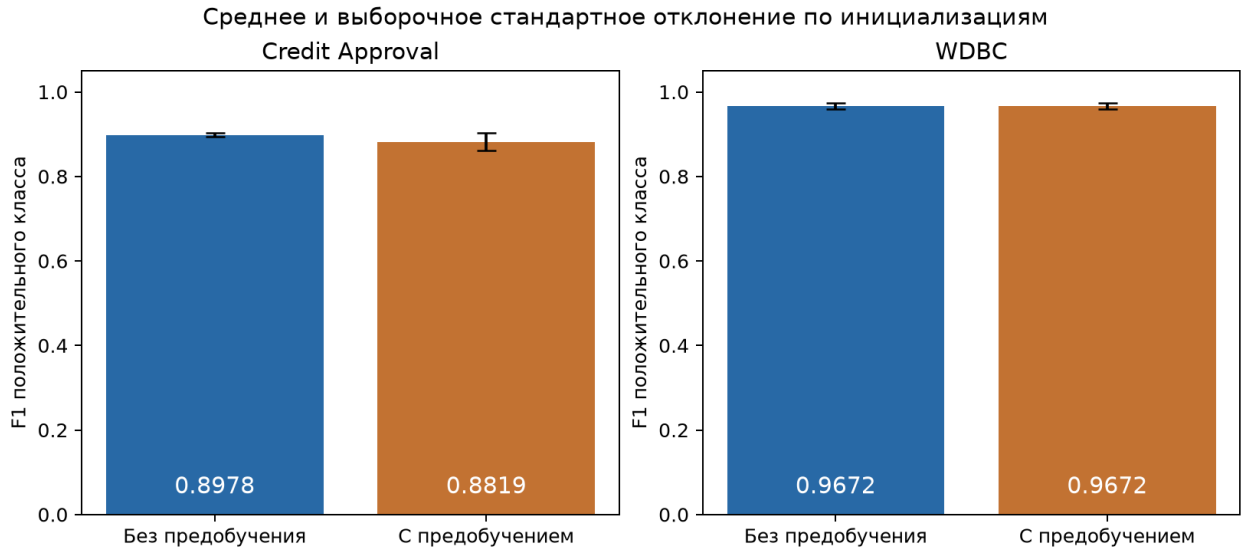


Рисунок 6 — Средний F1 и его разброс по трём инициализациям

Датасет	Режим	Accuracy	F1	ROC-AUC
Credit Approval	Без предобучения	0,9082 ± 0,0042	0,8978 ± 0,0047	0,9485 ± 0,0139
Credit Approval	С предобучением	0,8961 ± 0,0167	0,8819 ± 0,0215	0,9400 ± 0,0306
WDBC	Без предобучения	0,9766 ± 0,0051	0,9672 ± 0,0073	0,9851 ± 0,0086
WDBC	С предобучением	0,9766 ± 0,0051	0,9672 ± 0,0073	0,9888 ± 0,0064

В таблице приведены среднее ± выборочное стандартное отклонение (ddof=1). Все запуски используют одну и ту же тестовую часть; меняются только начальные веса. Этот разброс характеризует чувствительность к инициализации, а не неопределённость по всем возможным разбиениям данных и не доверительный интервал.

Для Credit Approval средний F1 изменился с 0,8978 до 0,8819: разность −0,0159, или −1,59 процентного пункта при представлении F1 в процентах. Основное ухудшение наблюдается при seed=43: число FN увеличилось с 5 до 10. Для WDBC F1 совпал в каждой из трёх пар; среднее равно 0,9672.

8 Интерпретация результатов

Автоэнкодер настраивается на восстановление входа, тогда как классификатор — на различение меток. Сохранение вариаций признаков не обязательно усиливает направления, значимые для целевого класса. Поэтому уменьшение MSE на всех этапах автоэнкодеров совместимо с отсутствием роста F1. Полученные результаты не расходятся с самим алгоритмом предобучения.

Применяемая базовая сеть с ReLU и Adam уже обучается без предобучения. На WDBC она достигает высокого F1, поэтому дополнительная инициализация не изменила ни F1, ни суммарную матрицу ошибок при пороге 0,5. Предобучение изменило упорядочение вероятностей: средний ROC-AUC вырос с 0,9851 до 0,9888. Данное наблюдение относится к фиксированному тесту.

Число эпох и вычислительные затраты

Датасет	Seed	Эпоха без предобучения	Эпоха с предобучением
Credit Approval	42	102	132
Credit Approval	43	113	118
Credit Approval	44	100	121
WDBC	42	155	99
WDBC	43	132	360
WDBC	44	146	157

Предобучение дополнительно требует 4 × 100 = 400 шагов по полным обучающим представлениям. Эти шаги имеют иную стоимость, чем шаг классификатора, поскольку автоэнкодеры отличаются по размерности. Одинаковый максимум supervised-эпох не означает одинаковое полное время работы.

Для WDBC при seed=42 лучшая эпоха дообучения сместилась с 155 на 99, но при seed=43 — с 132 на 360. Следовательно, в проведённых запусках утверждать устойчивое ускорение нельзя. При seed=43 предобученная WDBC-сеть выполнила все 400 разрешённых эпох; сохранены веса эпохи 360. Ранний останов не срабатывает, если предел эпох достигнут раньше patience.

Границы выводов

Архитектура и параметры были зафиксированы до сравнения. Поиск лучших параметров по тесту не проводился. Три инициализации и одно разбиение дают ограниченный эксперимент: нельзя заключать, что предобучение всегда ухудшает Credit Approval или всегда бесполезно для WDBC. Для более широкого вывода потребовались бы дополнительные разбиения и оценка статистической устойчивости.

В отличие от лабораторной работы №2 здесь решается задача классификации. Переносить выводы о качестве реконструкции или разделении облаков на точность классификатора нельзя. Кроме того, используется новое стратифицированное разбиение и подготовка данных, обучаемая только по train; числа из предыдущего отчёта напрямую не сопоставляются с текущими метриками.

9 Реализация и проверка программы

В файл встроена сжатая копия crx.data; при загрузке проверяется SHA-256. WDBC берётся из scikit-learn. После установки зависимостей отдельные CSV и интернет для запуска не требуются. Для Credit Approval сохранены ссылка на UCI, автор, DOI и лицензия CC BY 4.0.

Команды запуска

```
python -m pip install numpy "scikit-learn>=1.2" matplotlib torch
python iad_lab3_variant1.py
python iad_lab3_variant1.py --no-show
python iad_lab3_variant1.py --self-test
```

Обычный запуск выполняет обе задачи и открывает семь рисунков matplotlib. Флаг `--no-show` сохраняет рисунки без окон. По умолчанию результаты помещаются в `results_lab3` рядом со скриптом; параметр `--out` задаёт другой каталог. `--seeds`, `--pretrain-epochs` и `--epochs` позволяют менять условия эксперимента; отчёт соответствует значениям по умолчанию.

Сохраняются `results.json` с настройками, разбиением, кривыми и метриками; `metrics.csv`; CSV с вероятностями и предсказаниями каждого запуска; файлы весов `.pt` и обученные преобразователи `.joblib`. Для преобразования новых объектов следует использовать сохранённый преобразователь, а не обучать стандартизацию повторно.

Выполненные проверки

Проверены целостность встроенных данных, размеры выборок и численности классов, отсутствие пересечений train/validation/test, обучение стандартизатора только по train, конечность подготовленных признаков и наличие ровно пяти линейных слоёв классификатора.

Проверены уменьшение MSE после короткого предобучения, изменение кодирующих весов, неизменность предыдущих слоёв и выходной головы на соответствующих этапах, воспроизводимость при одинаковом seed и изменение скрытых весов при совместном дообучении. Также проверены диапазон вероятностей, сумма элементов матрицы ошибок и формулы accuracy и F1.

Режим `--self-test` пройден. Полный запуск завершил все 12 экспериментов: две выборки, два режима и три инициализации. Таблицы и рисунки отчёта построены по результатам этого запуска. Детальные показатели дополнительных метрик и всех эпох доступны в JSON и CSV.

10 Выводы

Реализована сеть с пятью обучаемыми слоями и два режима её обучения для Credit Approval и WDBC. Режим с автоэнкодером выполнен по лекционному алгоритму: четыре последовательных этапа восстановления без меток, перенос кодирующих весов, supervised-обучение выхода и совместная тонкая настройка всех слоёв.

Данные разделены на независимые обучающую, валидационную и тестовую части. Подготовка и предобучение используют только train; лучшие веса выбираются по validation BCE. Сравнение проведено при одинаковых начальных весах внутри каждой пары и одинаковой supervised-схеме.

На Credit Approval средний F1 положительного класса составил 0,8978 без предобучения и 0,8819 с предобучением. Средний recall снизился с 0,9126 до 0,8798. Следовательно, в выполненном эксперименте baseline оказался предпочтительнее по F1.

На WDBC средний F1 равен 0,9672 в обоих режимах, средняя accuracy — 97,66 %. Различия ROC-AUC показывают, что совпадение F1 и матриц ошибок ещё не означает совпадения всех предсказаний или вероятностных оценок. Предобучение не дало устойчивого уменьшения числа эпох и добавило вычислительные затраты.

Основной вывод: автоэнкодерное предобучение — это способ инициализации признаковых слоёв, а не гарантия улучшения классификации. Его полезность следует проверять по целевым метрикам на отложенных данных. В данной конфигурации ReLU-сеть с Adam достаточно эффективно обучилась и без него; вывод ограничен выбранными архитектурой, параметрами и разбиением.