Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №5
За седьмой семестр
По дисциплине: «Интеллектуальный анализ данных»
Тема: Деревья решений и ансамбли деревьев

Выполнил:
Студент 4 курса
Группы ИИ-26
Турич Д.А.
Проверил:
Никитин С.К.

Брест 2026

Классификация ирисов деревьями решений

1 Цель и исходные данные

Цель работы — сопоставить одиночное дерево решений, случайный лес и три алгоритма бустинга на задаче определения вида ириса. В варианте 6 использован предоставленный файл iris.csv. Основная метрика — accuracy на общей тестовой выборке. Дополнительно рассчитаны macro-F1, матрицы ошибок и точность кросс-валидации на обучающей части.

На выбранном тестовом разбиении наибольшую accuracy 0,9778 показало дерево решений. Этот результат относится к 45 тестовым объектам и заданным параметрам; он не доказывает универсального превосходства метода.

Набор содержит 150 наблюдений, четыре числовых признака в сантиметрах и целевой столбец variety. Классы Setosa, Versicolor и Virginica представлены по 50 раз. Пропущенных, бесконечных и неположительных значений измерений не обнаружено. Идентификаторы строк как признаки не используются.

Признак	Минимум	Максимум	Среднее	Станд. откл.
Длина чашелистика	4,300	7,900	5,843	0,828
Ширина чашелистика	2,000	4,400	3,057	0,436
Длина лепестка	1,000	6,900	3,758	1,765
Ширина лепестка	0,100	2,500	1,199	0,762

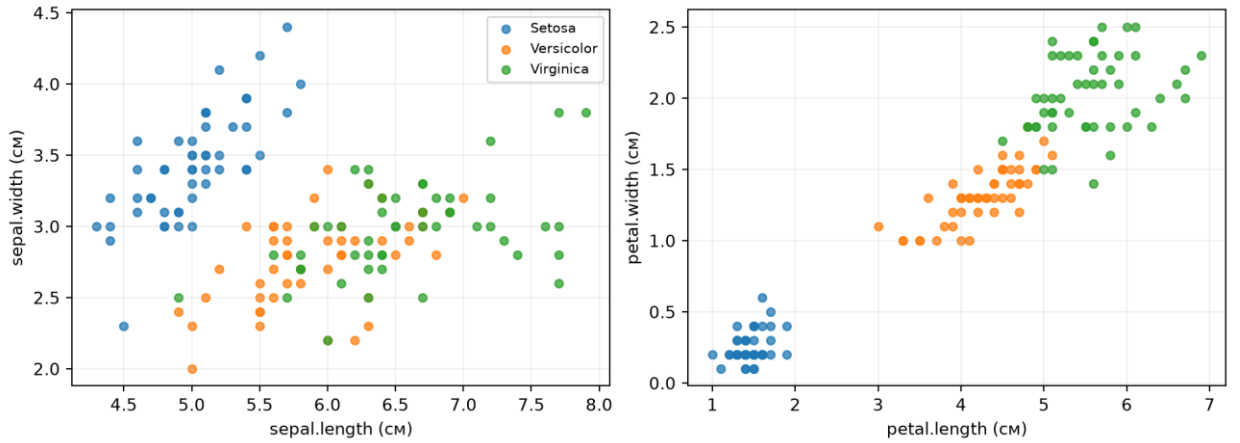


Рисунок 1 — Исходные измерения ирисов и истинные виды

На проекции по размерам лепестков Setosa отделяется от двух других видов. Versicolor и Virginica частично перекрываются. Рисунок служит описанием данных; обучение и оценка всех моделей задействуют четыре признака. Средние и стандартные отклонения в таблице рассчитаны по всему CSV только для описания, а не для преобразования входов.

2 Методы и организация эксперимента

Одиночное дерево последовательно разбивает пространство условиями вида $x_j \le t$. Критерий — индекс Джини: чем ниже неоднородность классов в дочерних узлах, тем удачнее разбиение. Ограничение глубины уменьшает сложность правил.

$$G = 1 - \sum p^2$$

Случайный лес обучает деревья на bootstrap-выборках и на каждом разбиении рассматривает случайные подмножества признаков. Итоговый класс определяется по усреднённым вероятностям деревьев. Это снижает зависимость прогноза от отдельного дерева.

AdaBoost SAMME строит последовательность неглубоких деревьев и повышает веса ошибочно классифицированных объектов. Ответ формируется взвешенным голосованием. Использован вариант SAMME для трёх классов, а не бинарная формула AdaBoost.

CatBoost и XGBoost реализуют градиентный бустинг деревьев: ансамбль наращивается последовательно для уменьшения многоклассовой функции потерь. В программе применяются их библиотечные классификаторы. Признаки Iris числовые, поэтому специальные возможности CatBoost для категорий здесь не задействованы.

Модель	Основные параметры
Дерево	criterion=gini; max_depth=3
Случайный лес	300 деревьев; max_features=sqrt; bootstrap=True
AdaBoost	SAMME; 200 деревьев глубины 1; learning_rate=0,5
CatBoost	300 итераций; depth=4; learning_rate=0,05; MultiClass
XGBoost	300 раундов; max_depth=3; learning_rate=0,05; multi:softprob; hist

Разбиение train/test выполнено однократно в пропорции 70/30 при random_state=42 и stratify=y. Получено 105 обучающих объектов (по 35 каждого вида) и 45 тестовых (по 15). Масштабирование и PCA не применяются: деревья сравнивают отдельные признаки с порогами. Все пять методов получают одни и те же строки и признаки.

Параметры выбраны заранее и после просмотра теста не меняются. На train проведена пятикратная StratifiedKFold с shuffle=True и random_state=42: в каждом фолде 84 объекта для обучения и 21 для проверки. Затем каждая модель заново обучена на всех 105 объектах и один раз оценена на test. Кросс-валидация не использовалась для подбора параметров.

Во всех случайных компонентах задан seed=42; лес, CatBoost и XGBoost используют один вычислительный поток. Число раундов не означает одинаковой вычислительной сложности: например, XGBoost в стандартном многоклассовом режиме строит по дереву на каждый класс за раунд.

3 Сравнение точности

$$Accuracy = N\text{правильных} / N\text{тестовых}$$

Основная оценка — доля правильных ответов из 45. Macro-F1 усредняет F1 трёх видов с одинаковыми весами. Train accuracy приведена для сопоставления с тестом, но оценкой обобщающей способности не является.

Модель	Train accuracy	Test accuracy	Верно / 45	Macro-F1
Дерево	0,9810	0,9778	44	0,9778
Случайный лес	1,0000	0,9111	41	0,9107
AdaBoost	1,0000	0,9333	42	0,9333
CatBoost	1,0000	0,8889	40	0,8878
XGBoost	1,0000	0,9333	42	0,9333

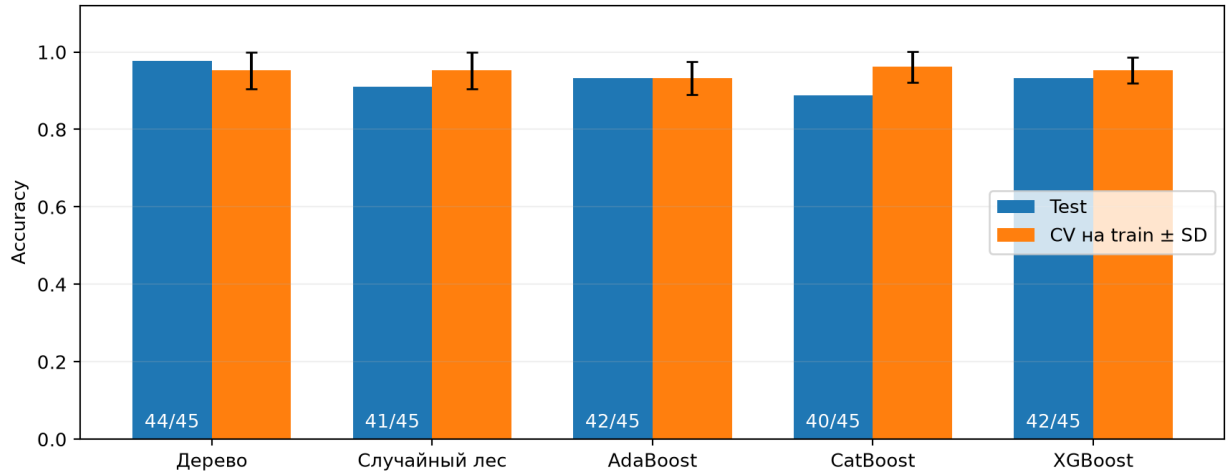


Рисунок 2 — Точность на тесте и при кросс-валидации train

Модель	CV accuracy ± SD	Ошибок на test	Обучение, с
Дерево	0,9524 ± 0,0476	1	0,0006
Случайный лес	0,9524 ± 0,0476	4	0,2414
AdaBoost	0,9333 ± 0,0426	3	0,2012
CatBoost	0,9619 ± 0,0398	5	0,0830
XGBoost	0,9524 ± 0,0337	3	0,0514

На графике приведено выборочное стандартное отклонение пяти оценок CV (ddof=1), а не доверительный интервал. Время измерено для единственного финального fit без кросс-валидации, импорта и построения графиков; оно зависит от оборудования и не является строгим сравнением скорости библиотек.

Одна ошибка на тесте меняет accuracy на 1/45 ≈ 0,0222, то есть на 2,22 процентного пункта. Поэтому малые различия на таком наборе следует трактовать осторожно. Результаты CV и test оцениваются на разных объектах и при разном объёме обучающей части.

4 Матрицы ошибок и разбор прогнозов

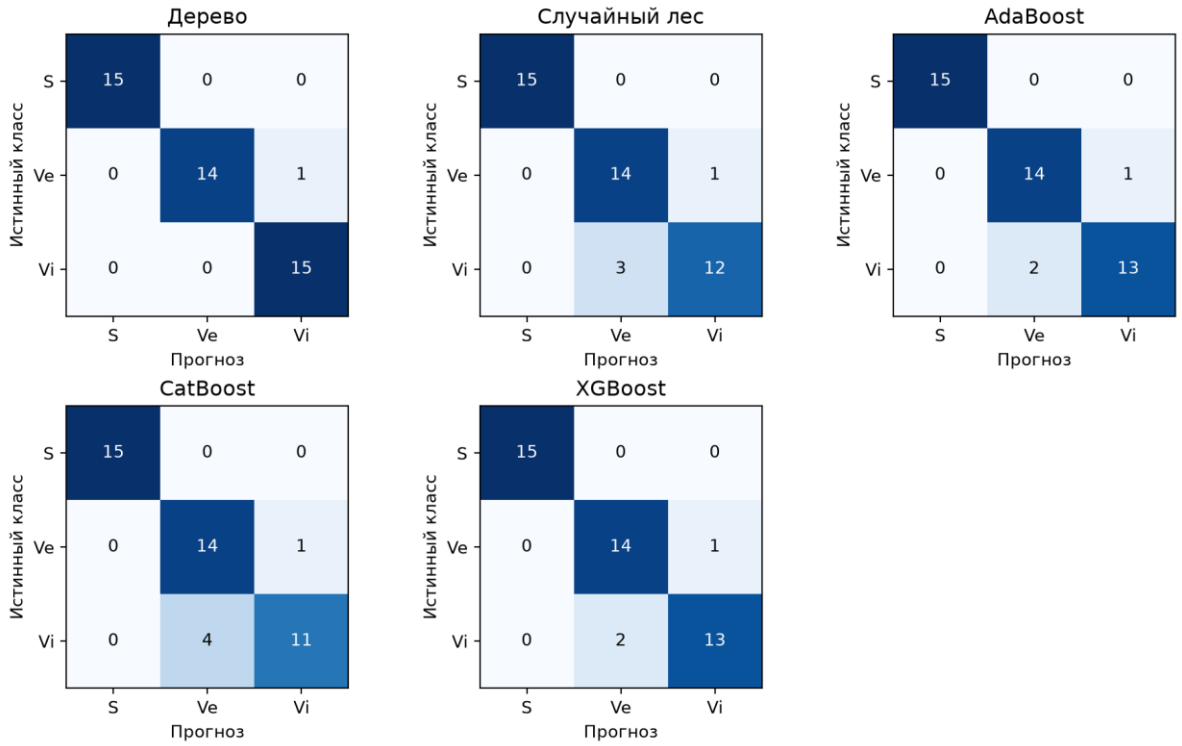


Рисунок 3 — Матрицы ошибок всех пяти классификаторов

Строки соответствуют истинным классам, столбцы — предсказанным. Обозначения: S — Setosa, Ve — Versicolor, Vi — Virginica. В каждой строке 15 объектов; сумма элементов каждой матрицы равна 45. Диагональные элементы — правильные ответы.

Дерево: Versicolor → Virginica: 1. Правильных ответов 44 из 45.
Случайный лес: Versicolor → Virginica: 1; Virginica → Versicolor: 3. Правильных ответов 41 из 45.
AdaBoost: Versicolor → Virginica: 1; Virginica → Versicolor: 2. Правильных ответов 42 из 45.
CatBoost: Versicolor → Virginica: 1; Virginica → Versicolor: 4. Правильных ответов 40 из 45.
XGBoost: Versicolor → Virginica: 1; Virginica → Versicolor: 2. Правильных ответов 42 из 45.

Полные precision, recall и F1 для каждого вида записываются в `results.json`. Файл `predictions.csv` содержит номер исходной строки CSV, истинный вид и ответы всех пяти моделей; заголовок CSV считается первой строкой. Это позволяет проверить каждую ошибку по исходным измерениям.

5 Интерпретация одиночного дерева

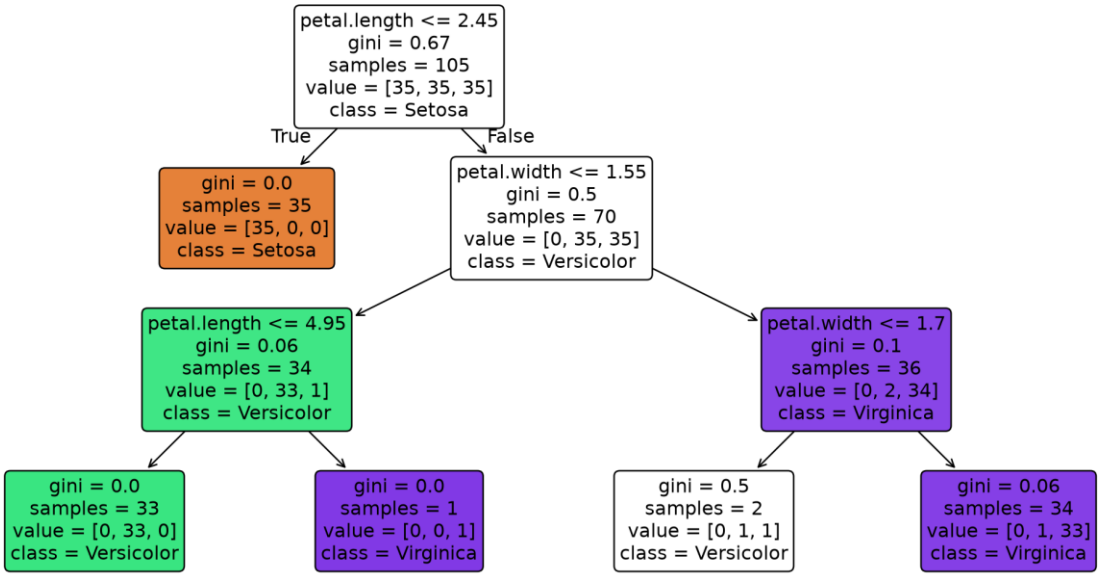


Рисунок 4 — Обученное дерево с ограничением глубины 3

Полученное дерево имеет глубину 3 и 5 листьев. В каждом узле указаны условие, неоднородность gini, число обучающих объектов samples, распределение value и выбранный класс. Значение value может отображаться как доли классов в зависимости от версии scikit-learn; samples остаётся числом объектов. Левая ветвь соответствует выполнению условия, правая — его нарушению.

Признак	Важность по уменьшению Джини
Длина чашелистика	0,0000
Ширина чашелистика	0,0000
Длина лепестка	0,5509
Ширина лепестка	0,4491

Важности вычислены по обучающим разбиениям одного дерева и нормированы так, что их сумма равна 1. Нулевая важность означает, что признак не использовался данным деревом, а не отсутствие его связи с видом ириса. Коррелирующие измерения могут подменять друг друга в правилах.

В отличие от ансамблей, дерево можно полностью проследить от корня к листу и объяснить отдельный прогноз через несколько порогов. Случайный лес и бустинг объединяют множество правил, поэтому одной компактной схемы для них недостаточно. Текстовое представление правил этого дерева сохраняется в `tree_rules.txt`.

6 Реализация и воспроизводимость

Вся программа находится в одном файле iad_lab5_variant1.py. В него встроена сжатая точная копия предоставленного iris.csv с проверкой SHA-256. Встроенный sklearn.datasets.load_iris не используется. Можно явно передать исходный файл через --csv; в этом случае проверяются структура, численность, классы и допустимость значений, а его SHA-256 записывается в результаты.

```
python -m pip install numpy scikit-learn matplotlib catboost xgboost

python iad_lab5_variant1.py

python iad_lab5_variant1.py --no-show

python iad_lab5_variant1.py --csv iris.csv --no-show

python iad_lab5_variant1.py --self-test
```

Обычный запуск выполняет 25 обучений внутри CV и пять финальных обучений, выводит метрики и открывает четыре графика. --no-show сохраняет графики без окон. Результаты помещаются в results_lab5 рядом с программой; --out позволяет выбрать другой каталог.

Файл результата	Содержимое
metrics.csv	Сводные метрики, CV и время fit
results.json	Версии, SHA-256, индексы, метрики и матрицы
predictions.csv	Истинные виды и пять прогнозов на test
tree_rules.txt	Пороговые правила одиночного дерева
Четыре PNG	Данные, сравнение, ошибки, дерево

Самопроверка контролирует целостность встроенных данных, отсутствие пересечений индексов train/test, покрытие объектов фолдами CV, доли классов, размерность и нормировку вероятностей. Для всех пяти моделей выполнено повторное обучение с теми же настройками и проверено совпадение прогнозов. Accuracy сверена с долей диагональных элементов матрицы ошибок.

В исходном CSV найдено 1 повторное наблюдение по всем четырём признакам и классу. Данные сохранены как в задании. Число тестовых строк с точным совпадением четырёх признаков с train: 0. Разбиение выполнено по строкам; повторные измерения следует учитывать при интерпретации, а не считать независимой проверкой на новой популяции.

7 Выводы

Выполнены все пункты варианта 6: загружен предоставленный Iris, изучены признаки и классы, выделены обучающая и тестовая части, обучены дерево, случайный лес, AdaBoost, CatBoost и XGBoost, рассчитана accuracy и проведено сравнение.

Наибольшая тестовая accuracy составила 0,9778 (44 правильных ответа из 45). Лучшей моделью по этой метрике стало дерево решений. На данном разбиении дерево оказалось точнее всех четырёх ансамблей.

По средней accuracy пятикратной кросс-валидации train наилучшее значение 0,9619 получено у CatBoost. Это дополнительное свидетельство в рамках фиксированного набора, а не основание объявлять статистически значимое превосходство. Настройки после сравнения не изменялись.

Для небольшого набора Iris простое дерево полезно своей наглядностью и небольшим числом правил. Лес снижает зависимость от одного дерева, но требует хранения ансамбля. AdaBoost, CatBoost и XGBoost дают альтернативные последовательные ансамбли; само по себе увеличение числа моделей не гарантирует роста точности на каждом разбиении.

Вывод о лучшем методе ограничен одним тестом, заданными гиперпараметрами и небольшой выборкой. Для дальнейшего исследования уместны повторные стратифицированные разбиения и подбор параметров внутри вложенной кросс-валидации с сохранением внешнего теста. В данной работе такой подбор не выполнялся.