Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №5
По дисциплине: «интеллектуальный анализ данных»
Тема: «Деревья решений»

Выполнил:
Студент 4 курса
Группы ИИ-26
Згера Е. А.
Проверил:
Никитин С. К.

Брест 2026

Цель работы: на практике сравнить работу нескольких алгоритмов одиночного дерева решений, случайного леса и бустинга для деревьев решений

Общее задание:

1. Загрузить датасет по варианту;
2. Разделить данные на обучающую и тестовую выборки;
3. Обучить на обучающей выборке одиночное дерево, случайный лес и реализовать бустинг для решающих деревьев (AdaBoost, CatBoost, XGBoost);
4. Оценить точность каждой модели на тестовой выборке;
5. Сравнить результаты, сделать выводы о применимости каждого метода для данного набора данных.

Вариант 5

- Mushroom Classification
- Определить, является ли гриб ядовитым или съедобным
- **Задания:**
    1. Загрузите данные и преобразуйте все категориальные признаки в числовые (например, с помощью One-Hot Encoding);
    2. Разделите данные на обучающую и тестовую части;
    3. Обучить на обучающей выборке одиночное дерево, случайный лес и реализовать бустинг для решающих деревьев (AdaBoost, CatBoost, XGBoost);
    4. Рассчитайте точность и полноту (precision и recall) для класса "ядовитый";
    5. Сделайте вывод о том, какой классификатор лучше всего справляется с этой задачей, где цена ошибки очень высока.

Ход работы

```
Размер данных: (8124, 23)
Пропуски: 0
Баланс классов:
 class
e    4208
p    3916

Признаков после One-Hot: 117

train: 5686, test: 2438


=== Результаты на тестовой выборке ===
```

МОДЕЛЬ	ACCURACY	PRECISION (ЯДОВИТЫЙ)	RECALL (ЯДОВИТЫЙ)	ПРОПУЩЕНО ЯДОВИТЫХ	ЛОЖНЫЕ ТРЕВОГИ	ВРЕМЯ, С
DECISION TREE	1.0000	1.0	1.0000	0	0	0.02
RANDOM FOREST	1.0000	1.0	1.0000	0	0	0.28
ADABOOST	1.0000	1.0	1.0000	0	0	1.72
XGBOOST	1.0000	1.0	1.0000	0	0	0.26
CATBOOST	0.9988	1.0	0.9974	3	0	0.72

```
Топ-10 признаков (Random Forest):
odor_n                        0.1409
odor_f                        0.0768
gill-size_n                   0.0657
stalk-surface-below-ring_k    0.0506
gill-size_b                   0.0479
stalk-surface-above-ring_k    0.0445
gill-color_b                  0.0384
spore-print-color_h           0.0382
bruises_f                     0.0272
ring-type_p                   0.0247

Process finished with exit code 0
```

Вывод по работе программы:

1. Набор данных очень простой. Классы разделяются почти полностью по нескольким категориальным признакам. Важнее всего запах (odor_n, odor_f), размер жабр, поверхность ножки и цвет споровой печати. Поэтому даже одиночное дерево даёт 100% на тесте и на всех 5 фолдах кросс-валидации, а ансамбли не дают выигрыша в качестве.

2. Для этой задачи главная метрика - recall по классу «ядовитый». Пропущенный ядовитый гриб (ошибка FN) опаснее, чем съедобный, принятый за ядовитый (FP). У четырёх моделей из пяти recall равен 1.0, то есть ни одного ядовитого гриба не пропущено. CatBoost пропустил 3 ядовитых гриба (recall 0.9974) при нулевых ложных тревогах. Для задачи с высокой ценой ошибки это неприемлемо, поэтому в такой конфигурации CatBoost использовать не стоит. Причина, вероятно, в настройках (300 итераций, глубина 4): модели не хватило сложности, и подбор параметров мог бы это исправить.

3. Какой метод выбрать.

- **Random Forest** - лучший выбор. Он безошибочен, обучается за доли секунды, усредняет много деревьев и потому устойчивее к шуму и к смещению распределения данных. Он также показывает важность признаков.
- **Decision Tree** безошибочен, быстрее всех и легко интерпретируется, так как правила можно прочитать целиком. Но одно дерево менее надёжно на новых данных, чем лес.
- **XGBoost** тоже даёт 100% при быстром обучении, но на таком простом наборе его сложность ничего не добавляет.
- **AdaBoost** безошибочен, но самый медленный (1.72 с), без выигрыша в качестве.
- **CatBoost** в текущей конфигурации хуже остальных и для данной задачи не подходит.

4. Ограничения. Идеальные метрики характеризуют простоту учебного набора, а не гарантию безопасности на реальных грибах. На данных из другого региона или с другим распределением качество может быть ниже. В реальном применении нужны проверка на независимых данных и порог классификации, смещённый в сторону «ядовитый», чтобы recall для этого класса оставался максимальным.

Итог: для этого датасета сложные ансамбли не нужны, а лучший баланс надёжности и простоты даёт случайный лес.

Вывод по лабораторной работе: на практике сравнил работу нескольких алгоритмов одиночного дерева решений, случайного леса и бустинга для деревьев решений.