Министерство образования Республики Беларусь

Учреждение образования

«Брестский государственный технический университет»

Кафедра ИИТ

Лабораторная работа №3

По дисциплине: «Интеллектуальный анализ данных»

Тема: «Предобучение нейронных сетей с использованием автоэнкодерного подхода»

Выполнил:

Студент 4 курса

Группы ИИ-26

Ковальчук А.

Проверил:

Никитин С. К.

Брест 2026

Цель работы

Научиться осуществлять предобучение нейронных сетей с помощью автоэнкодерного подхода.

Общее задание

1. Взять полносвязную архитектуру с числом слоёв более трёх. Обучить её без предобучения. Оценить F1 и матрицу ошибок.

2. Выполнить послойное предобучение автоэнкодерами (условие останова — число эпох) и последующий fine-tuning.

3. Сравнить обучение с предобучением и без него.

4. Повторить п. 1–3 для датасета из ЛР 2.

5. Оформить отчёт, загрузить код и отчёт в репозиторий.

Вариант 7. Датасет HCV for Egyptian patients (UCI, 1385 объектов, 28 признаков). Задача — классификация Baselinehistological staging (F1–F4). По п. 4 использован датасет грибов из ЛР 2 (8124 объекта, 117 признаков после one-hot, классы edible / poisonous). Реализация — PyTorch. Seed = 42, дополнительно 43 и 44.

Ход работы

Разбиение 70/15/15 со стратификацией. StandardScaler обучался только на train. Архитектура: вход → 128 → 64 → 32 → 16 → число классов. Baseline — случайная инициализация, CrossEntropy, Adam. Предобучение: AE1 in→128→in, AE2

128→64→128, AE3 64→32→64, AE4 32→16→32, MSE, 25 эпох (HCV) и 15 эпох (грибы). Веса энкодеров переносятся в MLP; голова обучается при замороженных слоях, затем сеть дообучается целиком.

Результаты

HCV. Классы почти равны (336 / 332 / 355 / 362). Пропусков нет. Максимальная |корреляция| признака со стадией равна 0,057. Случайный уровень accuracy на 4 классах ≈ 0,25.

Таблица 1 – HCV, тестовая выборка, seed = 42

Метод	Accuracy	Macro-F1	train F1	val F1
baseline	0,231	0,232	0,934	0,232
pretrained	0,288	0,288	0,447	0,228

Таблица 2 – HCV, среднее ± ст. откл. по сидам 42, 43, 44

Метод	Accuracy	Macro-F1
baseline	0,264 ± 0,032	0,260 ± 0,028
pretrained	0,237 ± 0,050	0,230 ± 0,059

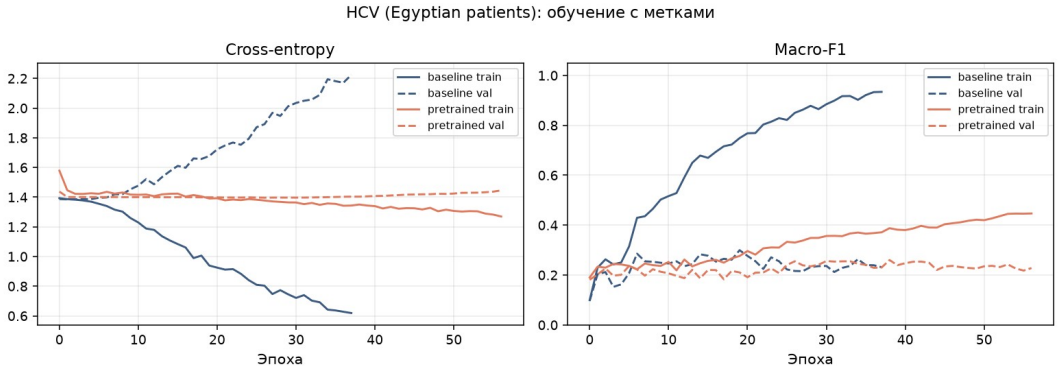


Рисунок 1 – HCV: кросс-энтропия и macro-F1 на train/val

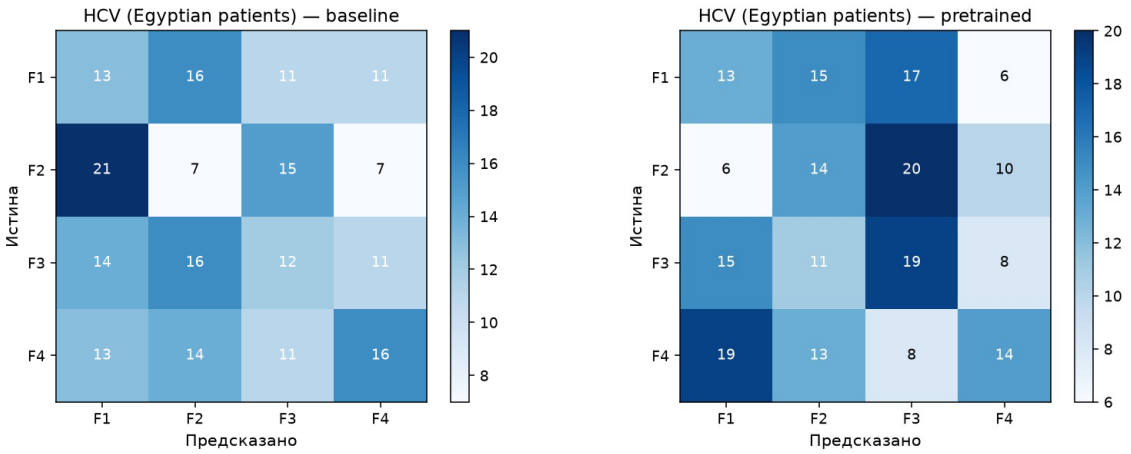


Рисунок 2 – HCV, матрицы ошибок: слева baseline, справа pretrained

Грибы (ЛР 2). Обе модели на полном наборе дают F1 ≈ 1. Предобучение не меняет итоговую метрику: задача линейно разделима после one-hot.

Таблица 3 – Грибы, тестовая выборка, среднее по трём сидам

Метод	Accuracy	Macro-F1
baseline	0,9995	0,9995
pretrained	0,9995	0,9995

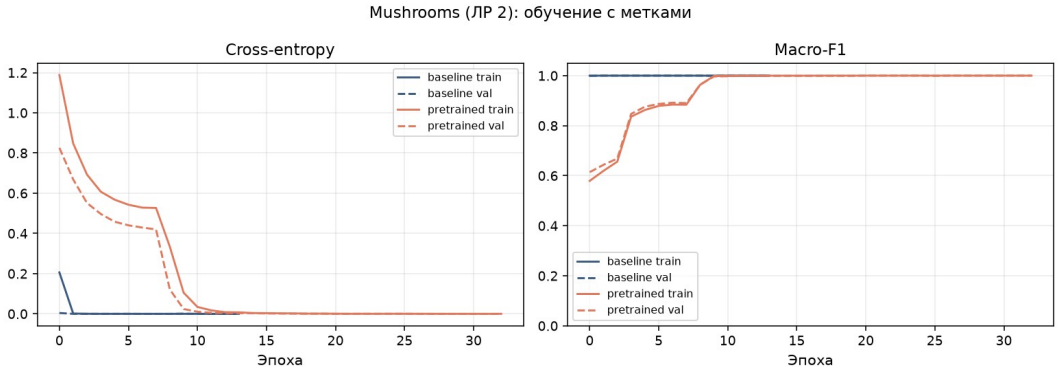


Рисунок 3 – Грибы: обучение baseline и pretrained

На рисунке 4 дополнительно показаны прогоны, где классификатор видел 30 % меток HCV и 2 % меток грибов; автоэнкодеры учились на всём train без меток.

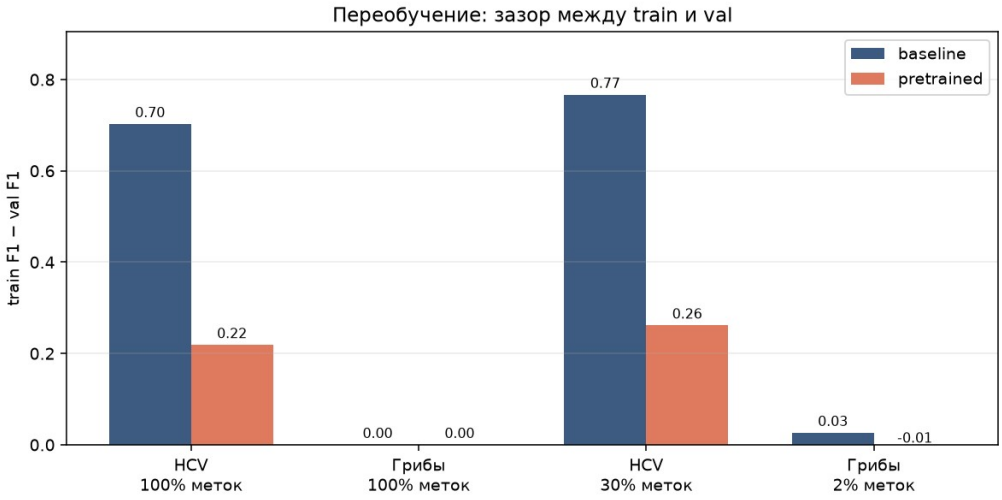


Рисунок 4 – Зазор train F1 − val F1

Выводы

1. На HCV обе модели дают accuracy 0,19–0,29 (случайный уровень ≈ 0,25). Признаки слабо связаны со стадией, предобучение F1 не поднимает.

2. Без предобучения сеть переобучается: train F1 = 0,93 при val F1 = 0,23. С предобучением зазор 0,45 / 0,23 (рисунок 4).

3. На грибах из ЛР 2 обе модели дают macro-F1 ≈ 1,00. Сравнивать методы по качеству нечего.

4. Автоэнкодерный старт не гарантирует рост метрик. На данной работе он проявляется как более устойчивое обучение, а не как лучший F1.