

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа № 1
По теме: «РСА»

Выполнил:
Студент 4 курса
Группы ИИ-26
Рудь В.В.
Проверил:
Никитин С.К.

Цель работы: научиться применять метод PCA для осуществления визуализации данных

15	wholesale+customers.zip	Region
----	-------------------------	--------

Задачи лабораторной работы:

1. Используя выборку по варианту, осуществить проецирование данных на плоскость первых двух и трех главных компонент (двумя способами: 1. вручную через использование `numpy.linalg.eig` для вычисления собственных значений и собственных векторов и 2. с помощью `sklearn.decomposition.PCA` для непосредственного применения метода PCA – два независимых варианта решения);
2. Выполнить визуализацию полученных главных компонент с использованием средств библиотеки `matplotlib`, обозначая экземпляры разных классов с использованием разных цветовых маркеров;
3. Используя собственные значения, рассчитанные на этапе 1, вычислить потери, связанные с преобразованием по методу PCA. Сделать выводы;
4. Оформить отчет по выполненной работе, загрузить исходный код и отчет в соответствующий репозиторий на github.

Код программы

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from mpl_toolkits.mplot3d import Axes3D
from sklearn.decomposition import PCA

# === 1. Загрузка данных ===
# Укажи путь к CSV внутри архива wholesale+customers.zip
# Например: data = pd.read_csv("Wholesale customers data.csv")
data = pd.read_csv("Wholesale customers data.csv")

# Класс для визуализации — колонка "Region"
labels = data["Region"]
X = data.drop(columns=["Region"])

# === 2. PCA вручную через numpy.linalg.eig ===
# Центрируем данные
X_centered = X - X.mean(axis=0)

# Ковариационная матрица
cov_matrix = np.cov(X_centered, rowvar=False)

# Собственные значения и векторы
eig_vals, eig_vecs = np.linalg.eig(cov_matrix)

# Сортировка по убыванию
idx = eig_vals.argsort()[::-1]
```

```

eig_vals = eig_vals[idx]
eig_vecs = eig_vecs[:, idx]

# Проекция на первые 2 и 3 компоненты
X_pca_manual_2D = np.dot(X_centered, eig_vecs[:, :2])
X_pca_manual_3D = np.dot(X_centered, eig_vecs[:, :3])

# === 3. PCA через sklearn ===
pca = PCA(n_components=3)
X_pca_sklearn = pca.fit_transform(X)

# === 4. Визуализация ===
def plot_2D(data_2d, labels, title):
    plt.figure(figsize=(8,6))
    for region in np.unique(labels):
        plt.scatter(data_2d[labels==region, 0],
                    data_2d[labels==region, 1],
                    label=f"Region {region}")
    plt.xlabel("PC1")
    plt.ylabel("PC2")
    plt.title(title)
    plt.legend()
    plt.show()

def plot_3D(data_3d, labels, title):
    fig = plt.figure(figsize=(8,6))
    ax = fig.add_subplot(111, projection='3d')
    for region in np.unique(labels):
        ax.scatter(data_3d[labels==region, 0],
                  data_3d[labels==region, 1],
                  data_3d[labels==region, 2],
                  label=f"Region {region}")
    ax.set_xlabel("PC1")
    ax.set_ylabel("PC2")
    ax.set_zlabel("PC3")
    ax.set_title(title)
    ax.legend()
    plt.show()

# Визуализация вручную
plot_2D(X_pca_manual_2D, labels.values, "PCA вручную (2D)")
plot_3D(X_pca_manual_3D, labels.values, "PCA вручную (3D)")

# Визуализация sklearn
plot_2D(X_pca_sklearn[:, :2], labels.values, "PCA sklearn (2D)")
plot_3D(X_pca_sklearn, labels.values, "PCA sklearn (3D)")

# === 5. Потери информации ===
explained_variance_ratio = pca.explained_variance_ratio_
print("Доля объяснённой дисперсии по компонентам:", explained_variance_ratio)
print("Суммарная сохранённая дисперсия:", explained_variance_ratio.sum())
print("Потери информации:", 1 - explained_variance_ratio.sum())

```

Результат программы








Figure 1



(x, y) = (3.11e+04, 8.52e+04)

Figure 1



```
Доля объяснённой дисперсии по компонентам: [0.45961362 0.40517227 0.07003008]
Суммарная сохранённая дисперсия: 0.9348159651011619
Потери информации: 0.06518403489883806

Process finished with exit code 0
```

Вывод: В ходе выполнения работы был реализован метод анализа главных компонент (РСА) двумя способами: вручную через вычисление собственных значений и векторов ковариационной матрицы, а также с использованием библиотеки `sklearn.decomposition.PCA`. Оба подхода показали согласующиеся результаты, что подтверждается визуализацией данных в двумерном и трёхмерном пространстве главных компонент.

- Визуализация позволила наглядно разделить экземпляры по классам (Region), что облегчает анализ структуры данных и выявление кластеров.
- Сохранённая дисперсия составила около 93,5%, а потери информации — примерно 6,5%. Это свидетельствует о высокой эффективности метода РСА для данного набора данных: первые три компонента описывают почти всю вариацию признаков.
- Сравнение методов показало, что использование готовых библиотек значительно упрощает процесс, однако ручная реализация позволяет глубже понять математическую основу метода.

Таким образом, поставленные задачи выполнены: данные успешно проецированы на главные компоненты, проведена визуализация, рассчитаны потери информации и сделаны аналитические выводы. Метод РСА подтвердил свою применимость для снижения размерности и выявления скрытых закономерностей в выборке Wholesale customers.