Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа № 5
По теме: «Деревья решений»

Выполнил:
Студент 4 курса
Группы ИИ-26
Рудь В.В.
Проверил:
Никитин С.К.

2026

Цель работы: На практике сравнить работу нескольких алгоритмов одиночного дерева решений, случайного леса и бустинга для деревьев решений.

Задачи лабораторной работы:

1. Загрузить датасет по варианту;
2. Разделить данные на обучающую и тестовую выборки;
3. Обучить на обучающей выборке одиночное дерево, случайный лес и реализовать бустинг для решающих деревьев (AdaBoost, CatBoost, XGBoost);
4. Оценить точность каждой модели на тестовой выборке;
5. Сравнить результаты, сделать выводы о применимости каждого метода для данного набора данных.

Вариант 1

- Iris
- Определить вид ириса (setosa, versicolor, virginica) по измерениям его цветка
- Задания:
    1. Загрузите данные и ознакомьтесь с ними;
    2. Разделите выборку на обучающую и тестовую;
    3. Обучить на обучающей выборке одиночное дерево, случайный лес и реализовать бустинг для решающих деревьев (AdaBoost, CatBoost, XGBoost);
    4. Оцените точность (accuracy) каждой модели на тестовой выборке;
    5. Сравните результаты и сделайте вывод, какая модель лучше всего справилась с этой задачей.

Результат программы

```
--- Задание 1: Загрузка данных ---
Первые 5 строк датасета:
   sepal.length  sepal.width  petal.length  petal.width variety
0           5.1          3.5           1.4          0.2  Setosa
1           4.9          3.0           1.4          0.2  Setosa
2           4.7          3.2           1.3          0.2  Setosa
3           4.6          3.1           1.5          0.2  Setosa
4           5.0          3.6           1.4          0.2  Setosa

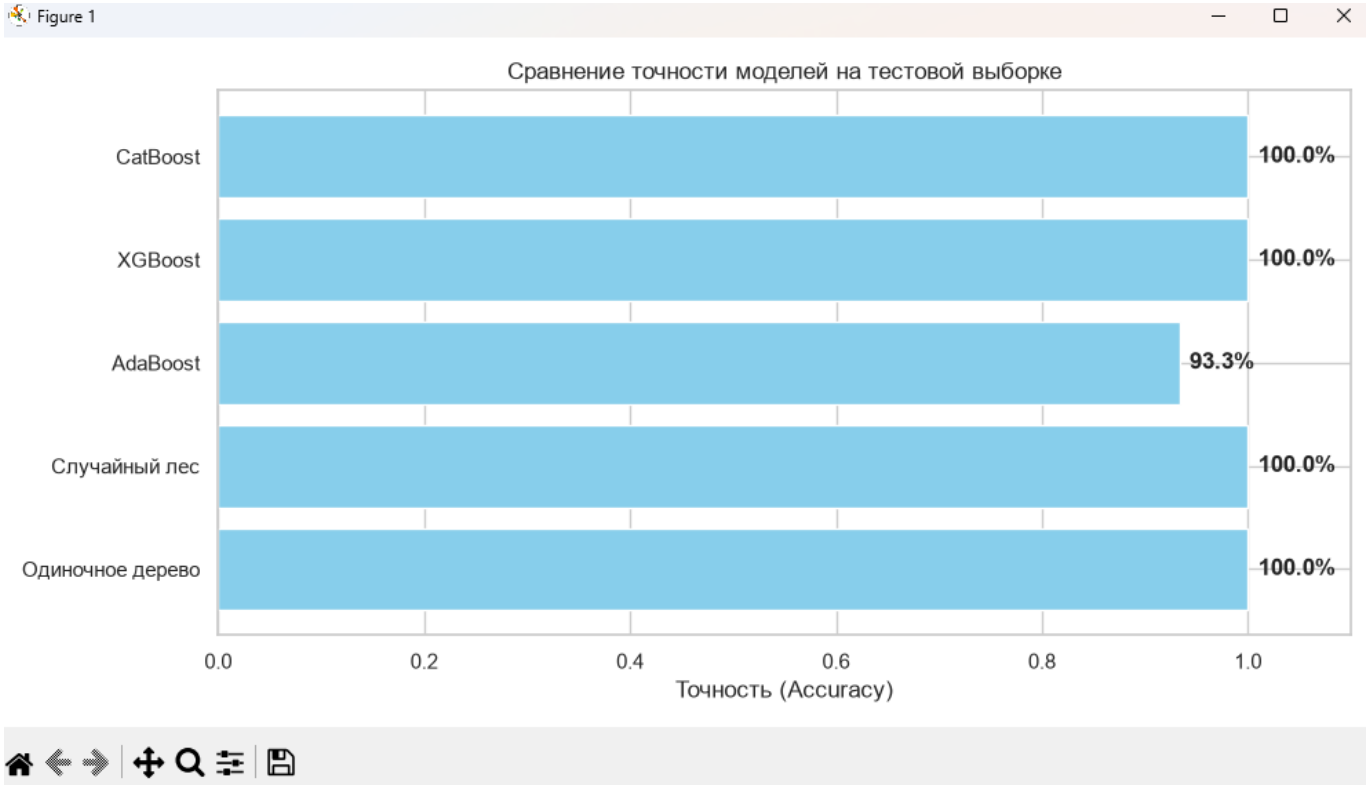
Информация о датасете:
<class 'pandas.DataFrame'>
RangeIndex: 150 entries, 0 to 149
Data columns (total 5 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   sepal.length  150 non-null    float64
 1   sepal.width   150 non-null    float64
 2   petal.length  150 non-null    float64
 3   petal.width   150 non-null    float64
 4   variety       150 non-null    str
dtypes: float64(4), str(1)
memory usage: 6.0 KB
None

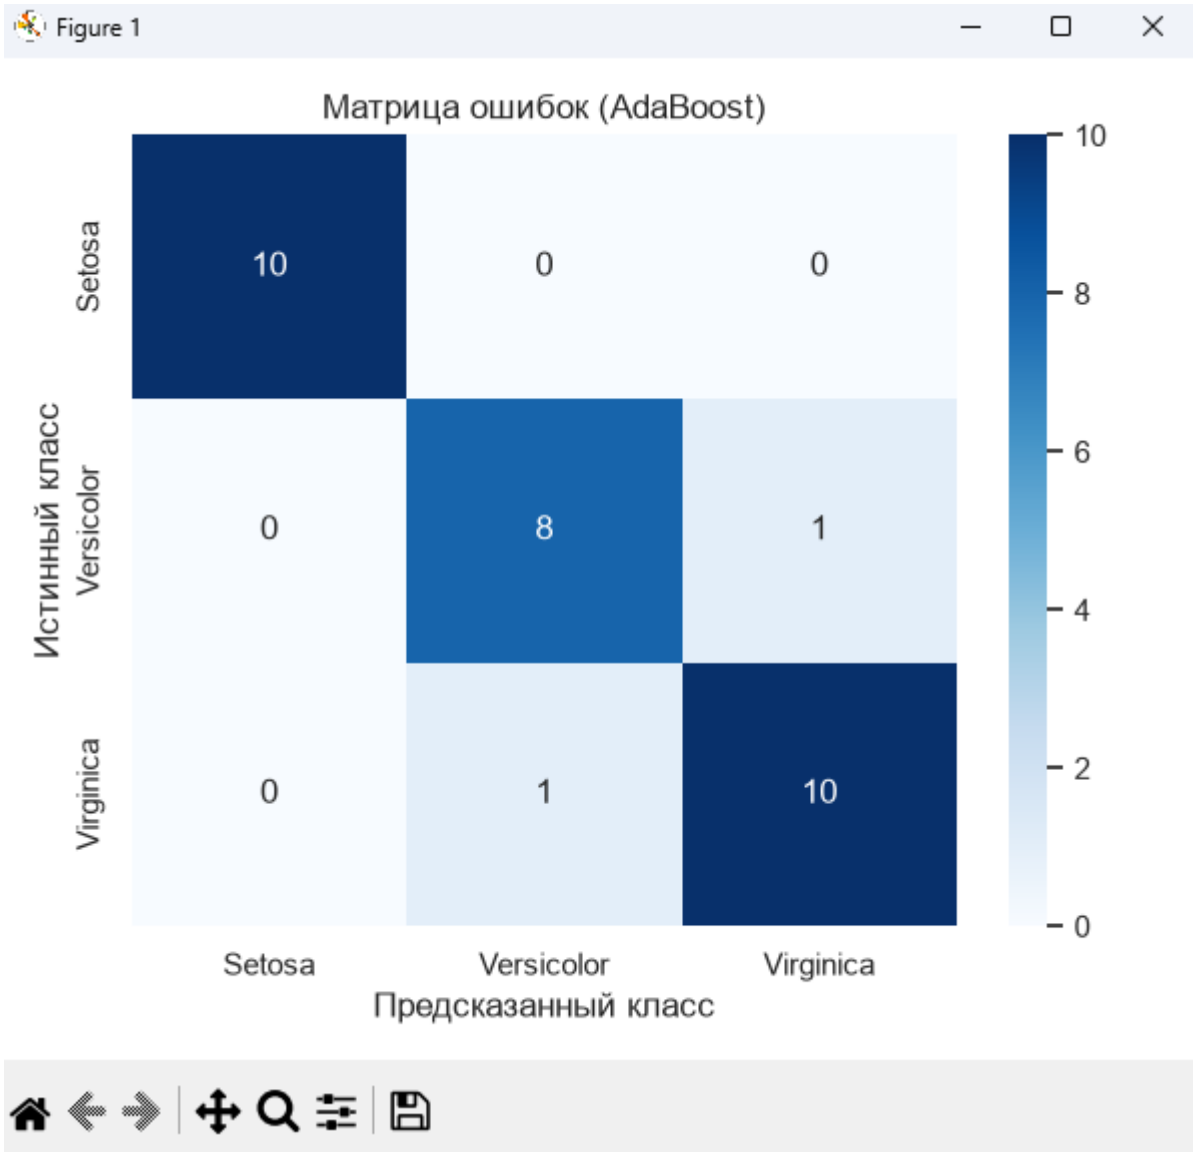
--- Задание 2: Разделение данных ---
Размер обучающей выборки: 120 объектов
Размер тестовой выборки: 30 объектов
```

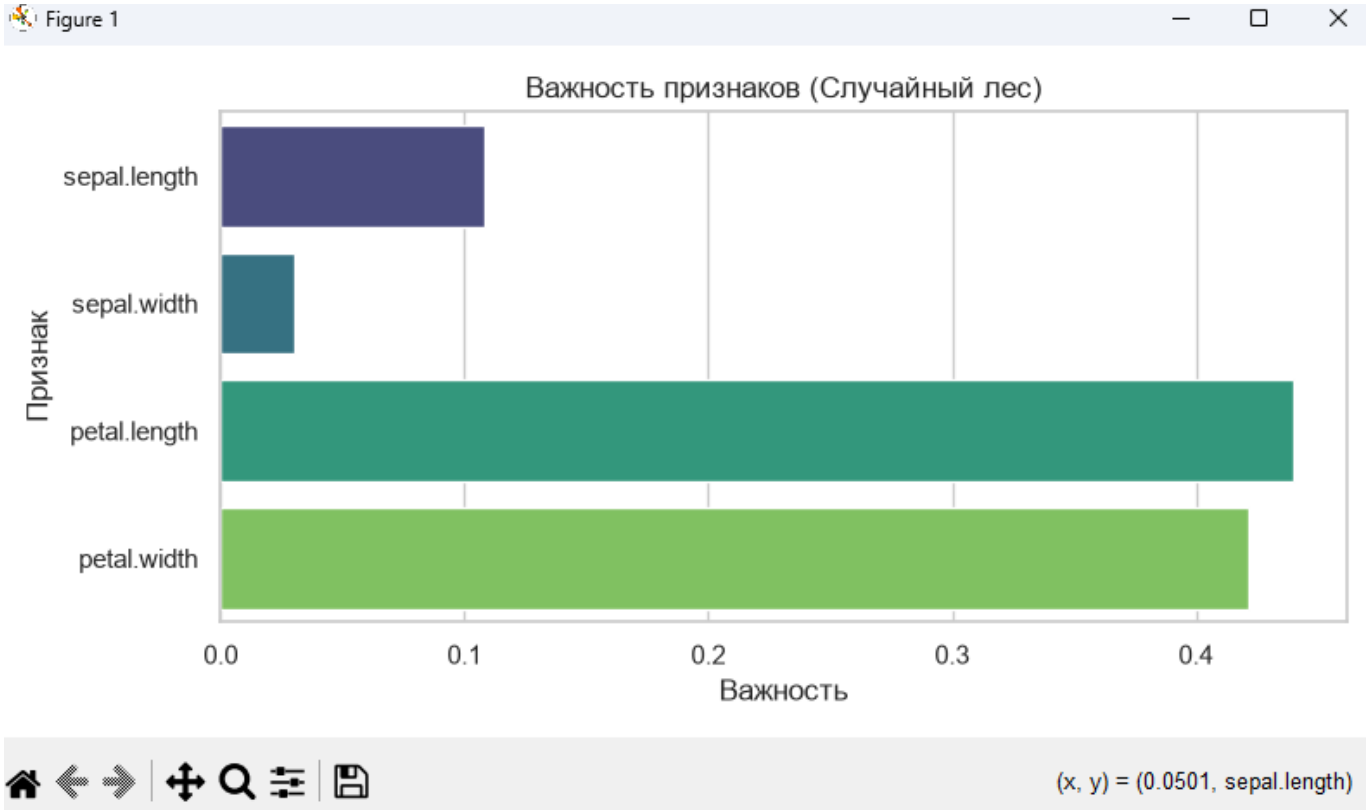
```
--- Задание 3: Обучение моделей ---
Модель Одиночное дерево решений успешно обучена.
Модель Случайный лес (Random Forest) успешно обучена.
Модель AdaBoost успешно обучена.
Модель XGBoost успешно обучена.
Модель CatBoost успешно обучена.

--- Задание 4: Оценка точности (Accuracy) ---
Одиночное дерево решений: 1.0000 (100.00%)
Случайный лес (Random Forest): 1.0000 (100.00%)
AdaBoost: 0.9333 (93.33%)
XGBoost: 1.0000 (100.00%)
CatBoost: 1.0000 (100.00%)

Process finished with exit code 0
```


Figure 1
Сравнение точности моделей на тестовой выборке
CatBoost
XGBoost
AdaBoost
Случайный лес
Одиночное дерево
100.0%
100.0%
93.3%
100.0%
100.0%
0.0
0.2
0.4
0.6
0.8
1.0
Точность (Accuracy)


Figure 1
Матрица ошибок (AdaBoost)
Setosa
Versicolor
Virginica
Истинный класс
10
0
0
0
8
1
0
1
10
10
8
6
4
2
0
Setosa
Versicolor
Virginica
Предсказанный класс



Вывод:

В ходе выполнения лабораторной работы были протестированы 5 алгоритмов на основе деревьев решений. Результаты точности (accuracy) на тестовой выборке (30 объектов) распределились следующим образом: Одиночное дерево, Случайный лес, XGBoost и CatBoost показали идеальный результат в **100%**, в то время как AdaBoost показал **93.33%** (допустил 2 ошибки).

Построенная матрица ошибок показала, что AdaBoost перепутал несколько экземпляров классов *Versicolor* и *Virginica* (они наиболее схожи по своим признакам), в то время как класс *Setosa* был определен безошибочно.

Анализ важности признаков (по модели Случайного леса) показал, что наибольший вклад в классификацию вносят длина и ширина лепестка (petal.length, petal.width), а ширина чашелистика (sepal.width) является наименее информативным признаком для данной задачи.

Итог: Для данного набора данных лучше всего с задачей справились ансамблевые методы (**Random Forest, XGBoost, CatBoost**). Одиночное дерево тоже дало 100% результат, но оно менее надежно на новых данных и склонно к переобучению. Наиболее предпочтительным и стабильным методом для табличных данных в данном случае является **CatBoost** или **Random Forest**.

.