Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа № 5
За седьмой семестр
По дисциплине: «Интеллектуальный анализ данных »
Тема: «Деревья решений»

Выполнил:
Студент 4 курса
Группы ИИ-26
Хомиченко И.А.
Проверил:
Никитин С.К.

2026

Цель: На практике сравнить работу нескольких алгоритмов одиночного дерева решений, случайного леса и бустинга для деревьев решений.

Задачи:

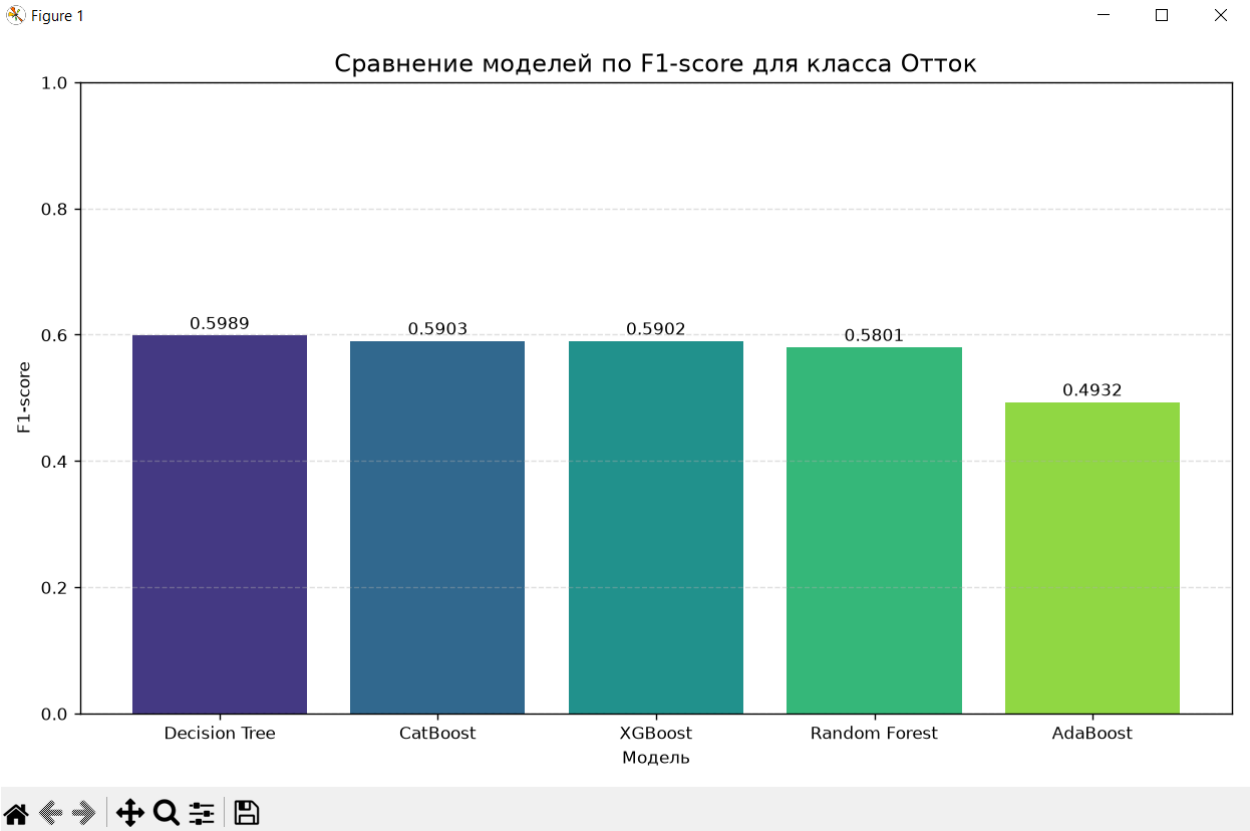
1. Загрузить датасет по варианту;
2. Разделить данные на обучающую и тестовую выборки;
3. Обучить на обучающей выборке одиночное дерево, случайный лес и реализовать бустинг для решающих деревьев (AdaBoost, CatBoost, XGBoost);
4. Оценить точность каждой модели на тестовой выборке;
5. Сравнить результаты, сделать выводы о применимости каждого метода для данного набора данных.

Вариант 7

- Telco Customer Churn
- Предсказать, откажется ли клиент от услуг телеком-оператора
- **Задания:**
    1. Загрузите данные, обработайте категориальные признаки и пропуски;
    2. Разделите данные на обучающую и тестовую выборки;
    3. Обучить на обучающей выборке одиночное дерево, случайный лес и реализовать бустинг для решающих деревьев (AdaBoost, CatBoost, XGBoost);
    4. Сравните модели по метрике F1-score для класса "отток";
    5. Сделайте вывод о применимости каждого из методов для решения бизнес-задачи по удержанию клиентов.

Код программы в файле main.py

Результат программы:



1. ПРОВЕРКА CUDA

Обнаружена видеокарта:

NVIDIA GeForce RTX 3050 Laptop GPU

CatBoost: GPU

XGBoost: GPU (проверка при обучении)

2. ЗАГРУЗКА ДАННЫХ

Размер датасета: (7043, 21)

Первые 5 строк:

```
   customerID  gender  SeniorCitizen  ... MonthlyCharges TotalCharges  Churn
0  7590-VHVEG  Female              0  ...          29.85        29.85     No
1  5575-GNVDE    Male              0  ...          56.95       1889.5     No
2  3668-QPYBK    Male              0  ...          53.85       108.15    Yes
3  7795-CFOCW    Male              0  ...          42.30      1840.75     No
4  9237-HQITU  Female              0  ...          70.70       151.65    Yes

[5 rows x 21 columns]
```

Информация о данных:

```
<class 'pandas.DataFrame'>
RangeIndex: 7043 entries, 0 to 7042
Data columns (total 21 columns):
 #   Column            Non-Null Count  Dtype
0   customerID        7043 non-null   str
 1   gender            7043 non-null   str
 2   SeniorCitizen     7043 non-null   int64
 3   Partner           7043 non-null   str
 4   Dependents        7043 non-null   str
 5   tenure            7043 non-null   int64
 6   PhoneService      7043 non-null   str
 7   MultipleLines     7043 non-null   str
 8   InternetService   7043 non-null   str
 9   OnlineSecurity    7043 non-null   str
 10  OnlineBackup      7043 non-null   str
 11  DeviceProtection  7043 non-null   str
```

12 TechSupport 7043 non-null str

13 StreamingTV 7043 non-null str

14 StreamingMovies 7043 non-null str

15 Contract 7043 non-null str

16 PaperlessBilling 7043 non-null str

17 PaymentMethod 7043 non-null str

18 MonthlyCharges 7043 non-null float64

19 TotalCharges 7043 non-null str

20 Churn 7043 non-null str

dtypes: float64(1), int64(2), str(18)

memory usage: 1.1 MB

Распределение Churn:

Churn

No 5174

Yes 1869

Name: count, dtype: int64

Доли классов:

Churn

No 0.73463

Yes 0.26537

Name: proportion, dtype: float64

3. ПРЕДОБРАБОТКА ДАННЫХ

Пропущенные значения:

customerID 0

gender 0

SeniorCitizen 0

Partner 0

Dependents 0

tenure 0

PhoneService 0

MultipleLines 0

InternetService 0

OnlineSecurity 0

OnlineBackup 0

DeviceProtection 0

TechSupport 0

StreamingTV 0

StreamingMovies 0

Contract 0

PaperlessBilling 0

PaymentMethod 0

MonthlyCharges 0

TotalCharges 11

Churn 0

dtype: int64

Количество признаков: 19

4. РАЗДЕЛЕНИЕ ВЫБОРКИ

Обучающая выборка: 5634

Тестовая выборка: 1409

Распределение классов в обучающей выборке:

Churn

0 4139

1 1495

Name: count, dtype: int64

Распределение классов в тестовой выборке:

Churn

0 1035

1 374

Name: count, dtype: int64

5. ОБРАБОТКА ПРИЗНАКОВ

Числовые признаки:

['SeniorCitizen', 'tenure', 'MonthlyCharges', 'TotalCharges']

Категориальные признаки:

['gender', 'Partner', 'Dependents', 'PhoneService', 'MultipleLines', 'InternetService', 'OnlineSecurity', 'OnlineBackup', 'DeviceProtection', 'TechSupport', 'StreamingTV', 'StreamingMovies', 'Contract', 'PaperlessBilling', 'PaymentMethod']

6. СОЗДАНИЕ МОДЕЛЕЙ

7. ОБУЧЕНИЕ И ОЦЕНКА МОДЕЛЕЙ

Обучение модели: Decision Tree

Обучение выполнено на CPU

Accuracy: 0.7984

Precision: 0.6347

Recall: 0.5668

F1-score: 0.5989

Отчет классификации:

	precision	recall	f1-score	support
Нет оттока	0.85	0.88	0.87	1035
Отток	0.63	0.57	0.60	374
accuracy			0.80	1409
macro avg	0.74	0.72	0.73	1409
weighted avg	0.79	0.80	0.79	1409

Обучение модели: Random Forest

Обучение выполнено на CPU

Accuracy: 0.8027

Precision: 0.6667

Recall: 0.5134

F1-score: 0.5801

Отчет классификации:

	precision	recall	f1-score	support
Нет оттока	0.84	0.91	0.87	1035
Отток	0.67	0.51	0.58	374
accuracy			0.80	1409
macro avg	0.75	0.71	0.73	1409
weighted avg	0.79	0.80	0.79	1409

Обучение модели: AdaBoost

Обучение выполнено на CPU

Accuracy: 0.7871

Precision: 0.6697

Recall: 0.3904

F1-score: 0.4932

Отчет классификации:

	precision	recall	f1-score	support
Нет оттока	0.81	0.93	0.87	1035
Отток	0.67	0.39	0.49	374
accuracy			0.79	1409
macro avg	0.74	0.66	0.68	1409
weighted avg	0.77	0.79	0.77	1409

Обучение модели: CatBoost

CatBoost обучен на GPU

Accuracy: 0.8020

Precision: 0.6547

Recall: 0.5374

F1-score: 0.5903

Отчет классификации:

	precision	recall	f1-score	support
Нет оттока	0.84	0.90	0.87	1035
Отток	0.65	0.54	0.59	374
accuracy			0.80	1409
macro avg	0.75	0.72	0.73	1409
weighted avg	0.79	0.80	0.80	1409

Обучение модели: XGBoost

XGBoost: обучение завершено с запросом CUDA

Использование GPU зависит от сборки XGBoost

  return func(**kwargs)

Accuracy: 0.8048

Precision: 0.6667

Recall: 0.5294

F1-score: 0.5902

Отчет классификации:

	precision	recall	f1-score	support
Нет оттока	0.84	0.90	0.87	1035
Отток	0.67	0.53	0.59	374
accuracy			0.80	1409
macro avg	0.75	0.72	0.73	1409
weighted avg	0.80	0.80	0.80	1409

8. СРАВНЕНИЕ МОДЕЛЕЙ

ИТОГОВАЯ ТАБЛИЦА:

Model	Accuracy	Precision	Recall	F1-score
Decision Tree	0.7984	0.6347	0.5668	0.5989
CatBoost	0.8020	0.6547	0.5374	0.5903
XGBoost	0.8048	0.6667	0.5294	0.5902
Random Forest	0.8027	0.6667	0.5134	0.5801
AdaBoost	0.7871	0.6697	0.3904	0.4932

9. ОПРЕДЕЛЕНИЕ ЛУЧШЕЙ МОДЕЛИ

Лучшая модель: Decision Tree

F1-score лучшей модели: 0.5989

Анализ результатов: В ходе лабораторной работы обучены пять моделей: Decision Tree, Random Forest, AdaBoost, CatBoost и XGBoost.

Для оценки качества использовались Accuracy, Precision, Recall и F1-score.

Наибольший F1-score для класса 'Отток' получила модель Decision Tree: 0.5989.

Для удержания клиентов особенно важен Recall, поскольку он показывает долю обнаруженных клиентов, которые действительно ушли.

Precision позволяет оценить, какая доля клиентов с прогнозом оттока действительно относится к группе уходящих.

При выборе модели для практического применения нужно учитывать F1-score и стоимость ошибок.

Вывод: на практике сравнил работу нескольких алгоритмов одиночного дерева решений, случайного леса и бустинга для деревьев решений