Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа № 5

За седьмой семестр

По дисциплине «Интеллектуальный анализ данных»

Тема: «Деревья решений»

Выполнил:
Студент 4 курса
Группы ИИ-26
Черноиван А.Н.
Проверил:
Никитин С.К.

2026

Цель: на практике сравнить работу нескольких алгоритмов одиночного дерева решений, случайного леса и бустинга для деревьев решений.

Задачи:

1. Загрузить датасет по варианту;
2. Разделить данные на обучающую и тестовую выборки;
3. Обучить на обучающей выборке одиночное дерево, случайный лес и реализовать бустинг для решающих деревьев (AdaBoost, CatBoost, XGBoost);
4. Оценить точность каждой модели на тестовой выборке;
5. Сравнить результаты, сделать выводы о применимости каждого метода для данного набора данных.

Вариант 8

- `Seeds`
- Классифицировать семена на три сорта пшеницы (Kama, Rosa, Canadian) на основе их геометрических параметров
- **Задания:**
    1. Загрузите и стандартизируйте данные;
    2. Разделите выборку на обучающую и тестовую;
    3. Обучить на обучающей выборке одиночное дерево, случайный лес и реализовать бустинг для решающих деревьев (AdaBoost, CatBoost, XGBoost);
    4. Сравните общую точность (accuracy) всех трех моделей;
    5. Визуализируйте данные в 2D (например, с помощью PCA), раскрасив точки в соответствии с предсказаниями лучшей модели.

Результаты:

```
(.venv) anastasiacernoivan@MacBook-Pro-Anastasia lab5 % python 5.py
seeds_dataset.txt

Размер данных: (210, 8)

Пропуски: 0

class

Kama        70

Rosa        70

Canadian    70

Name: count, dtype: int64


Decision Tree  accuracy = 0.8889   (обучение 0.00 с)

Random Forest  accuracy = 0.9206   (обучение 0.10 с)

AdaBoost       accuracy = 0.8413   (обучение 0.13 с)

XGBoost        accuracy = 0.8730   (обучение 0.43 с)

CatBoost       accuracy = 0.8889   (обучение 0.18 с)
```

Сравнение моделей по accuracy:

Random Forest	0.9206
Decision Tree	0.8889
CatBoost	0.8889
XGBoost	0.8730
AdaBoost	0.8413

Лучшая модель: Random Forest (0.9206)

classification_report для Random Forest:

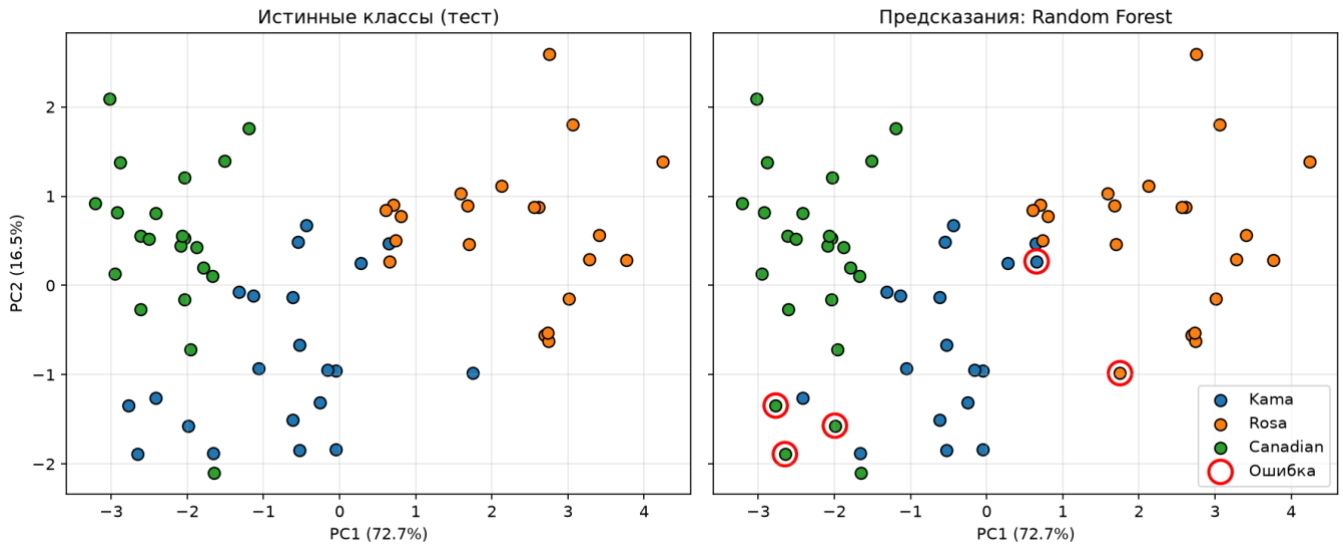
	precision	recall	f1-score	support
Kama	0.94	0.81	0.87	21
Rosa	0.95	0.95	0.95	21
Canadian	0.88	1.00	0.93	21
accuracy			0.92	63
macro avg	0.92	0.92	0.92	63
weighted avg	0.92	0.92	0.92	63

Кросс-валидация (5 folds), средняя accuracy ± std:

Decision Tree	0.8952 ± 0.0490
Random Forest	0.9143 ± 0.0387
AdaBoost	0.9238 ± 0.0316
XGBoost	0.9143 ± 0.0490
CatBoost	0.9238 ± 0.0316

График сохранён: pca_best_model.png

(.venv) anastasiacernoivan@MacBook-Pro-Anastasia lab5 %



Вывод: В ходе работы сравнили одиночное дерево, случайный лес, AdaBoost, XGBoost и CatBoost на датасете Seeds: на тестовой выборке лучшую accuracy показал случайный лес (0.921), одиночное дерево и CatBoost дали 0.889, XGBoost 0.873, AdaBoost 0.841. Тестовая выборка мала (63 объекта), поэтому разница в 1-2 ошибки не значима, а по кросс-валидации все ансамбли дают 0.91-0.92 и превосходят одиночное дерево (0.895), так что для этого набора применимы все методы. На PCA-графике ошибки лучшей модели в основном приходятся на сорт Kama (recall 0.81), чьи признаки пересекаются с сортом Canadian.