

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа № 1
За седьмой семестр
Тема: «РСА»

Выполнил:
Студент 4 курса
Группы ИИ-26
Шарубнёв Д.С.
Проверил:
Никитин С.К.

Цель: научиться применять метод PCA для осуществления визуализации данных

Задание:

1. Используя выборку по варианту, осуществить проецирование данных на плоскость первых двух и трех главных компонент (двумя способами: 1. вручную через использование `numpy.linalg.eig` для вычисления собственных значений и собственных векторов и 2. с помощью `sklearn.decomposition.PCA` для непосредственного применения метода PCA – два независимых варианта решения);
2. Выполнить визуализацию полученных главных компонент с использованием средств библиотеки `matplotlib`, обозначая экземпляры разных классов с использованием разных цветовых маркеров;
3. Используя собственные значения, рассчитанные на этапе 1, вычислить потери, связанные с преобразованием по методу PCA. Сделать выводы;
4. Оформить отчет по выполненной работе, загрузить исходный код и отчет в соответствующий репозиторий на github.

Ход работы

9	heart+failure+clinical+records.zip	death event
---	------------------------------------	-------------

Код программы:

В электронном виде

Результат работы программы:

Первые строки:

```
age anaemia creatinine_phosphokinase ... smoking time DEATH_EVENT
0 75.0    0                582 ...    0  4      1
1 55.0    0                7861 ...   0  6      1
2 65.0    0                146 ...    1  7      1
3 50.0    1                111 ...    0  7      1
4 65.0    1                160 ...    0  8      1
```

[5 rows x 13 columns]

Информация о данных:

<class 'pandas.DataFrame'>

RangeIndex: 299 entries, 0 to 298

Data columns (total 13 columns):

#	Column	Non-Null Count	Dtype
0	age	299 non-null	float64
1	anaemia	299 non-null	int64

2 creatinine_phosphokinase 299 non-null int64
3 diabetes 299 non-null int64
4 ejection_fraction 299 non-null int64
5 high_blood_pressure 299 non-null int64
6 platelets 299 non-null float64
7 serum_creatinine 299 non-null float64
8 serum_sodium 299 non-null int64
9 sex 299 non-null int64
10 smoking 299 non-null int64
11 time 299 non-null int64
12 DEATH_EVENT 299 non-null int64

dtypes: float64(3), int64(10)

memory usage: 30.5 KB

None

Пропуски:

age 0
anaemia 0
creatinine_phosphokinase 0
diabetes 0
ejection_fraction 0
high_blood_pressure 0
platelets 0
serum_creatinine 0
serum_sodium 0
sex 0
smoking 0
time 0
DEATH_EVENT 0
dtype: int64

Собственные значения sklearn:

[1.66854625 1.5843945 1.27239806 1.11968295 1.03333917 0.99219419
0.88632232 0.84812523 0.76658155 0.71018618 0.64617272 0.51232534]

Доля объяснённой дисперсии sklearn:



[0.13858049 0.13159129 0.10567855 0.09299485 0.0858236 0.08240632
0.07361317 0.07044072 0.06366814 0.05898425 0.05366763 0.04255099]

Доля сохранённой дисперсии (2 компоненты): 0.2702+0.0000j

Потери (2 компоненты): 0.7298+0.0000j

Доля сохранённой дисперсии (3 компоненты): 0.3759+0.0000j

Потери (3 компоненты): 0.6241+0.0000j



Вывод: научился применять метод PCA для осуществления визуализации данных